

修士論文

時系列補間型学習データに基づく
疎パイロット下の無線チャネル予測機構

指導教員 森川 博之 教授



東京大学大学院工学系研究科
電気系工学専攻

氏名 37-246529 松橋 悠

提出日 2025年1月22日

目次

第 1 章	序論	1
1.1	本論文の背景と目的	2
1.2	本論文の構成	3
第 2 章	5G NR 物理層におけるチャネル予測	4
2.1	はじめに	5
2.2	5G NR の物理層における無線伝送処理	5
2.2.1	リソースグリッド	5
2.2.2	チャネル推定	9
2.2.3	プリコーディング	10
2.2.4	ビームフォーミング	11
2.3	チャネル予測の動作原理	13
2.4	関連研究	14
2.5	おわりに	17
第 3 章	チャネル予測モデルの重み更新に向けた補間手法比較	19
3.1	はじめに	20
3.2	CSI の時系列補間手法	20
3.2.1	線形補間	21
3.2.2	スプライン補間	21
3.2.3	多項式近似	21
3.2.4	ニューラルネットワークによる補間	22
3.3	シミュレーション	23
3.3.1	地形データと Sionna によるレイトレーシング	24
3.3.2	シミュレーション条件	32

3.4	地形ごとの補間手法比較評価	33
3.4.1	結果	33
3.5	パイロット疎化拡大時の補間精度評価	36
3.5.1	結果	37
3.6	おわりに	46
第 4 章	時系列補間型学習データを用いた無線チャネル予測機構	47
4.1	はじめに	48
4.2	時系列補間型学習データを用いたチャネル予測機構によるモデル重み更新	48
4.3	シミュレーション	50
4.3.1	シミュレーション条件	50
4.3.2	機械学習モデル	52
4.4	時系列補間型学習データを用いた無線チャネル予測機構評価	54
4.4.1	新基地局設置時	54
4.4.2	セル内チャネル統計変動時	69
4.5	パイロット疎化拡大に伴う無線チャネル予測機構評価	78
4.5.1	LSTM モデルにおける疎化拡大	80
4.5.2	多出力 LSTM モデルによる疎化拡大	84
4.6	おわりに	89
第 5 章	結論	91
5.1	本研究の主たる成果	92
5.2	今後の課題	92
謝辞		94
参考文献		96
発表文献		100

目次

2.1	5G NR におけるフレーム構造の例 (SCS ごとのスロット数)	6
2.2	5G NR のスロット構造 [1]	7
2.3	TDD と FDD の概念図 [2]	8
2.4	CSI-RS と SRS の通信方向 (文献 [3] より)	8
2.5	チャネルエイジングの例 [4]	14
2.6	時系列 CSI 予測の例 [5]	15
3.1	三次元モデル化に用いたエリア (池袋)	26
3.2	三次元モデル化に用いたエリア (渋谷)	27
3.3	三次元モデル化に用いたエリア (新宿)	28
3.4	三次元モデル化に用いたエリア (錦糸町)	29
3.5	三次元モデル化に用いたエリア (八重洲)	30
4.1	提案機構の概要	49
4.2	ベースラインモデルの学習曲線	56
4.3	学習サンプル数と予測 NMSE の関係	60
4.4	各 SNR における予測 NMSE	62
4.5	ベースラインモデルの学習曲線 (NLoS から LoS への適応)	64
4.6	学習サンプル数とファインチューニング後 NMSE の関係 (NLoS から LoS への適応)	66
4.7	各 SNR における予測 NMSE (NLoS から LoS への適応)	68
4.8	ベースラインモデルの学習曲線 (LoS から NLoS への適応)	70
4.9	学習サンプル数とファインチューニング後 NMSE の関係 (LoS から NLoS への適応)	73
4.10	各 SNR における予測 NMSE (LoS から NLoS への適応)	75

- 4.11 周期 3 出力 1 パターンにおける LSTM ベースラインモデルの学習曲線 . 81
4.12 周期 2 出力 1 パターンにおける LSTM ベースラインモデルの学習曲線 . 81

表目次

3.1	三次元モデル化に用いたエリア	25
3.2	錦糸町データセットにおける周期4出力1パターンの補間精度	34
3.3	八重洲（LoS）データセットにおける周期4出力1パターンの補間精度	35
3.4	八重洲（NLoS）データセットにおける周期4出力1パターンの補間精度	36
3.5	錦糸町データセットにおける周期3出力1および周期2出力1パターンの補間精度	37
3.6	錦糸町データセットにおける周期3・2出力パターンの補間精度	38
3.7	錦糸町データセットにおける周期4・3出力パターンの補間精度	39
3.8	八重洲（LoS）データセットにおける周期3出力1および周期2出力1パターンの補間精度	40
3.9	八重洲（LoS）データセットにおける周期3・2出力パターンの補間精度	41
3.10	八重洲（LoS）データセットにおける周期4・3出力パターンの補間精度	42
3.11	八重洲（NLoS）データセットにおける周期3出力1および周期2出力1パターンの補間精度	43
3.12	八重洲（NLoS）データセットにおける周期3・2出力パターンの補間精度	44
3.13	八重洲（NLoS）データセットにおける周期4・3出力パターンの補間精度	45
3.14	周期4出力1, 周期3出力1, 周期2出力1パターンにおける平均NMSE	45
4.1	事前学習データのサンプル数	55
4.2	ベースラインモデルと予測なしのNMSE比較	57
4.3	補間値の配置位置による学習サンプルの構成	58
4.4	スプライン補間ににおける配置位置ごとのファインチューニング結果	58
4.5	補間手法ごとの予測精度改善率	59
4.6	学習サンプル数と予測NMSEの関係	60
4.7	各SNRにおける予測NMSE	62

4.8	ベースラインモデルと予測なしの NMSE 比較 (NLoS から LoS への適応)	64
4.9	補間手法ごとのファインチューニング結果 (NLoS から LoS への適応) .	65
4.10	各 SNR における予測 NMSE (NLoS から LoS への適応)	68
4.11	ベースラインモデルと予測なしの NMSE 比較 (LoS から NLoS への適応)	71
4.12	補間手法ごとのファインチューニング結果 (LoS から NLoS への適応) .	71
4.13	各 SNR における予測 NMSE (LoS から NLoS への適応)	74
4.14	NLoS → LoS 適応と LoS → NLoS 適応の比較	76
4.15	疎化パターンと入出力の対応	79
4.16	ファインチューニング用サンプルの構成	80
4.17	周期 3 出力 1 パターンにおけるベースライン比較	82
4.18	周期 2 出力 1 パターンにおけるベースライン比較	83
4.19	ファインチューニング後の予測性能 (周期 3 出力 1 パターン)	83
4.20	ファインチューニング後の予測性能 (周期 2 出力 1 パターン)	83
4.21	周期 3・2 出力および周期 4・3 出力パターンにおける入出力の値の種別 .	87
4.22	周期 3・2 出力パターンにおけるベースライン比較	88
4.23	周期 4・3 出力パターンにおけるベースライン比較	88
4.24	周期 3・2 出力パターンにおけるファインチューニング結果	89
4.25	周期 4・3 出力パターンにおけるファインチューニング結果	89

第1章

序論

1.1 本論文の背景と目的

5G 以降の移動体通信では、高周波数帯の利用と大規模 MIMO 技術の導入が進んでいく。基地局は多数のアンテナ素子を用いてビームフォーミングやプリコーディングを行い、空間多重により通信容量を確保する。これらの送信処理では、送受信間の伝搬特性を表すチャネル状態情報が不可欠である。チャネル状態情報の誤差はビームの指向ずれや干渉増大を招き、通信品質の劣化に直結する。

チャネル状態情報は、端末が送信する参照信号に基づいて基地局が推定する。アンテナ素子数や同時接続ユーザ数が増加すると、チャネル状態情報の次元と更新頻度の要求が増大する。参照信号の送信頻度を高めれば推定精度は向上するが、時間周波数リソースと送信電力を消費し、データ伝送に割ける資源を圧迫する。加えて、移動や遮蔽物によりチャネルが時間変動する環境では、推定から利用までの遅延によりチャネル状態情報が陳腐化するチャネルエイジングが問題となる。以上より、チャネル状態情報の推定精度と更新コストの両立が今後の移動体通信における重要な課題となっている。

参照信号のオーバーヘッドを抑えつつ将来のチャネル状態情報を推定する手段として、時系列 CSI 予測が研究されている。時系列 CSI 予測は、過去の観測系列から将来時刻のチャネル状態情報を外挿する枠組みである。予測値をビームフォーミングやプリコーディングに用いれば、参照信号の送信頻度を低減しながら通信品質を維持できる。近年は深層学習を用いてチャネルの時間変動をデータから学習する手法が提案されており、古典的なウィナーフィルタやカルマンフィルタに比べて柔軟なモデル化が期待できる。

時系列 CSI 予測を実環境で運用するには、学習時と異なる環境への適応が求められる。基地局配置、周波数帯、散乱特性、移動速度が変化すると、訓練分布とテスト分布が不一致となり、予測誤差が増大する。セル内の建造物の増減や時間帯に伴うユーザ密度の変化も、電波伝搬環境を変化させる要因となる。このような分布変化に追従するには、運用中にモデルを更新する仕組みが必要である。

既存のモデル更新手法の多くは、新環境で得られる正解データを用いた教師あり学習を前提としている。一方、時系列 CSI 予測で参照信号を削減する場合、予測スロットでは参照信号を送信しないため、予測対象時刻のチャネル状態情報を観測できない。このように正解ラベルが欠損する状況では、予測値と真値の誤差を計算できず、教師あり学習に基づくモデル更新が困難となる。予測を一時停止して参照信号を送信すれば正解ラベルを取得できるが、参照信号削減という時系列 CSI 予測の目的に反する。以上より、参照信号削減を維持しながら予測モデルを更新する枠組みが必要である。

本研究では、参照信号削減下において予測を継続しながら時系列 CSI 予測モデルを更新する機構を提案する。提案機構の要点は、欠損した正解ラベルを補間により事後的に推定し、補間値を含む系列から更新用の学習サンプルを構成する点にある。予測スロットより後に得られる観測値を用いて補間値を算出するため、参照信号削減を維持したまま学習サンプルを生成できる。本論文では、複数の補間手法を比較して有効な手法を選定し、提案機構の有効性をシミュレーションにより検証する。評価シナリオとして、新規基地局への展開とセル内の環境変動を想定し、いずれの場合においても予測精度が改善することを示す。

1.2 本論文の構成

本論文は全 5 章で構成される。第 1 章では、本研究の背景と目的を述べる。第 2 章では、5G NR 物理層における無線伝搬と CSI 取得の枠組みを整理し、時系列 CSI 予測が必要となる背景と関連研究、および環境適応における課題を述べる。第 3 章では、参照信号削減に伴い欠損する CSI を扱うための時系列補間手法を定式化し、レイトレーシングにより生成した CSI 系列を用いて補間精度を比較する。第 4 章では、補間値に基づき更新用サンプルを構成して予測モデルを更新する機構を提案し、複数のシナリオで有効性を評価する。第 5 章では、本研究で得られた知見をまとめ、今後の課題を述べる。

■ 第2章

5G NR 物理層における チャネル予測

2.1 はじめに

本章では 5G NR 物理層におけるチャネル予測の基礎事項を整理する。まず 5G NR の無線伝送処理として、リソースグリッド、参照信号、チャネル推定、プリコーディング、ビームフォーミングを概説する。続いて、チャネル予測の動作原理と関連研究を整理し、本論文が取り組む課題を明確にする。

2.2 5G NR の物理層における無線伝送処理

本節では、5G NR の物理層で用いられる無線伝送処理を概説する [6]。5G NR では OFDM による広帯域伝送と複数アンテナによる MIMO 伝送が採用されており、送信アンテナ数を N_t 、受信アンテナ数を N_r 、サブキャリア添字を f 、時間添字を t とすると、チャネル行列 $\mathbf{H}(f, t) \in \mathbb{C}^{N_r \times N_t}$ により送受信信号の対応関係が表される。以降では、リソースグリッド上の信号配置、参照信号に基づくチャネル推定、プリコーディングとビームフォーミングの順に述べる。

2.2.1 リソースグリッド

(a) 時間・周波数構造

OFDM では、時間領域の畳み込みが周波数領域でサブキャリアごとの乗算として表される。実際の通信では、周波数軸に加えて時間軸にも無線資源が割り当てられる。時間と周波数で張られる二次元平面をリソースグリッドと呼ぶ。リソースグリッド上の最小単位をリソースエレメント (RE) と呼ぶ。RE は 1 本のサブキャリアと 1 つの OFDM シンボルで定義される。通信システムはリソースグリッド上に、ユーザデータ、制御信号、チャネル推定に用いる参照信号 (RS) を配置して伝送する。受信信号は $\mathbf{y}(f, t)$ と表され、データまたは参照信号が割り当てられた RE で観測される。

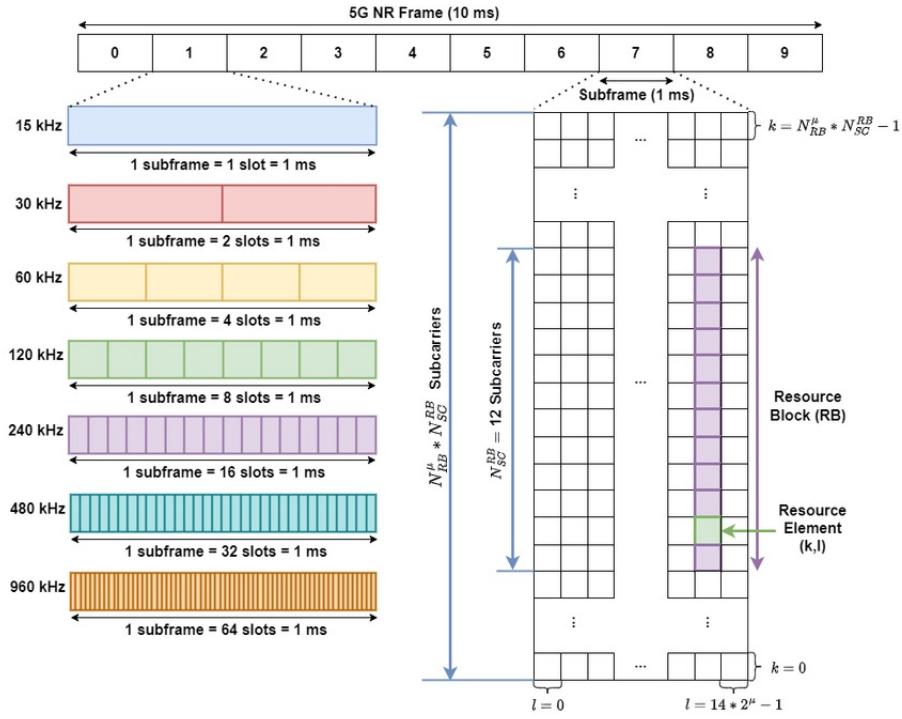


図 2.1 5G NR におけるフレーム構造の例 (SCS ごとのスロット数)

■時間方向の構造 5G NR では、時間方向の基本単位として無線フレームを定義し、長さは 10 ms である。無線フレームはサブフレームへ分割され、サブフレーム長は 1 ms である。さらにサブフレームはスロットへ分割される。サブキャリア間隔を Δf [kHz] とすると、スロット長 T_{slot} は

$$T_{\text{slot}} = 1 \text{ ms} \times \frac{15 \text{ kHz}}{\Delta f} \quad (2.1)$$

と表される。5G NR では $\Delta f = 15 \times 2^{\mu}$ [kHz] とし、 μ は 0,1,2,... である。このとき $T_{\text{slot}} = 1 \text{ ms}/2^{\mu}$ となる。また、OFDM ではマルチパス遅延によるシンボル間干渉を抑えるため、サイクリックプレフィクス (CP) を付加する。5G NR では CP 長に応じて normal CP と extended CP を規定しており、normal CP では 1 スロットは 14 個の OFDM シンボル、extended CP では 12 個の OFDM シンボルで構成される [7].

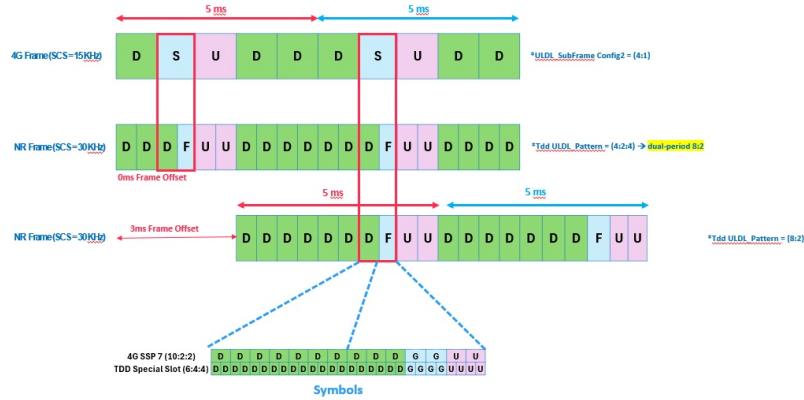


図 2.2 5G NR のスロット構造 [1]

■周波数方向の構造 周波数方向では、サブキャリアを 12 本束ねた単位をリソースブロック (RB) と呼ぶ。RB により、スケジューリングや参照信号配置をブロック単位で表せる。広帯域伝送ではマルチパス遅延により周波数選択性が生じるため、サブキャリアごとにチャネル行列 $\mathbf{H}(f, t)$ が定義される。

(b) TDD 方式と参照信号

リソースグリッド上の信号配置と送受信のタイミングは、複信方式によって決定される。特に 5G NR 以降の移動体通信システムでは高い周波数帯の利用が進み、上りリンク (UL) と下りリンク (DL) で同一の周波数帯域を用いて時間方向に通信方向を切り替える方式が広く用いられる。この方式を時分割複信 (TDD) と呼ぶ。

TDD ではチャネル状態情報 (CSI) を得るために参照信号を用いる。代表例として、DL では基地局が送信し端末が受信する CSI-RS、UL では端末が送信し基地局が受信する SRS が挙げられる。従来の周波数分割複信 (FDD) では、基地局が CSI-RS を送信し、端末が推定した CSI を基地局へフィードバックする運用が主であった。

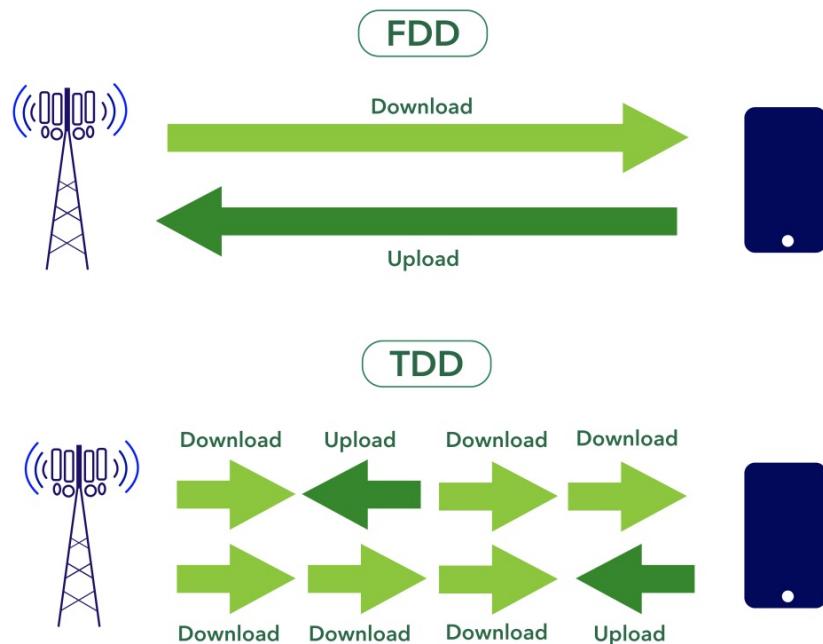


図 2.3 TDD と FDD の概念図 [2]

(c) チャネル相反性と SRS の活用

TDD では送受信に同一の周波数を用いるため、UL と DL の電波伝搬特性が等価とみなせる場合がある。この性質をチャネル相反性と呼ぶ。チャネル相反性が成り立つ条件では、基地局は端末から CSI のフィードバックを受けずに、UL で受信した SRS に基づいて DL のチャネル状態を推定できる。

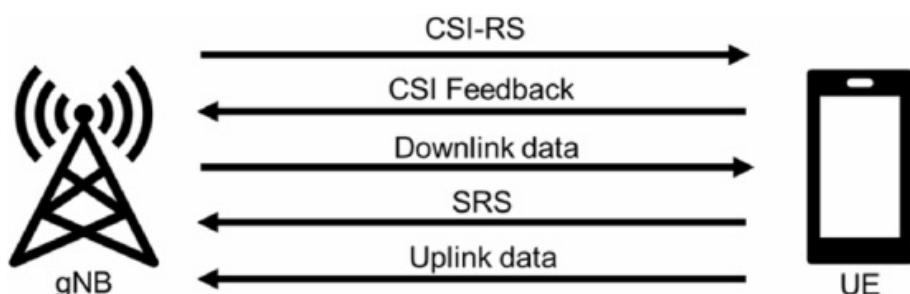


図 2.4 CSI-RS と SRS の通信方向 (文献 [3] より)

2.2.2 チャネル推定

(a) パイロット観測モデル

参照信号が送信される RE に着目する。送信参照信号を $\mathbf{X}(f, t)$ 、受信信号を $\mathbf{Y}(f, t)$ とする。ここで $\mathbf{X}(f, t)$ と $\mathbf{Y}(f, t)$ は、参照信号が割り当てられた複数の RE をまとめた行列表現である。

$$\mathbf{Y}(f, t) = \mathbf{H}(f, t)\mathbf{X}(f, t) + \mathbf{N}(f, t) \quad (2.2)$$

と表される。 $\mathbf{X}(f, t)$ は既知である。 $\mathbf{N}(f, t)$ は受信雑音であり、熱雑音に起因する加法性白色ガウス雑音 (AWGN) としてモデル化する場合が多い。チャネル推定とは、既知の参照信号と受信信号から $\mathbf{H}(f, t)$ を推定することである。以降で述べるプリコーディングとビームフォーミングの設計では、推定されたチャネル状態情報が用いられる。

(b) 最小二乗推定

单一のサブキャリアに着目して説明する。送信側が既知の参照信号ベクトル $\mathbf{x}(f, t) \in \mathbb{C}^{N_t \times 1}$ を送信し、受信側が $\mathbf{y}(f, t) \in \mathbb{C}^{N_r \times 1}$ を観測する場合を考える。複素数体を \mathbb{C} で表す。このとき、式 2.2 は次式のように書き換えられる。

$$\mathbf{y}(f, t) = \mathbf{H}(f, t)\mathbf{x}(f, t) + \mathbf{n}(f, t) \quad (2.3)$$

である。

参照信号を時間方向に並べた行列 $\mathbf{X}(f, t)$ と、対応する受信信号行列 $\mathbf{Y}(f, t)$ を用いると、観測モデルは式 2.2 で表される。ここでは、 f, t を固定し、既知の $\mathbf{X}(f, t)$ と観測 $\mathbf{Y}(f, t)$ から未知のチャネル行列 $\mathbf{H}(f, t)$ を推定する。最小二乗 (LS) 推定は、観測とモデルの差である残差が最も小さくなる \mathbf{H} を選ぶ推定である。LS 推定は次の最適化問題として定式化される。

$$\hat{\mathbf{H}}_{\text{LS}}(f, t) = \arg \min_{\mathbf{H}} \|\mathbf{Y}(f, t) - \mathbf{H}\mathbf{X}(f, t)\|_{\text{F}}^2 \quad (2.4)$$

ここで $\hat{\mathbf{H}}_{\text{LS}}(f, t)$ は $\mathbf{H}(f, t)$ の LS 推定値である。 $\hat{\cdot}$ は推定値を表し、添字 LS は最小二乗推定を表す。 $\arg \min$ は目的関数を最小にする \mathbf{H} を表す。 $\|\cdot\|_{\text{F}}$ はフロベニウスノルムである。記号 $(\cdot)^{\text{H}}$ は共役転置である。

参照信号が適切に設計され、 $\mathbf{X}(f, t)\mathbf{X}(f, t)^{\text{H}}$ の逆行列が存在するとき、LS 推定値は

$$\hat{\mathbf{H}}_{\text{LS}}(f, t) = \mathbf{Y}(f, t)\mathbf{X}(f, t)^{\text{H}} (\mathbf{X}(f, t)\mathbf{X}(f, t)^{\text{H}})^{-1} \quad (2.5)$$

と表される。

(c) LMMSE 推定

LS 推定は単純である一方、雑音や事前統計を考慮しないため SNR が低い場合に推定誤差が大きくなる。チャネルの相関や雑音分散などの統計情報が得られる場合、LMMSE 推定により推定誤差を低減できる。事前統計とは、観測 $\mathbf{Y}(f, t)$ とは独立に既知である確率的性質である。例として、受信雑音の分散、チャネルの平均電力、時間方向、周波数方向、空間方向の相関が挙げられる。

■LMMSE 推定の導出 LS 推定は観測 $\mathbf{Y}(f, t)$ と既知の $\mathbf{X}(f, t)$ だけから $\mathbf{H}(f, t)$ を求めるため、雑音が大きい場合に推定誤差が増大しやすい。そこで事前統計を利用し、推定誤差の平均二乗誤差を小さくすることを考える線形最小平均二乗誤差 (LMMSE) 推定を導入する。式 2.2 に対して、次の評価関数を最小化する。期待値を $\mathbb{E}[\cdot]$ で表し、本節では受信雑音に関する平均として扱う。

$$\mathbb{E} \left[\| \mathbf{Y}(f, t) - \mathbf{H}(f, t) \mathbf{X}(f, t) \|_F^2 \right] \quad (2.6)$$

この評価関数を $\mathbf{H}(f, t)$ で微分し 0 とおくと、

$$\hat{\mathbf{H}}(f, t) \mathbb{E} [\mathbf{X}(f, t) \mathbf{X}(f, t)^H] = \mathbb{E} [\mathbf{Y}(f, t) \mathbf{X}(f, t)^H] \quad (2.7)$$

が得られる。したがって、

$$\hat{\mathbf{H}}_{\text{LMMSE}}(f, t) = \mathbb{E} [\mathbf{Y}(f, t) \mathbf{X}(f, t)^H] (\mathbb{E} [\mathbf{X}(f, t) \mathbf{X}(f, t)^H])^{-1} \quad (2.8)$$

と表される。なお、 $\mathbb{E} [\mathbf{X} \mathbf{X}^H]$ は参照信号の自己相関行列、 $\mathbb{E} [\mathbf{Y} \mathbf{X}^H]$ は受信信号と参照信号の相互相関行列に対応する。

2.2.3 プリコーディング

(a) プリコーディング

送信側で信号に重みを乗じ、所望の信号を受信側で得やすくする処理をプリコーディングと呼ぶ。单一のサブキャリアに着目し、表記を簡単のため添字 f, t を省略する。所望の送信シンボルベクトルを $\mathbf{s} \in \mathbb{C}^{N_s \times 1}$ 、送信アンテナ数を N_t 、受信アンテナ数を N_r とする。送信側ではプリコーディング行列 $\mathbf{P} \in \mathbb{C}^{N_t \times N_s}$ を用いて

$$\mathbf{x} = \mathbf{Ps} \quad (2.9)$$

とし、受信信号は

$$\mathbf{y} = \mathbf{H} \mathbf{Ps} + \mathbf{n} \quad (2.10)$$

と表される。ただし $\mathbf{H} \in \mathbb{C}^{N_r \times N_t}$ はチャネル行列, $\mathbf{n} \in \mathbb{C}^{N_r \times 1}$ は受信雑音である。以下では、 \mathbf{P} の代表的な設計を示す。重みは推定チャネル $\hat{\mathbf{H}}$ に基づいて計算されるが、表記を簡単のため \mathbf{H} と書く。

(b) 最小二乗基準

雑音が無視できると仮定すると、所望信号 \mathbf{s} を得るには $\mathbf{HPs} \approx \mathbf{s}$, すなわち $\mathbf{HP} \approx \mathbf{I}$ となる \mathbf{P} が望ましい。そこで

$$\min_{\mathbf{P}} \|\mathbf{HP} - \mathbf{I}\|_F^2 \quad (2.11)$$

を考える。 \mathbf{H} が行フルランクであり $N_t \geq N_r$ が成り立つとき、式 (2.11) の解はチャネルの擬似逆行列で与えられ、

$$\mathbf{P}_{LS} = \mathbf{H}^+ = \mathbf{H}^H (\mathbf{HH}^H)^{-1} \quad (2.12)$$

となる。この解はゼロフォーシング (ZF) プリコーディングとして知られる。ZF は干渉を抑圧できる一方、 \mathbf{HH}^H の条件数が大きい場合に雑音が増幅しやすい。

(c) 最小平均二乗誤差基準

ZF は雑音を考慮しないため、SNR が低い場合に性能が劣化しやすい。雑音の影響を抑えるため、ZF の目的関数に正則化項を加えた

$$\min_{\mathbf{P}} \|\mathbf{HP} - \mathbf{I}\|_F^2 + \alpha \|\mathbf{P}\|_F^2 \quad (2.13)$$

を用いる。 α は雑音分散や送信 SNR に基づく正則化係数である。式 (2.13) を \mathbf{P} で偏微分して 0 とおくと

$$\mathbf{H}^H(\mathbf{HP} - \mathbf{I}) + \alpha \mathbf{P} = \mathbf{0} \quad (2.14)$$

となり、よって

$$\mathbf{P}_{LMMSE} = \mathbf{H}^H (\mathbf{HH}^H + \alpha \mathbf{I})^{-1} \quad (2.15)$$

が得られる。 $\alpha \rightarrow 0$ で式 (2.12) に一致する。この形は正則化 ZF とも呼ばれる。

2.2.4 ビームフォーミング

(a) MIMO におけるビームフォーミングの位置づけ

複数の送受信アンテナを用いる多入力多出力 (MIMO) 伝送がもたらす利得は、空間多重、空間多様性、ビームフォーミングに整理できる。空間多重は複数ストリームを同時

に送信してスループットを向上させる。空間多様性は同一情報を冗長に分散してフェージングの影響を低減する。ビームフォーミングは所望ユーザ方向の有効利得を高め、他ユーザ方向への漏洩を抑える。まず空間多重では、送信ストリーム数 N_s を $N_s > 1$ として、式(2.9)のプリコーディング行列 $\mathbf{P} \in \mathbb{C}^{N_t \times N_s}$ により複数ストリームを同時送信する。受信側では式(2.10)のように \mathbf{HP} を通じてストリーム間干渉が生じ得るため、ZFやLMMSE等の設計により干渉を抑えつつ所望信号を復元する必要がある。一方、空間多様性は、同一情報をアンテナ、時間、周波数に冗長に分散して送ることで、深いフェージングの影響を平均化し、誤り率を改善する考え方である。本節で扱うビームフォーミングはプリコーディングの特殊形として理解でき、単一ストリームであり $N_s = 1$ のときに典型的に現れる。

(b) ビームフォーミングの基本

ビームフォーミングは、複数アンテナの送信信号に位相と振幅の重みを付与し、空間的に特定方向の電力を強める送信方式である。単一ストリームであり $N_s = 1$ のとき、式(2.9)の \mathbf{P} はベクトル $\mathbf{w} \in \mathbb{C}^{N_t \times 1}$ に退化し、

$$\mathbf{x} = \mathbf{ws} \quad (2.16)$$

と書ける。受信側の有効チャネルは \mathbf{Hw} となり、 \mathbf{w} を適切に選べば所望ユーザの SNR を高められる。代表例として、單一ユーザで雑音が支配的な場合には最大比送信(MRT)が用いられ、

$$\mathbf{w}_{\text{MRT}} = \frac{\mathbf{h}^H}{\|\mathbf{h}\|_2} \quad (2.17)$$

を用いる。ここで $\mathbf{h} \in \mathbb{C}^{1 \times N_t}$ は当該ユーザのチャネル行ベクトルである。MRT はチャネルと同位相で送信してアレー利得を得る一方、多ユーザでは他ユーザへの干渉を考慮する必要がある。いずれの設計でも、 \mathbf{w} の計算には CSI が必要である。CSI の時間変動に追従できない場合、ビームの指向が外れて受信品質が劣化する。

(c) 単一ユーザにおける MIMO ビームフォーミング

单一ユーザの $N_s > 1$ ストリーム送信では、 \mathbf{w} を1本選ぶ代わりに、 \mathbf{P} の列ベクトルとして複数本のビームを設計する。この单一ユーザ MIMO(SU-MIMO)では、代表的な理論モデルとして特異値分解(SVD)を用いる。

$$\mathbf{H} = \mathbf{U}\Sigma\mathbf{V}^H \quad (2.18)$$

を用いると、 \mathbf{V} の列ベクトルは送信側の直交ビームを与える。例えば上位 N_s 本の固有モードを用いる場合、

$$\mathbf{P} = \mathbf{V}_{(:,1:N_s)}, \quad \mathbf{D} = \mathbf{U}_{(:,1:N_s)}^H \quad (2.19)$$

とおけば、理想化した条件下でストリーム間干渉を抑えた並列チャネルに分解できる。この観点から、単一ストリームのビームフォーミングは SU-MIMO で $N_s = 1$ の場合に対応する。実システムでは、完全な CSI の取得や無制限のデジタル自由度は仮定できないため、アナログ、デジタル、ハイブリッドといった実装制約の下でビーム設計が行われる。

2.3 チャネル予測の動作原理

本節では、CSI を将来時刻へ外挿する CSI 予測を扱う [8, 9]。まず、5G の進展に伴って CSI の取得と更新が抱える課題を整理し、CSI 予測が必要となる背景を述べる。次に、CSI 予測の代表的な枠組みを概観した上で、時系列 CSI 予測に焦点を当てて関連手法を整理する。

5G では高周波数帯の利用や高密度化が進み、基地局は多数のアンテナ素子を用いた大規模 MIMO(mMIMO) により、空間多重とビーム運用で容量を確保する。前節で述べたプリコーディングやビームフォーミングの設計には CSI が不可欠であり、CSI の誤差はビームの指向ずれや干渉増大として性能劣化に直結する。一方で、アンテナ素子数や同時接続ユーザ数の増加に伴い、CSI の次元と更新頻度の要求が増大する。参照信号の送信やフィードバックを高頻度化すれば推定精度は向上するが、時間周波数リソースと送受信電力を消費し、データ伝送に割ける資源を圧迫する。多ユーザかつ多ビームの運用では測定、推定、重み更新の計算負荷も増大し、実装面の制約が顕在化する。加えて、移動や遮蔽物により無線チャネルが時間変動する環境では、推定から利用までの遅延により CSI が陳腐化するチャネルエイジングが問題となる。チャネルエイジングは mMIMO のようにビームが鋭い系ほど影響が大きく、追従遅れがリンク品質の低下を招く。以上より、CSI の推定精度を高めるほど参照信号等のオーバーヘッドが増大するため、精度と更新コストの両立が課題となる。追加の無線リソース投入を抑えつつ将来の CSI を推定し、実効的な CSI 品質を改善する手段として CSI 予測が研究されている。

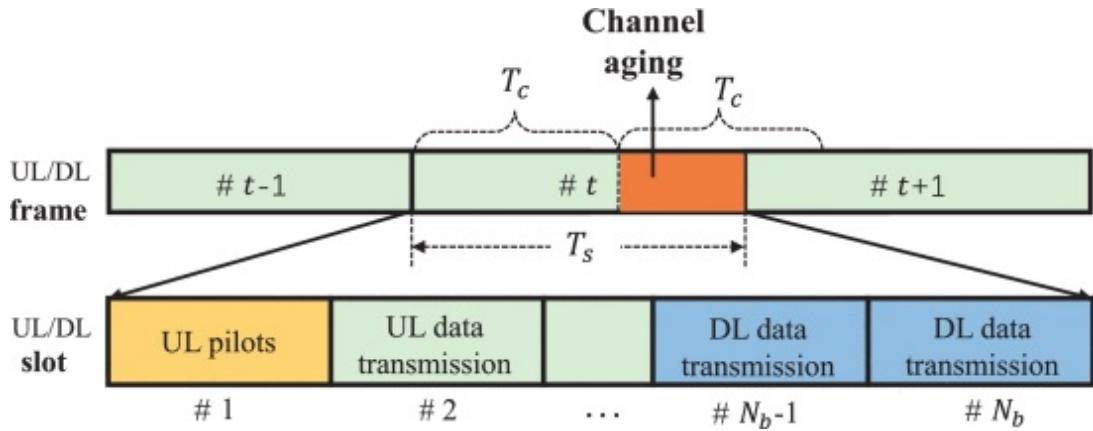


図2.5 チャネルエイジングの例 [4]

2.4 関連研究

CSI予測とは、観測済みのCSIから未観測のCSIを推定する枠組みである。未観測の対象は、将来時刻のCSIに限らず、異なる周波数帯域のCSIや、圧縮により欠落した成分を含む場合がある。本節では、既存研究で用いられる代表的な分類を整理し、本章で扱う範囲を明確にする。

(a) 周波数方向のCSI予測

前節で述べたように、FDD方式ではULとDLの周波数帯域が異なるため、TDDのようなチャネル相反性を直接には利用できない。一方で、散乱体配置、到來角、出發角などの幾何学的パラメータは、近接する周波数帯域で共通性をもつ場合がある。周波数方向のCSI予測は、この共通性に基づき、ULで得られる情報からDLのCSIを推定することを目的とする。推定は、伝搬パラメータを介してDLのCSIを再構成するモデルに基づく方法や、ULとDLの対応をデータから学習する方法として定式化されることが多い。

(b) CSIフィードバック圧縮

FDD方式では端末がCSI-RS等からDLのCSIを推定し、基地局へフィードバックする運用が基本となる。端末をUE、基地局をBSと略記する。mMIMOではCSIの次元が大きく、フィードバック量が無線リソースを圧迫する。端末(UE)側でCSIを低次元表現へ圧縮して送信し、基地局(BS)側で復元する枠組みが提案されている[10]。符号帳に基づく量子化に加え、疎性や低ランク性を仮定した圧縮、自己符号化器を用いたデータ駆

動の圧縮も検討されている。フィードバック圧縮は時間方向の外挿ではないが、限られた無線リソースで BS が利用可能な CSI 品質を維持するという観点で、本章の課題設定と密接に関係する。

(c) 時系列 CSI 予測

時系列 CSI 予測は、同一の周波数帯域における CSI 系列から、将来時刻の CSI を推定する枠組みである。参照信号が疎である場合や、推定と重み更新に遅延が生じる場合に、チャネルエイジングの影響を緩和する手段として位置づけられる。アンテナ素子数や同時接続ユーザ数の増加により CSI 更新要求が厳しくなる状況では、参照信号密度を過度に高めずにビーム重みを更新するための補助手段となり得る。特に、触覚インターネットや自動運転など低遅延アプリケーションの普及に伴いミリ波帯の利用が進む場合、TDD 運用を前提としたシステム設計が想定され、時間方向の CSI 外挿は実装上の親和性が高い。3GPP の技術報告でも CSI フィードバック遅延の影響評価や予測に基づくリンク適応が議論されており [11]、時系列 CSI 予測の重要性は今後さらに高まると考えられる。以降では、この時系列 CSI 予測に焦点を当て、代表的手法と課題を整理する。

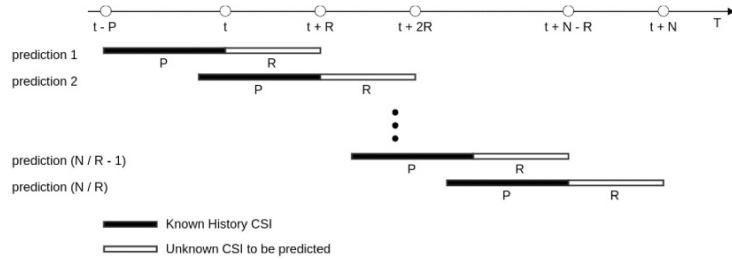


図 2.6 時系列 CSI 予測の例 [5]

(d) 時系列 CSI 予測研究の潮流

古典的には、ウィナーフィルタやカルマンフィルタに基づく推定として CSI 予測が定式化してきた [12, 13]。ただし、これらはチャネルの統計モデルや状態空間モデルの仮定に依存し、実環境との不整合が性能劣化につながる場合がある。時系列 CSI 予測は、参照信号の送受信やフィードバックの頻度を下げても、予測により CSI の陳腐化を補償できる点に利点がある。参照信号のオーバーヘッドを抑えれば、データ伝送に割ける時間周波数資源が増加し、実効スループットの向上に寄与する。この観点から、近年は深層学習を用いてチャネルの時間変動をデータから学習する手法が提案されている [14]。

深層学習に基づく時系列 CSI 予測では、複素値表現を直接扱うモデル、再帰構造により時間相関を捉えるモデル、畳み込みにより局所的な構造を抽出するモデルなどが提案されている。複素数ニューラルネットワークを用いて周波数領域でフェージングチャネルを予測する手法が報告されている [15]。RNN を用いた周波数領域チャネル予測を MIMO-OFDM へ適用した研究では、多ステップ予測の枠組みが示され、カルマンフィルタとの比較も行われている [16]。大規模 MIMO におけるチャネルエイジング下では、機械学習に基づく予測により、予測品質とユーザスループットの観点で改善が示されている [17]。注意機構を導入して時系列内の重要な時刻へ重み付けする手法も検討されている [18]。Transformer を用いる手法では自己注意機構と並列処理により、マルチステップ予測における誤差伝播の抑制を狙った設計が提案されている [4]。

(e) 時系列 CSI 予測の環境適応

時系列 CSI 予測は、学習時と運用時で環境が同一である前提として評価される場合が多い。基地局配置、周波数帯、散乱特性、移動速度が変化すると、訓練分布とテスト分布が不一致となり、予測誤差が増大する。セル内の建造物の増減や時間帯に伴うユーザ密度の変化も、遮蔽や干渉環境を変化させ、同様の分布不一致を生じさせる。以上より、時系列 CSI 予測モデルには、少量データでの高速適応や運用中の分布変化に対する性能維持を含む環境適応が求められる。

環境適応に関する研究は、転移学習、メタ学習、オンライン学習、継続学習など複数のアプローチに分類できる。転移学習に基づくアプローチとして、Yang らは環境変化による性能劣化を転移学習問題として定式化し、既存環境で訓練したモデルを新環境で微調整することで適応力を向上させた [19]。

シミュレーションと実環境間のギャップに着目した研究も進んでおり、Hoang らはチャネルモデルで事前学習したモデルを実データで微調整し、限られた実測 CSI でも高い予測性能を達成できることを示した [20]。

また、統計的チャネルモデルと地図ベースチャネルモデル間のドメインギャップをドメイン適応で埋め、シミュレーションから実環境への汎化性能を向上させた研究もある [21]。

転移学習に関する研究として

メタ学習に基づくアプローチでは、少量データでの高速適応を狙った初期化の学習が検討されている。Kim らは、複数環境でメタ学習により初期モデルを学習し、新環境では少數サンプルで微調整する枠組みを示した [22]。低 SNR 環境では、深層画像事前分布に基づく前処理を併用し、観測雑音の影響を低減した上で予測する設計としている [22]。事前学習済みモデルの転用も環境変化に対する汎化を狙う方向性であり、Liu らは大規模言語

モデルを CSI 予測へ適用し、少量データ学習と未学習環境での性能を評価した [23].

オンライン学習に基づくアプローチでは、Xu らがパイロット信号のみで逐次学習するモデルにより、オフライン学習モデルの環境不一致を上回る性能を達成できることを報告している [24]. 運用中の分布変化に対しては、継続学習により逐次追従する枠組みも提案されている [25]. 特にハンドオーバー時の環境変化に対しては、Mohsin らが継続学習問題として定式化し、リプレイ、正則化、蒸留を組み合わせて忘却を抑制しつつ新環境へ適応する手法を提案している [26].

チャネル予測モデルの重みを更新せずに疎なパイロット信号を補間する試みも検討されている. Chen らは、空間的および周波数的に部分的に推定した CSI を CDNet に入力し、パイロットが送信されないスロットの値も継続的に入力して逐次予測する手法を提案した [27]. Li らは、予測時刻でパイロットが欠如する条件に対し、VAE による補間を用いて逐次的な予測を実現している [28]. Tekgul らは、入力の欠如をそのまま欠落として扱い逐次的な予測を実現している [29].

2.5 おわりに

本章では、5G NR 物理層におけるチャネル予測の基礎と背景を整理した. まず、帯域幅とアンテナ数の観点からチャネルモデルを分類し、狭域 SISO から広域 MIMO へ至る入出力関係を定式化した. OFDM リソースグリッドと TDD 運用を概観し、参照信号に基づく CSI 取得の前提を明確にした. チャネル推定では、LS 推定と LMMSE 推定を示し、推定に必要な既知参照信号、雑音、事前統計の関係を整理した. プリコーディングでは、ZF と正則化 ZF を取り上げ、チャネル行列の性質が雑音増幅や干渉抑圧に影響する点を述べた. ビームフォーミングでは、単一ストリームの MRT と SU-MIMO における SVD に基づく固有モード伝送を例に、重み計算に CSI が不可欠であることを確認した.

続いて、CSI 予測の動作原理として、5G の進展に伴う CSI 取得と更新の課題、およびチャネルエイジングの問題を整理した. 関連研究では、周波数方向の CSI 予測、CSI フィードバック圧縮、時系列 CSI 予測の三つの枠組みを概観し、本論文では時系列 CSI 予測に焦点を当てることを述べた. 時系列 CSI 予測の環境適応に関しては、メタ学習に基づく初期化学習 [22]、大規模言語モデルの転用 [23]、継続学習による逐次追従 [25] などの研究を紹介した.

既存研究の多くは、新環境で得られる正解データを用いたモデル更新を前提としている. 一方、時系列 CSI 予測で参照信号を削減する場合、予測スロットでは参照信号を送信しないため、予測対象時刻の CSI 推定値が得られない. 正解ラベルを獲得できなければ

教師あり学習に基づく損失を計算できず、予測を継続しながら逐次的にモデルを更新することが困難となる。

具体例として、時刻 t の CSI 推定値を \mathbf{H}_t 、予測値を $\widehat{\mathbf{H}}_t$ とする。3 入力 1 出力の予測モデルを運用する場合、 $\mathbf{H}_t, \mathbf{H}_{t+1}, \mathbf{H}_{t+2}$ から $\widehat{\mathbf{H}}_{t+3}$ を得る。参照信号を削減する予測スロットでは、時刻 $t + 3$ の推定値 \mathbf{H}_{t+3} を獲得できない。 $\widehat{\mathbf{H}}_{t+3}$ に対する教師信号が欠落し、更新用の学習データを逐次獲得できない。結果として運用で基地局が利用できる CSI 系列は推定値と予測値が混在する系列となる。

この混在系列を用いてモデルを更新する方法として、三つの方針が考えられる。第 1 の方針は、一時的に予測を停止し、参照信号を送信して全時刻の推定値を揃えた後に更新するものである。参照信号削減という時系列 CSI 予測の目的に反するうえ、更新までの遅延も増大する。運用中にモデルを停止する場合、停止と再開の手順、許容中断時間、遅延を考慮した運用方針を設計する必要がある。3GPP では AI モデルのライフサイクル管理に関する要件を議論しているが、モデルの有効化と無効化、切り替え時の遅延の扱いは策定途上にある [30–32]。産業界では AI-RAN として無線アクセスネットワークに AI モデルを組み込む次世代アーキテクチャが議論されているが、フォールバック機構の設計指針は確立されていない [33]。以上より、第 1 の方針は参照信号削減の利点を損なうだけでなく、実運用における実現可能性にも課題を残す。

第 2 の方針は、予測対象時刻の正解ラベルを用いて更新するものである。参照信号削減下では \mathbf{H}_{t+3} を獲得できないため、予測値との間の損失計算が成り立たず、教師あり学習ができない。他分野では観測や正解データが継続的に得られるため、オンライン学習 [34] [35,36] により逐次更新する枠組みが一般的である。しかし、時系列 CSI 予測では予測スロットで参照信号を送らないため、この枠組みを直接適用できない。

第 3 の方針は、入力に予測値を含め、次に推定値が得られる時刻を正解ラベルとして更新するものである。例えば $\mathbf{H}_{t+1}, \mathbf{H}_{t+2}, \widehat{\mathbf{H}}_{t+3}$ から \mathbf{H}_{t+4} を学習する。この場合は、入力に予測誤差が混入し、誤差蓄積による性能劣化を招く可能性が指摘されている [4]。

参照信号削減を前提とする時系列 CSI 予測の運用では、推定値と予測値が混在する CSI 系列から、モデルを更新する枠組みが必要となる。第 1 の方針は参照信号削減の目的と整合せず、標準化検討途上である運用手順の設計負担も大きい。本論文では、第 2 および第 3 の方針が想定する状況を対象として、予測を継続したまま欠損する正解ラベルを扱い、モデルを更新する問題に取り組む。

■ 第3章

チャネル予測モデルの重み 更新に向けた補間手法比較

3.1 はじめに

前章では、時系列 CSI 予測の運用において、参照信号削減に伴い予測スロットで正解ラベルが欠損する問題を述べた。予測を継続しながらモデルを更新するには、欠損する正解ラベルを何らかの方法で補う必要がある。本章では、この欠損を補う手段として時系列補間に着目し、チャネル予測モデルの重み更新に適した補間手法を選定する。

補間の基本方針は、欠損時刻の前後に存在する推定値から補間値を算出し、これを更新用サンプルの正解ラベルとして用いることである。補間対象時刻より後に得られる推定値も活用するため、一方向の外挿と比較して補間誤差を抑えられる。本章では、線形補間、スプライン補間、多項式近似、ニューラルネットワーク補間の4種類を比較対象とする。

評価にはレイトレーシングにより生成した CSI 系列を用いる。東京都内の複数地点の地形データを三次元モデル化し、歩行軌道に沿った CSI 系列を生成する。パイロット信号の送信周期を変化させた複数の観測パターンを設定し、欠損率が 25% から 50% に変化した場合の補間精度を評価する。

本章の構成は以下のとおりである。第3.2節では、比較対象とする4種類の補間手法を説明する。第3.3節では、シミュレーションに用いる地形データとレイトレーシングの設定を述べる。第3.4節および第3.5節では、各補間手法の精度を評価し、チャネル予測モデルの重み更新に適した手法を選定する。

3.2 CSI の時系列補間手法

本節では、予測を継続したまま欠損する正解ラベルを扱うための補間手法を説明する。チャネル予測モデル運用時には、予測スロットにおいて \mathbf{H}_t が欠損するため、後続スロットで得られる推定値から補間値 $\widetilde{\mathbf{H}}_t$ を算出し、更新用サンプル生成に用いる。補間は時間方向に対してを行い、各スロットの CSI をフラット化した特微量ベクトルの各次元に対して適用する。本論文では、複数の補間手法を比較対象として用いる。以下に示す手法は、補間対象時刻の前後に存在する推定値から $\widetilde{\mathbf{H}}_t$ を得るという点が共通である。補間対象時刻より後に得られる推定値も用いるため、欠損を一方向の外挿として扱う場合に比べて、補間値の推定誤差を抑えられる。

3.2.1 線形補間

最も簡単な基準手法として、補間対象時刻の前後1スロットで得られる推定値の平均を補間値とする。補間対象時刻を t とすると、 \mathbf{H}_{t-1} と \mathbf{H}_{t+1} から補間値 $\widetilde{\mathbf{H}}_t$ を

$$\widetilde{\mathbf{H}}_t = \frac{1}{2} (\mathbf{H}_{t-1} + \mathbf{H}_{t+1}) \quad (3.1)$$

として算出する。

3.2.2 スプライン補間

スプライン補間では、補間対象時刻の前後に存在する複数スロットの推定値を用い、時間方向に平滑な曲線で $\widetilde{\mathbf{H}}_t$ を算出する。具体例として、補間対象を \mathbf{H}_3 とし、近傍として $\mathbf{H}_0, \mathbf{H}_1, \mathbf{H}_2, \mathbf{H}_4, \mathbf{H}_5, \mathbf{H}_6$ の6点を用いる。補間対象時刻 $t=3$ からの相対時刻を τ とし、 τ が取り得る値の集合を $\mathcal{T} = \{-3, -2, -1, 1, 2, 3\}$ と定義する。すなわち、 $\tau = -3$ は時刻0、 $\tau = 1$ は時刻4に対応する。このとき、観測点を

$$\{(\tau, \mathbf{H}_{3+\tau}) \mid \tau \in \mathcal{T}\} \quad (3.2)$$

と表す。この観測点を通過する三次スプライン関数 $s(\tau)$ を構成し、

$$s(\tau) = \mathbf{H}_{3+\tau} \quad \tau \in \mathcal{T} \quad (3.3)$$

を満たすように係数を定める。境界条件は自然スプラインとする。これは、観測区間の両端で曲率が0となる条件を課し、端点付近で過度に曲がることを抑える設定である。 $\tau = 0$ で評価して

$$\widetilde{\mathbf{H}}_3 = s(0) \quad (3.4)$$

を得る。

3.2.3 多項式近似

多項式近似では、時間方向のみに対して低次多項式を当てはめ、補間対象時刻の値を推定して $\widetilde{\mathbf{H}}_t$ を算出する。補間対象を時刻 t とし、補間対象時刻からの相対時刻を τ とする。近傍として用いる τ の集合を $\mathcal{T} = \{\tau_1, \dots, \tau_K\}$ とする。このとき、 $\tau_i \in \mathcal{T}$ に対応す

る観測値を $\mathbf{H}_{t+\tau_i}$ とし、次数 d の多項式

$$\mathbf{p}(\tau) = \sum_{m=0}^d \mathbf{a}_m \tau^m \quad (3.5)$$

により時間方向の変化を近似する。係数 $\{\mathbf{a}_m\}_{m=0}^d$ は最小二乗により

$$\{\mathbf{a}_m\} = \arg \min_{\{\mathbf{a}_m\}} \sum_{i=1}^K \|\mathbf{H}_{t+\tau_i} - \mathbf{p}(\tau_i)\|_2^2 \quad (3.6)$$

として推定する。推定後、 $\tau = 0$ で評価して補間値を

$$\widetilde{\mathbf{H}}_t = \mathbf{p}(0) = \mathbf{a}_0 \quad (3.7)$$

として得る。

本論文では、多項式の次数 d と近傍点数 K を変化させ、補間精度と更新後の予測精度の関係を比較する。次数の比較では、 $\mathcal{T} = \{-3, -2, -1, 1, 2, 3\}$ の 6 点を用い、 $d \in \{2, 3, 4\}$ を比較する。近傍点数の比較では、参照信号削減に伴う欠測の周期を 4 とし、欠測時刻に対応する時刻差を近傍候補から除外する。具体的には、 \mathbb{Z} を整数集合として、周期を N とすると候補集合を

$$\mathcal{C} = \{\tau \in \mathbb{Z} \mid \tau \neq 0, \tau \not\equiv 0 \pmod{N}\} \quad (3.8)$$

と定義し、 \mathcal{C} から負の側に k_{true} 点、正の側に k_{true} 点を近い順に選び、

$$\mathcal{T} = \{\tau \in \mathcal{C} \mid \tau < 0\}^{k_{\text{true}}} \cup \{\tau \in \mathcal{C} \mid \tau > 0\}^{k_{\text{true}}} \quad (3.9)$$

として近傍点集合を構成する。ここで、 $\{\cdot\}^{k_{\text{true}}}$ は絶対値が小さい順に k_{true} 点を選ぶ演算を表す。例として、 $k_{\text{true}} = 3$ では $\mathcal{T} = \{-3, -2, -1, 1, 2, 3\}$ となり、 k_{true} を増やすことで $\pm 4, \pm 8, \dots$ を除外しつつ、より遠方の真値点を近傍に含める。

3.2.4 ニューラルネットワークによる補間

ニューラルネットワークを用いた補間では、補間対象時刻を t とし、補間に用いる時刻差の集合 $\mathcal{T} = \{-3, -2, -1, 1, 2, 3\}$ に対応する推定値を入力として、 \mathbf{H}_t への回帰を学習する。 $\mathbf{H}_{t+\tau}$ をフラット化したベクトルを $\mathbf{h}_{t+\tau}$ とし、入力ベクトルを

$$\mathbf{x}_t = [\mathbf{h}_{t-3}^\top, \mathbf{h}_{t-2}^\top, \mathbf{h}_{t-1}^\top, \mathbf{h}_{t+1}^\top, \mathbf{h}_{t+2}^\top, \mathbf{h}_{t+3}^\top]^\top \quad (3.10)$$

と定義する。サンプルごとの振幅差を抑えるため、 \mathbf{x}_t を RMS で正規化し、

$$\alpha_t = \sqrt{\frac{1}{\dim(\mathbf{x}_t)} \|\mathbf{x}_t\|_2^2}, \quad \bar{\mathbf{x}}_t = \frac{1}{\alpha_t} \mathbf{x}_t \quad (3.11)$$

を得る。学習済み補間器を $g_\phi(\cdot)$ とする。ここで、 g_ϕ の出力は補間対象時刻の CSI をフラット化したベクトルであり、 $\tilde{\mathbf{h}}_t$ と表す。補間値は

$$\tilde{\mathbf{h}}_t = \alpha_t g_\phi(\bar{\mathbf{x}}_t) \quad (3.12)$$

として算出する。 $\tilde{\mathbf{h}}_t$ をスロット t の CSI 行列の形状に戻すことで $\widetilde{\mathbf{H}}_t$ を得る。

(a) 補間ニューラルネットワーク

補間器は、欠損している中心時刻 t の CSI \mathbf{H}_t を、その前後の近傍フレームから推定するニューラルネットワークである。本論文では、context_size= 3 として $\mathcal{T} = \{-3, -2, -1, 1, 2, 3\}$ の 6 近傍フレームを用い、それらをフラット化して結合した入力 $\mathbf{x}_t \in \mathbb{R}^{6F}$ から、中心フレーム 1 枚分の CSI をフラット化した出力 $\tilde{\mathbf{h}}_t \in \mathbb{R}^F$ を推定する。得られた $\tilde{\mathbf{h}}_t$ を行列形状に戻すことで補間値 $\widetilde{\mathbf{H}}_t$ を構成する。

■MLP 補間器 基本設定の補間器は全結合層からなる MLP として実装する。context_size= 3 のとき、6F 次元の入力を 2048 次元へ変換し ReLU で活性化する第 1 層、2048 次元を 1024 次元へ変換し ReLU で活性化する第 2 層、1024 次元を F 次元へ変換する出力層の 3 層構造とする。

■RMS 正規化 チャネル全体のスケール変動に対する学習の安定化を目的として、入力の RMS による正規化を施す。入力 \mathbf{x}_t の RMS から正規化係数 α_t を算出し、正規化後の入力 $\bar{\mathbf{x}}_t = \mathbf{x}_t / \alpha_t$ を補間器へ与える。補間器の出力は元スケールへ戻し、 $\tilde{\mathbf{h}}_t = \alpha_t g_\phi(\bar{\mathbf{x}}_t)$ から $\widetilde{\mathbf{H}}_t$ を得る。この正規化は学習と推論の双方で共通して適用する。

3.3 シミュレーション

本節では、補間手法の評価手順について述べた後に、シミュレーションによる評価を行う。

3.3.1 地形データと Sionna によるレイトレーシング

本論文で用いる CSI 系列は Sionna [37] のレイトレーシングにより生成したものである。OpenStreetMap から取得した地形データを三次元モデル化し、Sionna へ入力して CSI 系列を生成する。白線は端末の移動軌跡であり、赤点は基地局が設置されている位置である。

白線で示される歩行軌道は、現実的な移動経路を生成するために PRM (Probabilistic Roadmap Method: 確率的ロードマップ法) を用いて生成した。PRM は複雑な障害物環境における経路計画アルゴリズムである。本手法はロードマップ構築フェーズと経路探索フェーズの二段階で構成され、事前に構築したグラフ構造を用いて効率的な経路探索を実現する。

ロードマップ構築フェーズでは、移動可能な経路網をグラフとして表現する。最初に、対象領域内にランダムにノードを配置する。配置したノードのうち建物内部に位置するものは移動経路として不適切であるため、各ノードから鉛直上方にレイを照射して建物との衝突判定を行い、屋内と判定されたノードを除外する。屋外ノードのみを抽出した後、KDTree を用いた K 近傍探索により各ノードの接続候補を選定する。接続候補間では見通し線チェックを実施し、二点間にレイを照射して障害物との衝突がなければエッジを作成する。この手順により、建物を貫通せずに歩行可能な経路のみで構成される無向グラフが得られる。

経路探索フェーズでは、構築したロードマップ上で A*アルゴリズムを適用し、出発点から目的地までの最短経路を探索する。A*アルゴリズムは各ノード n に対して評価関数 $f(n) = g(n) + h(n)$ を計算し、 $f(n)$ が最小となるノードを優先的に展開する。 $g(n)$ は出発点からノード n までに要した実コストを表し、 $h(n)$ はノード n から目的地までのユークリッド距離をヒューリスティックとして用いる。このヒューリスティックは真のコストを過大評価しないため、A*アルゴリズムは最適経路を保証する。得られた経路はノード列の折れ線となるため、指定した歩行速度とサンプリング間隔に基づいて等時間間隔でリサンプリングし、時系列の座標列として出力する。

PRM は格子状探索と比較して少ないノード数で広域をカバーでき、計算効率が高い。一度構築したロードマップは複数の出発点と目的地の組み合わせに対して再利用できるため、多数の経路を生成する場合に有効である。不規則に建物が配置された都市環境においても柔軟に適用できる点も利点として挙げられる。

本シミュレーションの対象エリアとして、東京都中央区八重洲 1 丁目を選定した。同

エリアでは現在、東京駅前八重洲一丁目東B地区市街地再開発事業が進行しており、旧「山本ビル」等の区画において大規模複合施設 TOFROM YAESU の建設が進められている。この地点を選定した理由は、セル内において新たな建造物が建設される環境変動を想定した実験を行うためである。地形データと現在の実際の風景は工事の進捗により異なるが、実際に大規模な開発が行われている土地をモデルとして採用することで、現実の都市更新に即した妥当性の高いシミュレーション環境を構築した。

表 3.1 三次元モデル化に用いたエリア

エリア	中心座標	位置の目安
新宿	35.693°N, 139.703°E	新宿区役所前交差点付近
池袋	35.729°N, 139.713°E	池袋駅東口前の明治通り付近
渋谷	35.659°N, 139.700°E	道玄坂下交差点付近
錦糸町	35.6958°N, 139.8145°E	錦糸町駅前交差点付近
八重洲	35.681°N, 139.770°E	東京駅八重洲口・旧山本ビル付近

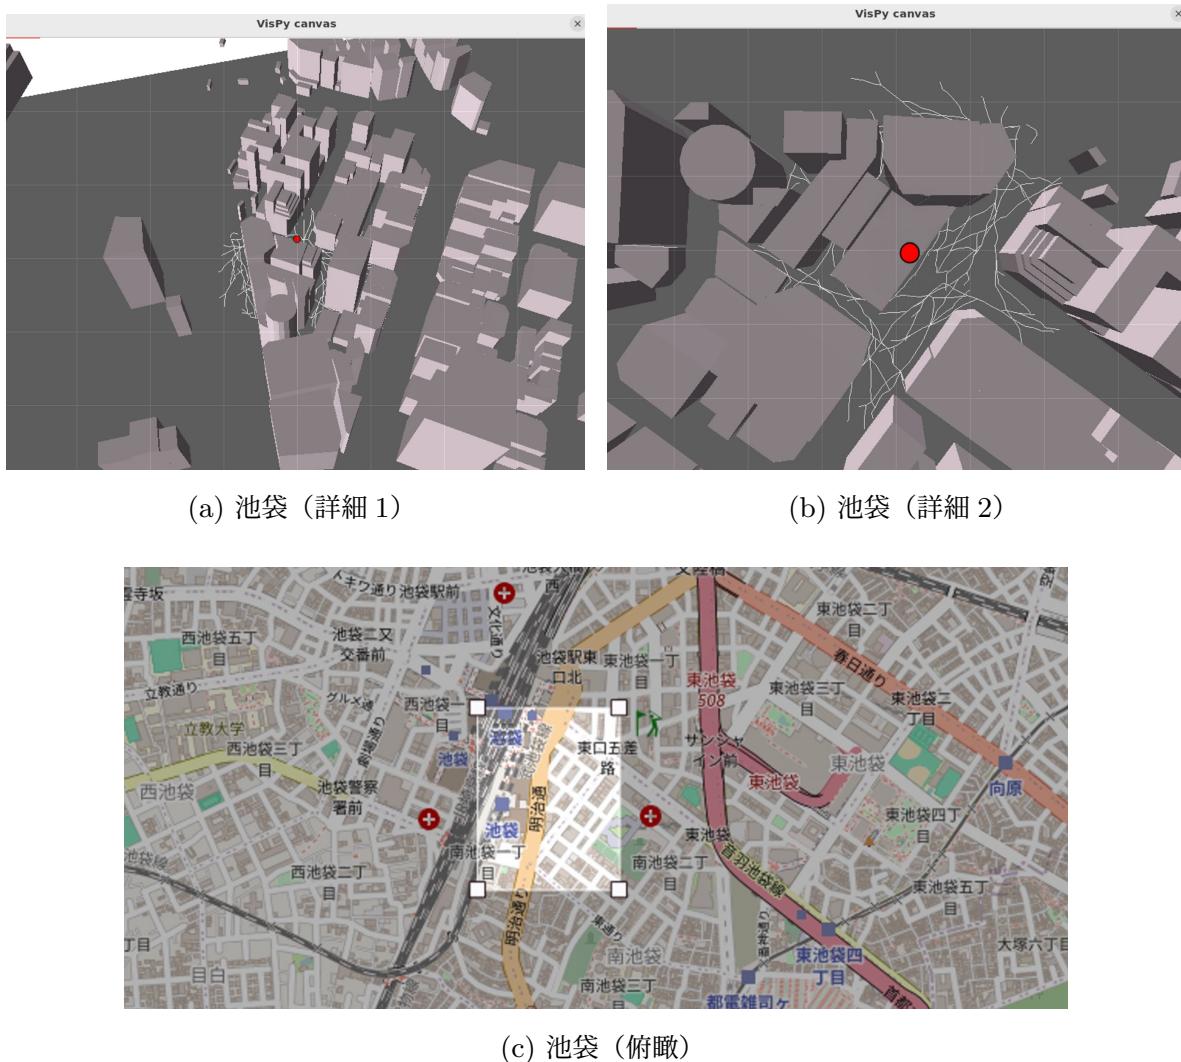


図3.1 三次元モデル化に用いたエリア（池袋）

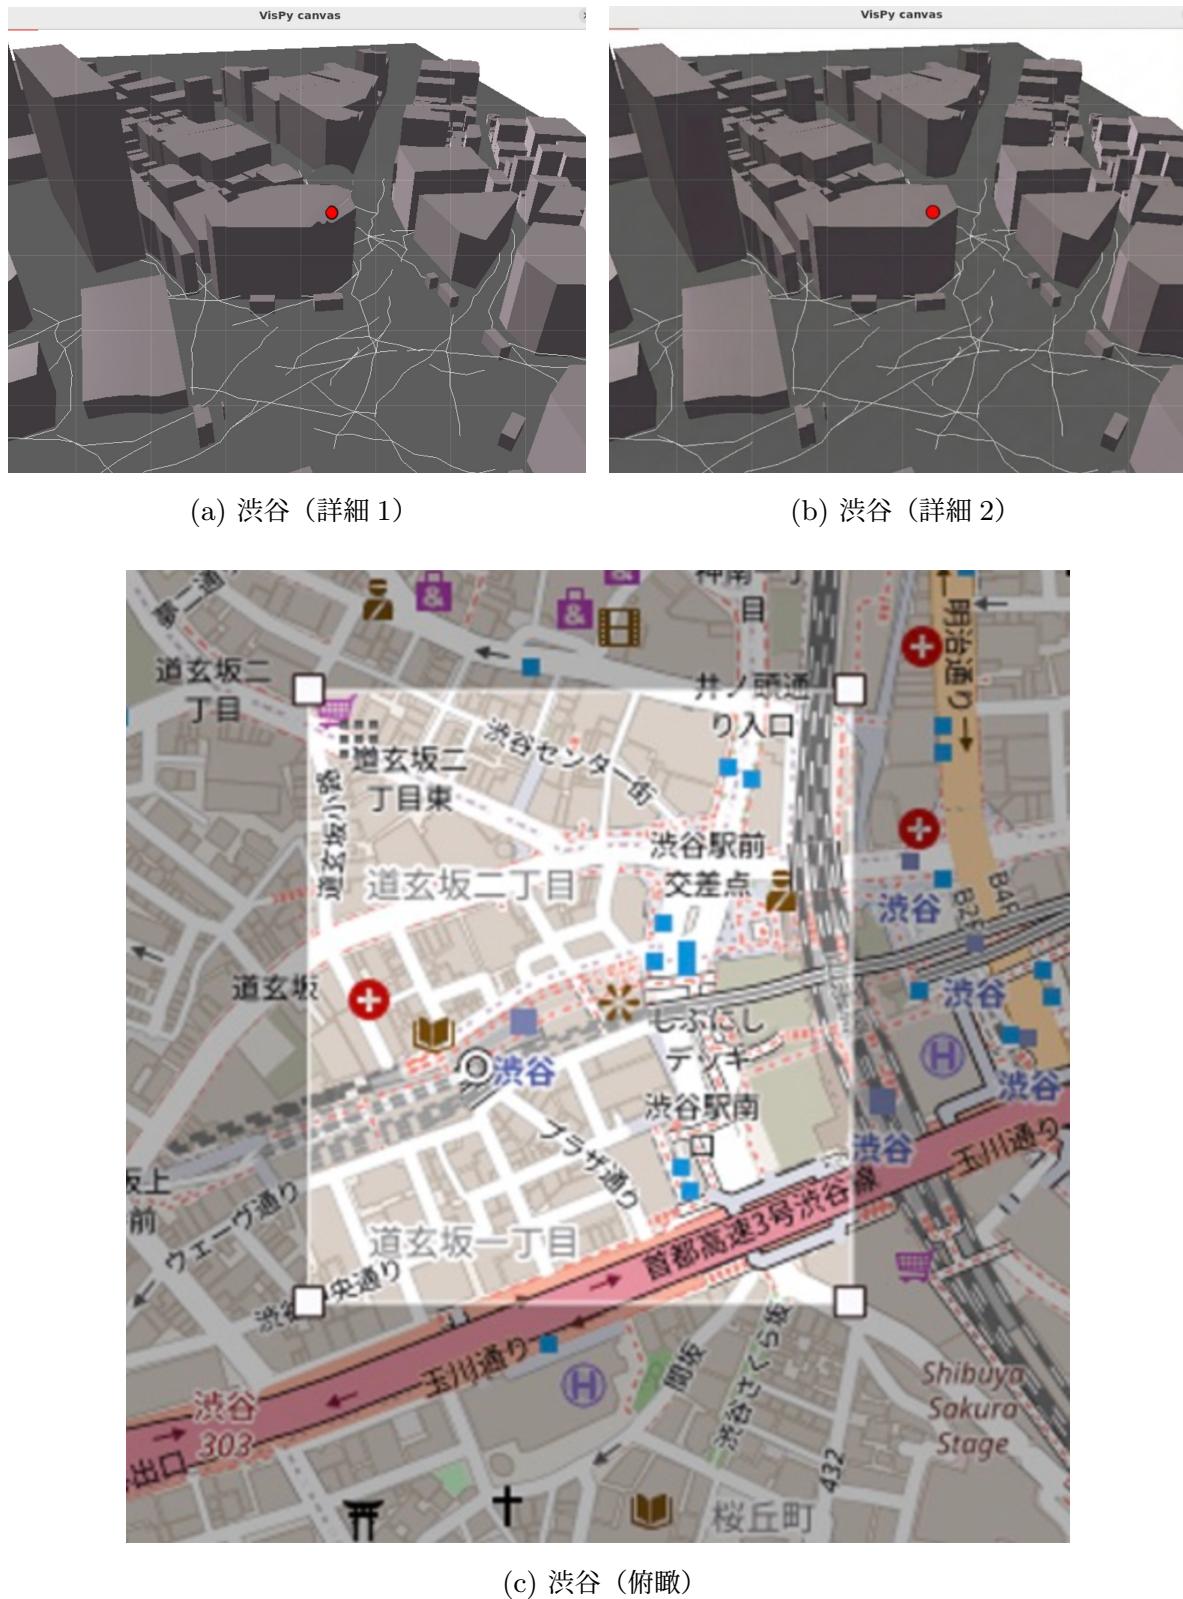


図3.2 三次元モデル化に用いたエリア（渋谷）

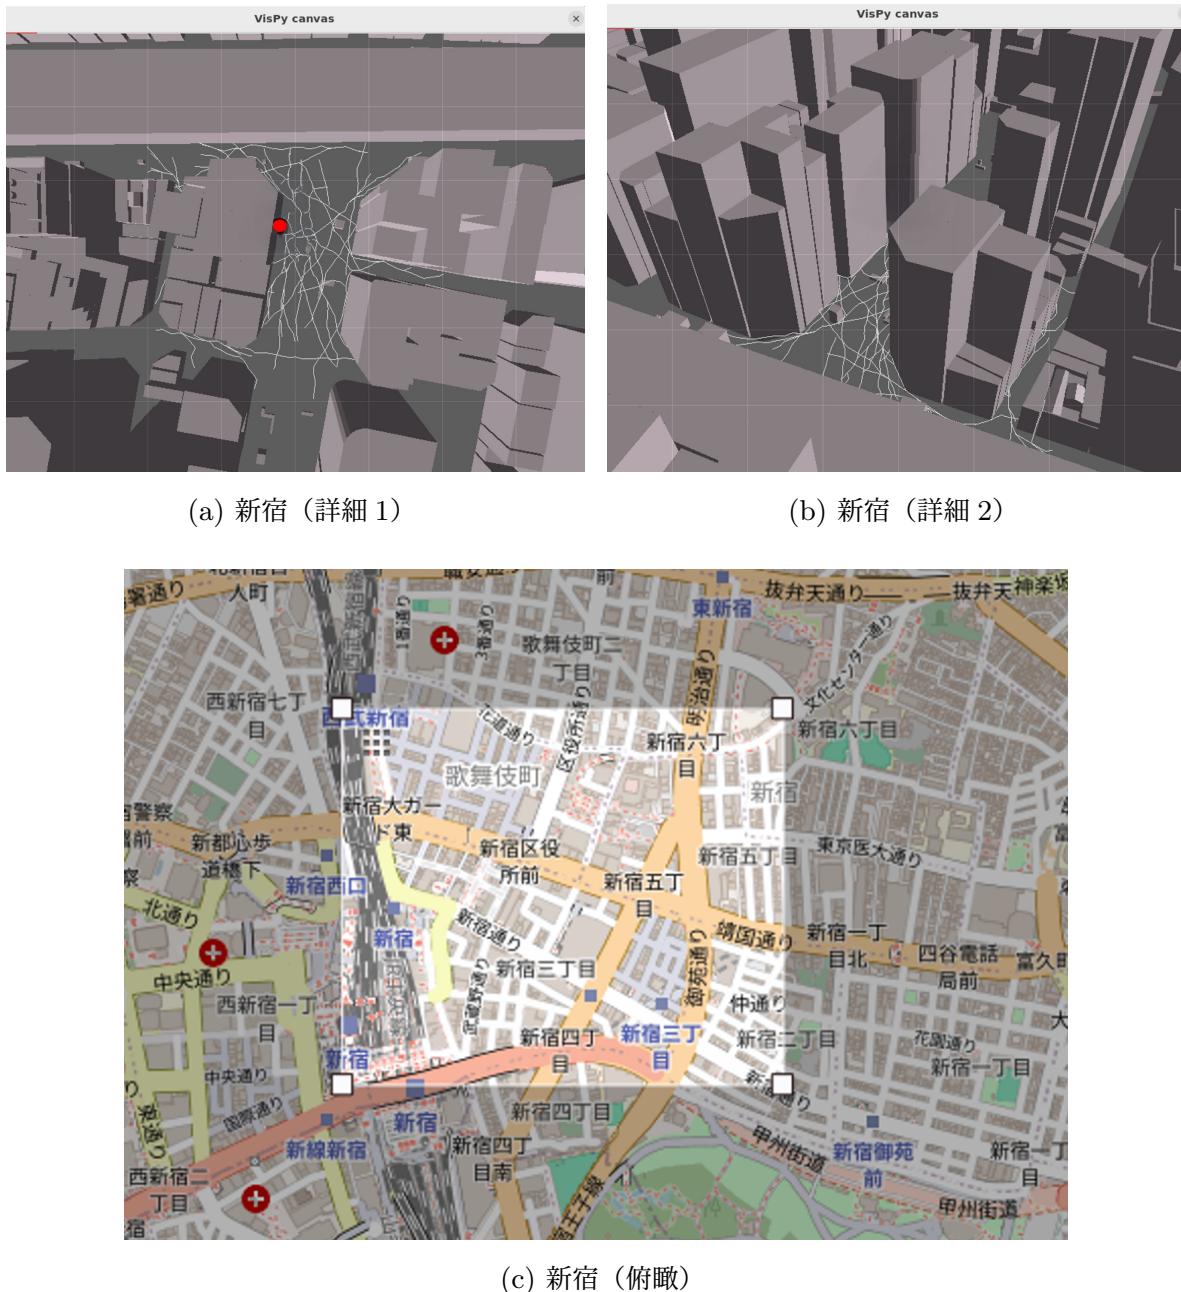
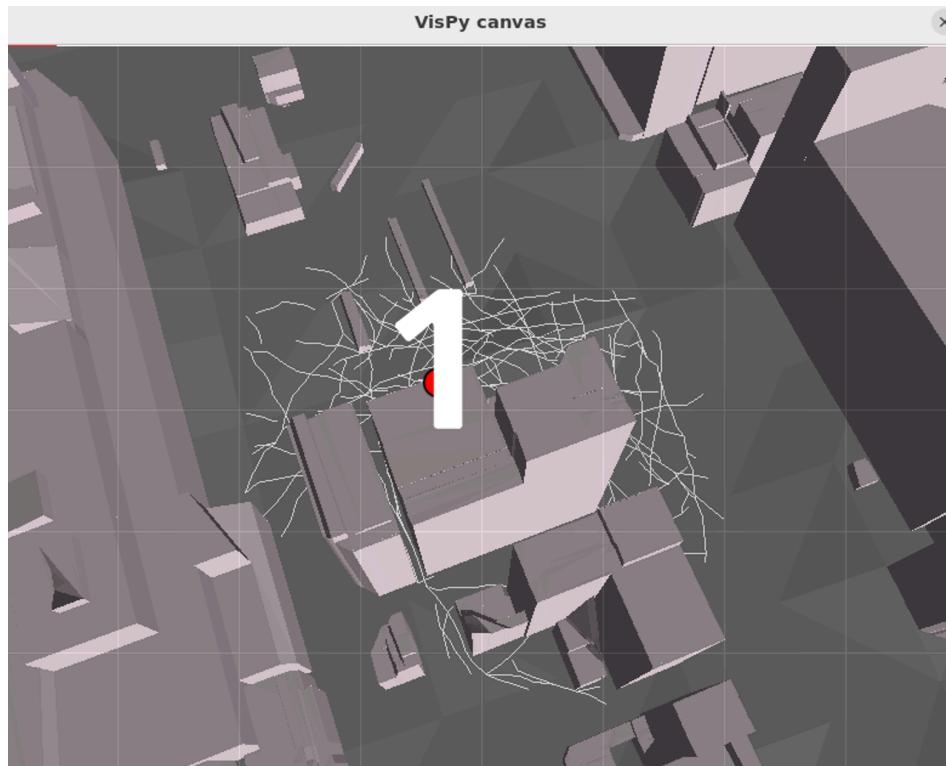
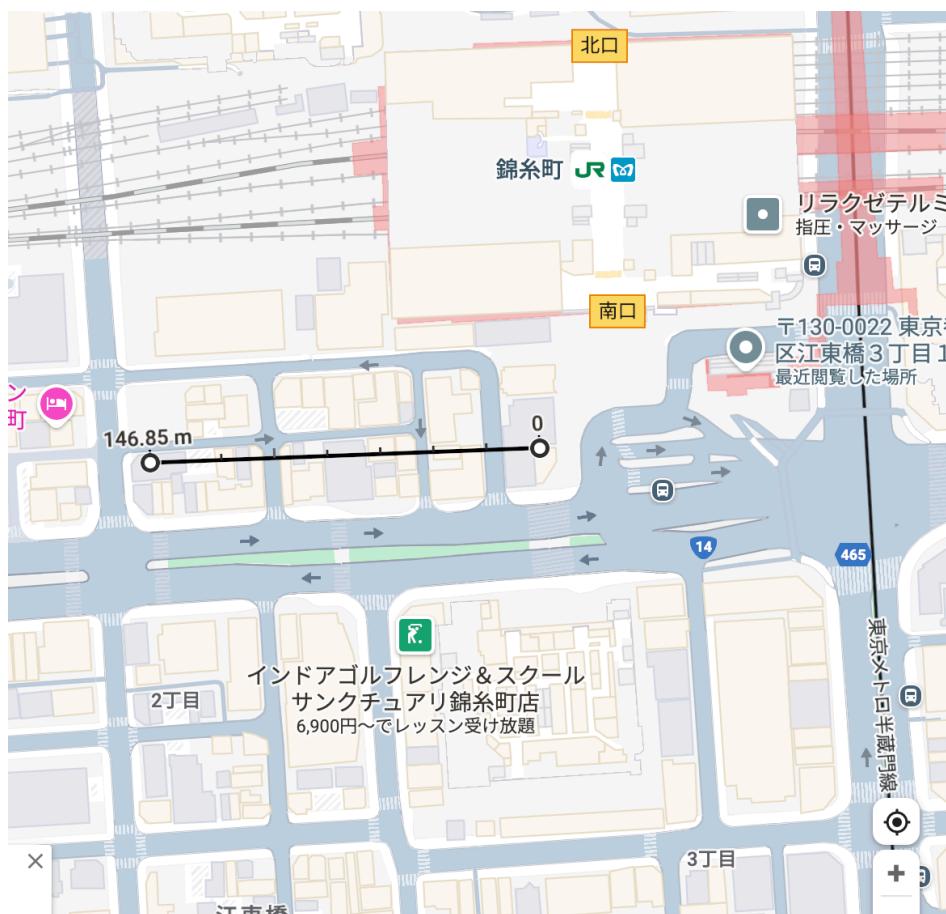


図 3.3 三次元モデル化に用いたエリア（新宿）



(a) 錦糸町（詳細）



(b) 錦糸町（俯瞰）

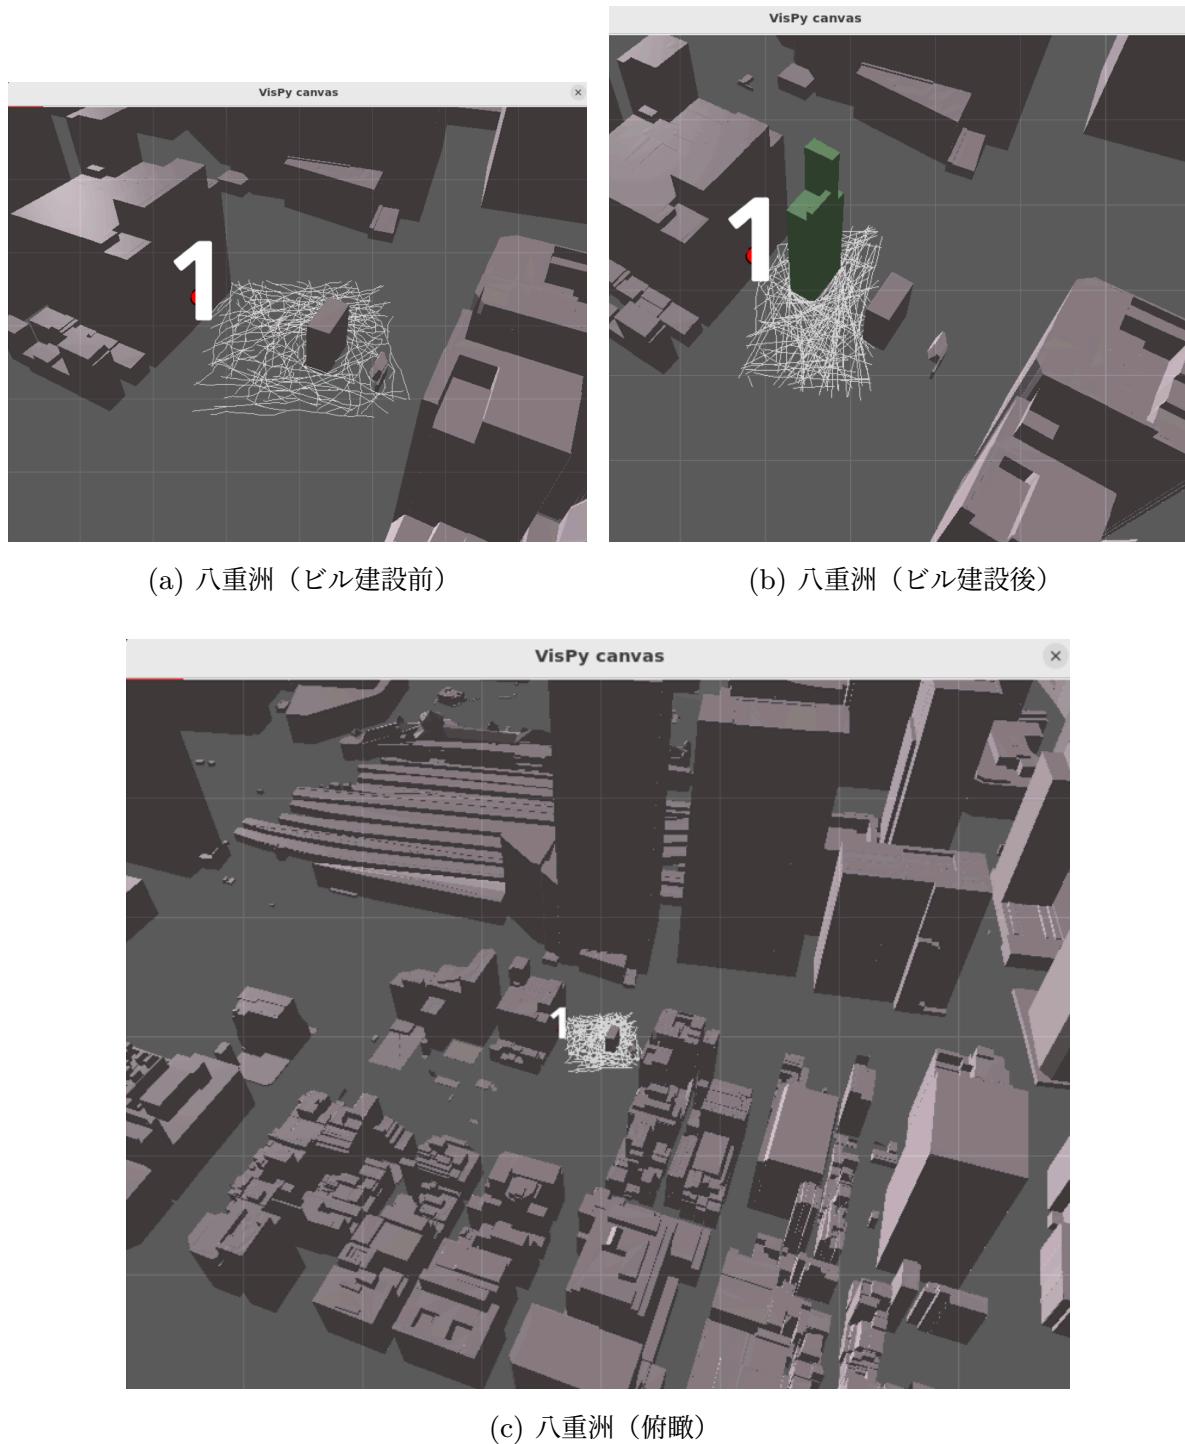


図3.5 三次元モデル化に用いたエリア（八重洲）

レイトレーシングの設定として用いたパラメータを示す。

- 中心周波数 :`frequency` = 3.5 GHz (3.13)
- サブキャリア間隔 :`SCS` = 15 kHz (3.14)
- 帯域幅 :`bandwidth` = 20 MHz (3.15)
- 送信アンテナ数 :`numTx` = 16 (3.16)
- 受信アンテナ数 :`numRx` = 2 (3.17)
- 速度 :`velocity` = 2 km/h, 20 km/h (3.18)
- サンプリング周波数 :`sampling_frequency` = 200 Hz (3.19)
- 最大反射回数 :`max_reflections` = 5 (3.20)
- BS 縦方向素子間隔 :`bs_antenna_vertical_spacing` = 0.5 (3.21)
- BS 横方向素子間隔 :`bs_antenna_horizontal_spacing` = 0.5 (3.22)
- 端末アンテナ列数 :`user_antenna_rows` = 2 (3.23)
- 端末アンテナ行数 :`user_antenna_cols` = 1 (3.24)
- UE 縦方向素子間隔 :`ue_antenna_vertical_spacing` = 0.5 (3.25)
- UE 横方向素子間隔 :`ue_antenna_horizontal_spacing` = 0.5 (3.26)
- 反射 :`reflection` = true (3.27)
- 回折 :`diffraction` = true (3.28)
- 散乱 :`scattering` = false (3.29)
- パス数上限 :`cir_num_paths` = 200 (3.30)
- 遅延の正規化 :`path.normalize_delays` = true (3.31)
- OFDM 変換正規化 :`cir_to_ofdm_normalize` = false (3.32)

上記の設定より、SRS 送信間隔 `srs_sampling` は

$$\text{srs_sampling} = \frac{1}{\text{sampling_frequency}} = \frac{1}{200 \text{ Hz}} = 5 \text{ ms} \quad (3.33)$$

となる。SRS は周波数方向に一定間隔で配置されるとし、SRS が配置された周波数点において CSI を算出する。周波数方向のリソースブロック Resource Block, RB は、サブキャリア 12 本を束ねた単位であり、1RB の周波数幅は

$$B_{\text{RB}} = 12 \text{ SCS} = 12 \times 15 \text{ kHz} = 180 \text{ kHz} \quad (3.34)$$

である。本研究では、周波数方向に 2RB おきに SRS を送信すると仮定する。すなわち、SRS が配置される RB の間隔は

$$B_{\text{SRS}} = 2 B_{\text{RB}} = 360 \text{ kHz} \quad (3.35)$$

である。このとき、CSI は SRS が配置された RB で算出されるため、周波数方向の CSI 系列は 2RB 間隔でサンプリングされたものとなる。

帯域端の影響を避けるため、本研究では帯域内の中心部分のみを用い、有効な RB 数を $N_{\text{RB}} = 96$ とする。このとき、有効帯域幅は

$$\text{bandwidth}_{\text{eff}} = N_{\text{RB}} B_{\text{RB}} = 96 \times 180 \text{ kHz} = 17.28 \text{ MHz} \quad (3.36)$$

となる。2RB おきに SRS が配置されるため、CSI が算出される RB 数は

$$N_{\text{rb}} = \frac{N_{\text{RB}}}{2} = \frac{96}{2} = 48 \quad (3.37)$$

となる。以上より、帯域幅 20 MHz では 1 スロットあたり周波数方向に $N_{\text{rb}} = 48$ 個の RB で CSI が算出される。建物には鉄、地面には土の物性値を割り当てている。以上の条件でレイトレーシングを実行し生成した CSI 系列を [時間, リソースブロック, 送信アンテナ, 受信アンテナ, 複素数次元] として保存する。

3.3.2 シミュレーション条件

本節では、補間手法評価のためのシミュレーション方法について述べる。補間精度の評価には、第 3.3.1 節で述べた錦糸町および八重洲の 2 種類の地形データに対してレイトレーシングにより生成した CSI 系列を用いる。補間手法としては、第 3.2 節で述べた線形補間、スプライン補間、多項式近似、ニューラルネットワーク補間を比較対象とする。ニューラルネットワーク補間器の学習には、評価対象とは異なる地形データから生成した CSI 系列を用いる。錦糸町駅前の CSI 系列を補間するモデルは、新宿、池袋、渋谷の 3 地点から生成した CSI 系列で学習する。八重洲の CSI 系列を補間するモデルは、八重洲から生成した CSI 系列を学習データとして用いる。前者は他セルで運用していた補間器を新規基地局へ展開する状況を想定しており、後者は同一セル内で環境変動が生じた際に補間器を再学習する状況を想定している。

補間器の構成は第 3.2 節で述べた MLP であり、 $\text{Linear}(6F \rightarrow 2048) \rightarrow \text{ReLU} \rightarrow \text{Linear}(2048 \rightarrow 1024) \rightarrow \text{ReLU} \rightarrow \text{Linear}(1024 \rightarrow F)$ の 3 層構造とする。学習時の損失関数には補間値 $\tilde{\mathbf{H}}_t$ と真値 \mathbf{H}_t の平均二乗誤差を用い、最適化には Adam を使用する。学習率は 10^{-4} 、バッチサイズは 128、エポック数は 10 とする。

パイロット信号の送信周期が変化した場合における補間精度を評価するため、推定値と予測値の配置を変化させた複数の疎化パターンを設定する。疎化パターンは、推定値 \mathbf{H} が得られるスロットと予測値 $\widehat{\mathbf{H}}$ で代替するスロットの周期的な配置として定義する。周期 N で 1 個の予測スロットを含むパターンを周期 N 出力 1 パターンと呼ぶ。本章では

以下の3種類を用いる。

$$\text{周期4出力1パターン: } \mathbf{H}, \mathbf{H}, \mathbf{H}, \widehat{\mathbf{H}} \text{ を周期4で繰り返し (削減率25\%)} \quad (3.38)$$

$$\text{周期3出力1パターン: } \mathbf{H}, \mathbf{H}, \widehat{\mathbf{H}} \text{ を周期3で繰り返し (削減率33\%)} \quad (3.39)$$

$$\text{周期2出力1パターン: } \mathbf{H}, \widehat{\mathbf{H}} \text{ を周期2で繰り返し (削減率50\%)} \quad (3.40)$$

周期4出力1パターンでは4スロットに1回、周期3出力1パターンでは3スロットに1回、周期2出力1パターンでは2スロットに1回の頻度で補間が必要となる。疎化パターンに応じて削減率が25%から50%まで変化するため、各パターンにおいて有効な補間手法を特定する。各パターンにおいて、周期 N スロットのうち最後の1スロットが補間対象となり、残りの $N-1$ スロットでは推定値が得られる。

評価指標には正規化平均二乗誤差 NMSE を用いる。補間対象時刻 t における補間値 $\widetilde{\mathbf{H}}_t$ と真値 \mathbf{H}_t の誤差を

$$\text{NMSE}(t) = \frac{\|\widetilde{\mathbf{H}}_t - \mathbf{H}_t\|_2^2}{\|\mathbf{H}_t\|_2^2} \quad (3.41)$$

として定義する。全ファイルおよび全補間対象時刻に対して NMSE を算出し、その平均値

$$\overline{\text{NMSE}} = \frac{1}{N} \sum_{n=1}^N \text{NMSE}(t_n) \quad (3.42)$$

を最終的な評価スコアとする。ここで N は評価に用いた補間対象時刻の総数である。

3.4 地形ごとの補間手法比較評価

3.4.1 結果

本節では、各地形データから生成した CSI 系列に対する補間精度の評価結果を示す。評価は周期4出力1パターンを用いて実施し、各補間手法の NMSE を比較する。

(a) 錦糸町データセットにおける補間精度

錦糸町駅前の地形データから生成した 284 ファイルの CSI 系列に対する補間精度評価を表 3.2 に示す。多項式近似の設定において、次数と片側近傍点数を記載する。例えば「4次、片側3点ずつ」は4次多項式を用い、補間対象時刻の前後それぞれ3点ずつ、計6点の推定値を近傍として使用することを意味する。ニューラルネットワーク補間の設定において、 c はコンテキストサイズを表す。

表 3.2 錦糸町データセットにおける周期 4 出力 1 パターンの補間精度

手法	設定	NMSE
線形補間	—	0.375
スプライン補間	—	0.00610
多項式近似	2 次, 片側 3 点ずつ	0.0517
多項式近似	3 次, 片側 3 点ずつ	0.0517
多項式近似	4 次, 片側 3 点ずつ	0.00590
多項式近似	5 次, 片側 3 点ずつ	0.00590
多項式近似	6 次, 片側 3 点ずつ	0.143
多項式近似	4 次, 片側 6 点ずつ	0.229
多項式近似	4 次, 片側 9 点ずつ	0.258
ニューラルネットワーク補間	$c = 1$	0.385
ニューラルネットワーク補間	$c = 2$	0.511
ニューラルネットワーク補間	$c = 3$	0.474

スプライン補間および 4 次または 5 次の多項式近似が NMSE 0.006 程度で最良の精度を達成した。一方、線形補間やニューラルネットワーク補間は NMSE 0.37 以上と低い精度にとどまった。ニューラルネットワークが低精度となった要因として、学習データが錦糸町と異なる 3 地点で構成されているため、チャネル特性の違いに対応できなかったことが考えられる。

(b) 八重洲 (LoS) データセットにおける補間精度

八重洲 (LoS) の地形データから生成した 101 ファイルの CSI 系列に対する補間精度評価を表 3.3 に示す。

表 3.3 八重洲 (LoS) データセットにおける周期 4 出力 1 パターンの補間精度

手法	設定	NMSE
線形補間	—	0.164
スプライン補間	—	0.0456
多項式近似	2 次, 片側 3 点ずつ	0.0576
多項式近似	3 次, 片側 3 点ずつ	0.0576
多項式近似	4 次, 片側 3 点ずつ	0.0463
多項式近似	5 次, 片側 3 点ずつ	0.0463
多項式近似	6 次, 片側 3 点ずつ	0.152
多項式近似	4 次, 片側 6 点ずつ	0.152
多項式近似	4 次, 片側 9 点ずつ	0.157
ニューラルネットワーク補間	$c = 1$	0.145
ニューラルネットワーク補間	$c = 2$	0.131
ニューラルネットワーク補間	$c = 3$	0.491

八重洲 (NLoS) データセットに対する周期 4 出力 1 パターンの補間精度評価を表 3.4 に示す。八重洲 (NLoS) データセットの評価では、線形補間およびニューラルネットワーク補間を比較対象から除外した。錦糸町および八重洲 (LoS) データセットの評価において、線形補間は補間対象の前後 1 点のみを用いる単純な手法であり、NMSE が 0.16 から 0.37 と低精度であることが確認された。ニューラルネットワーク補間も学習データと評価データの地点差に起因するドメインシフトにより解析的手法を下回る精度にとどまった。これらの結果から、八重洲 (NLoS) データセットにおいても同様の傾向が予想されるため、評価対象から除外した。

表3.4 八重洲 (NLoS) データセットにおける周期4出力1パターンの補間精度

手法	設定	NMSE
スプライン補間	–	0.0574
多項式近似	2次, 片側3点ずつ	0.0824
多項式近似	3次, 片側3点ずつ	0.0824
多項式近似	4次, 片側3点ずつ	0.0580
多項式近似	5次, 片側3点ずつ	0.0580
多項式近似	6次, 片側3点ずつ	0.174
多項式近似	4次, 片側6点ずつ	0.214
多項式近似	4次, 片側9点ずつ	0.225

八重洲 (LoS) データセットにおいても、スプライン補間と4次または5次の多項式近似が最良の精度を示し、NMSEは0.04から0.05程度であった。ニューラルネットワーク補間の精度は錦糸町データセットと比較して向上している。これは、八重洲 (LoS) データセットでは学習と評価が同一地点のCSI系列で構成されているためである。両データセットを通じて、スプライン補間と4次多項式近似が一貫して高い補間精度を達成した。多項式近似では、次数4と次数5で同一のNMSEを示した。これは総近傍点数 $K = 6$ ($k = 3$) に対して次数5の多項式が過剰適合となり、事実上4次と同等の近似となったためと考えられる。次数6では精度が大幅に低下しており、過学習による悪影響が確認された。近傍点数を増やした場合においても精度が低下しており、補間対象から離れた時刻の推定値は精度向上に寄与しないことが示された。

3.5 パイロット疎化拡大時の補間精度評価

本節では、パイロット信号の送信頻度をさらに低減した場合の補間精度を評価する。前節では周期4出力1パターンを用いて評価したが、本節では周期3出力1パターンおよび周期2出力1パターンを追加し、削減率が33%および50%に増加した場合の補間精度を比較する。

3.5.1 結果

(a) 錦糸町データセットにおける補間精度

錦糸町データセットに対する周期3出力1パターンおよび周期2出力1パターンの補間精度評価を表3.5に示す。

表3.5 錦糸町データセットにおける周期3出力1および周期2出力1パターンの補間精度

手法	設定	周期3出力1	周期2出力1
線形補間	—	0.275	0.287
スプライン補間	—	0.00620	0.0130
多項式近似	2次, 片側3点ずつ	0.117	0.176
多項式近似	3次, 片側3点ずつ	0.117	0.176
多項式近似	4次, 片側3点ずつ	0.00690	0.0162
多項式近似	5次, 片側3点ずつ	0.00690	0.0162
多項式近似	6次, 片側3点ずつ	0.159	0.218
多項式近似	4次, 片側6点ずつ	0.163	0.224
多項式近似	4次, 片側9点ずつ	0.280	0.313
ニューラルネットワーク補間	$c = 1$	0.312	0.378
ニューラルネットワーク補間	$c = 2$	0.427	0.397
ニューラルネットワーク補間	$c = 3$	0.576	0.596

周期3出力1パターンにおいても、スプライン補間と4次多項式近似が最良の精度を示し、NMSEは0.006から0.007程度であった。周期2出力1パターンでは削減率が50%に達するが、スプライン補間と4次多項式近似はNMSE 0.013から0.016程度を維持した。ニューラルネットワーク補間は全パターンで0.3以上のNMSEとなり、学習データと評価データの地点差による汎化性能の低さが確認された。

以降の周期3・2出力パターンおよび周期4・3出力パターンの評価では、線形補間およびニューラルネットワーク補間を比較対象から除外した。周期4出力1、周期3出力1、周期2出力1パターンの評価において、線形補間はNMSEが0.16から0.37と低精度であり、補間対象の前後1点のみを用いる単純な手法では時間変動を十分に捉えられないことが確認された。ニューラルネットワーク補間も同様に精度が低く、学習データと評価

データの地点差に起因するドメインシフトにより、スプライン補間や多項式近似といった解析的手法を下回る結果となった。連続補間パターンでは单一フレーム補間よりも推定が困難であり、これらの手法の精度低下が予想されるため、評価対象から除外した。

錦糸町データセットに対する周期3・2出力パターンおよび周期4・3出力パターンの補間精度評価をそれぞれ表3.6および表3.7に示す。本実験では補間位置が複数存在するため、補間位置ごとのNMSE(pos)と、それらを統合したOverall NMSEを算出した。

表3.6 錦糸町データセットにおける周期3・2出力パターンの補間精度

手法	設定	Overall NMSE	pos0	pos1
多項式近似	5次, 片側3点ずつ	0.129	0.128	0.129
スプライン補間	片側3点ずつ	0.131	0.131	0.132
スプライン補間	片側6点ずつ	0.136	0.136	0.137
スプライン補間	片側9点ずつ	0.136	0.136	0.137
多項式近似	4次, 片側3点ずつ	0.169	0.169	0.169
多項式近似	3次, 片側3点ずつ	0.245	0.246	0.245
多項式近似	2次, 片側3点ずつ	0.249	0.250	0.249
多項式近似	6次, 片側6点ずつ	0.265	0.265	0.265
多項式近似	5次, 片側6点ずつ	0.309	0.310	0.309
多項式近似	4次, 片側6点ずつ	0.312	0.312	0.311
多項式近似	6次, 片側9点ずつ	0.337	0.337	0.336
多項式近似	5次, 片側9点ずつ	0.371	0.371	0.371
多項式近似	4次, 片側9点ずつ	0.371	0.372	0.370
多項式近似	6次, 片側3点ずつ	0.419	0.419	0.419

表 3.7 錦糸町データセットにおける周期 4・3 出力パターンの補間精度

手法	設定	Overall NMSE	pos0	pos1	pos2
多項式近似	5 次, 片側 3 点ずつ	0.276	0.209	0.409	0.209
スプライン補間	片側 3 点ずつ	0.282	0.213	0.421	0.213
スプライン補間	片側 6 点ずつ	0.283	0.213	0.422	0.214
スプライン補間	片側 9 点ずつ	0.283	0.213	0.422	0.214
多項式近似	4 次, 片側 3 点ずつ	0.336	0.299	0.409	0.299
多項式近似	3 次, 片側 3 点ずつ	0.345	0.324	0.390	0.323
多項式近似	6 次, 片側 6 点ずつ	0.352	0.338	0.380	0.337
多項式近似	2 次, 片側 3 点ずつ	0.365	0.354	0.390	0.353
多項式近似	5 次, 片側 6 点ずつ	0.365	0.360	0.376	0.360
多項式近似	4 次, 片側 6 点ずつ	0.371	0.369	0.376	0.368
多項式近似	6 次, 片側 9 点ずつ	0.379	0.377	0.383	0.376
多項式近似	5 次, 片側 9 点ずつ	0.403	0.402	0.405	0.403
多項式近似	4 次, 片側 9 点ずつ	0.404	0.404	0.405	0.404
多項式近似	6 次, 片側 3 点ずつ	0.505	0.399	0.727	0.388

(b) 八重洲 (LoS) データセットにおける補間精度

八重洲 (LoS) データセットに対する周期 3 出力 1 パターンおよび周期 2 出力 1 パターンの補間精度評価を表 3.8 に示す.

表3.8 八重洲（LoS）データセットにおける周期3出力1および周期2出力1パターンの補間精度

手法	設定	周期3出力1	周期2出力1
線形補間	—	0.138	0.147
スプライン補間	—	0.0278	0.0360
多項式近似	2次, 片側3点ずつ	0.0969	0.118
多項式近似	3次, 片側3点ずつ	0.0969	0.118
多項式近似	4次, 片側3点ずつ	0.0278	0.0370
多項式近似	5次, 片側3点ずつ	0.0278	0.0370
多項式近似	6次, 片側3点ずつ	0.164	0.224
多項式近似	4次, 片側6点ずつ	0.107	0.132
多項式近似	4次, 片側9点ずつ	0.133	0.143
ニューラルネットワーク補間	$c = 1$	0.140	0.142
ニューラルネットワーク補間	$c = 2$	0.197	0.166
ニューラルネットワーク補間	$c = 3$	0.174	0.227

八重洲（LoS）データセットに対する周期3・2出力パターンおよび周期4・3出力パターンの補間精度評価をそれぞれ表3.9および表3.10に示す。本実験では補間位置が複数存在するため、補間位置ごとのNMSE(pos)と、それらを統合したOverall NMSEを算出した。

表3.9 八重洲（LoS）データセットにおける周期3・2出力パターンの補間精度

手法	設定	Overall NMSE	pos0	pos1
多項式近似	5次, 片側3点ずつ	0.168	0.165	0.171
スプライン補間	片側3点ずつ	0.174	0.171	0.177
スプライン補間	片側6点ずつ	0.176	0.176	0.176
スプライン補間	片側9点ずつ	0.176	0.176	0.176
多項式近似	3次, 片側3点ずつ	0.179	0.179	0.179
多項式近似	6次, 片側6点ずつ	0.183	0.183	0.183
多項式近似	2次, 片側3点ずつ	0.185	0.181	0.188
多項式近似	4次, 片側3点ずつ	0.199	0.191	0.208
多項式近似	5次, 片側6点ずつ	0.225	0.225	0.225
多項式近似	4次, 片側6点ずつ	0.226	0.226	0.226
多項式近似	6次, 片側9点ずつ	0.226	0.226	0.226
多項式近似	4次, 片側9点ずつ	0.257	0.257	0.257
多項式近似	5次, 片側9点ずつ	0.257	0.257	0.257
多項式近似	6次, 片側3点ずつ	0.452	0.452	0.452

表 3.10 八重洲 (LoS) データセットにおける周期 4・3 出力パターンの補間精度

手法	設定	Overall NMSE	pos0	pos1	pos2
多項式近似	5 次, 片側 3 点ずつ	0.257	0.204	0.360	0.206
スプライン補間	片側 6 点ずつ	0.262	0.209	0.370	0.206
スプライン補間	片側 9 点ずつ	0.262	0.209	0.370	0.206
スプライン補間	片側 3 点ずつ	0.262	0.208	0.368	0.209
多項式近似	3 次, 片側 3 点ずつ	0.272	0.244	0.324	0.247
多項式近似	5 次, 片側 6 点ずつ	0.276	0.261	0.307	0.260
多項式近似	4 次, 片側 6 点ずつ	0.281	0.269	0.307	0.268
多項式近似	6 次, 片側 9 点ずつ	0.287	0.275	0.310	0.275
多項式近似	2 次, 片側 3 点ずつ	0.287	0.265	0.324	0.273
多項式近似	6 次, 片側 6 点ずつ	0.288	0.265	0.335	0.264
多項式近似	4 次, 片側 3 点ずつ	0.291	0.247	0.360	0.265
多項式近似	5 次, 片側 9 点ずつ	0.295	0.289	0.306	0.288
多項式近似	4 次, 片側 9 点ずつ	0.298	0.293	0.306	0.293
多項式近似	6 次, 片側 3 点ずつ	0.543	0.433	0.770	0.426

八重洲 (LoS) データセットにおいても同様の傾向が確認された。スプライン補間と 4 次多項式近似は周期 3 出力 1 パターンで NMSE 0.03 程度、周期 2 出力 1 パターンで NMSE 0.04 程度を達成した。ニューラルネットワーク補間は錦糸町データセットと比較して精度が向上しており、同一地点での学習による効果が認められる。ただし、スプライン補間や 4 次多項式近似には及ばず、学習ベースの補間器が解析的手法を上回る条件は本評価では見出されなかった。

八重洲 (NLoS) データセットに対する周期 3 出力 1 パターンおよび周期 2 出力 1 パターンの補間精度評価を表 3.11 に示す。

表 3.11 八重洲 (NLoS) データセットにおける周期 3 出力 1 および周期 2 出力 1 パターンの補間精度

手法	設定	周期 3 出力 1	周期 2 出力 1
スプライン補間	片側 3 点ずつ	0.0550	0.0532
多項式近似	2 次, 片側 3 点ずつ	0.134	0.170
多項式近似	3 次, 片側 3 点ずつ	0.134	0.170
多項式近似	4 次, 片側 3 点ずつ	0.0545	0.0550
多項式近似	5 次, 片側 3 点ずつ	0.0545	0.0550
多項式近似	6 次, 片側 3 点ずつ	0.189	0.250
多項式近似	4 次, 片側 6 点ずつ	0.160	0.194
多項式近似	4 次, 片側 9 点ずつ	0.218	0.280

八重洲 (NLoS) データセットに対する周期 3・2 出力パターンおよび周期 4・3 出力パターンの補間精度評価をそれぞれ表 3.12 および表 3.13 に示す。本実験では補間位置が複数存在するため、補間位置ごとの NMSE (pos) と、それらを統合した Overall NMSE を算出した。

表 3.12 八重洲 (NLoS) データセットにおける周期 3・2 出力パターンの補間精度

手法	設定	Overall NMSE	pos0	pos1
多項式近似	2 次, 片側 3 点ずつ	0.212	0.213	0.212
多項式近似	3 次, 片側 3 点ずつ	0.209	0.209	0.209
多項式近似	4 次, 片側 3 点ずつ	0.182	0.182	0.182
多項式近似	5 次, 片側 3 点ずつ	0.153	0.153	0.153
多項式近似	6 次, 片側 3 点ずつ	0.458	0.458	0.458
多項式近似	4 次, 片側 6 点ずつ	0.281	0.281	0.281
多項式近似	5 次, 片側 6 点ずつ	0.279	0.279	0.279
多項式近似	6 次, 片側 6 点ずつ	0.210	0.211	0.210
多項式近似	4 次, 片側 9 点ずつ	0.346	0.346	0.346
多項式近似	5 次, 片側 9 点ずつ	0.346	0.346	0.346
多項式近似	6 次, 片側 9 点ずつ	0.309	0.309	0.309
スプライン補間	片側 3 点ずつ	0.157	0.157	0.157
スプライン補間	片側 6 点ずつ	0.161	0.161	0.161
スプライン補間	片側 9 点ずつ	0.161	0.161	0.161

表 3.13 八重洲 (NLoS) データセットにおける周期 4・3 出力パターンの補間精度

手法	設定	Overall NMSE	pos0	pos1	pos2
多項式近似	2 次, 片側 3 点ずつ	0.317	0.306	0.340	0.306
多項式近似	3 次, 片側 3 点ずつ	0.298	0.277	0.340	0.277
多項式近似	4 次, 片側 3 点ずつ	0.301	0.268	0.368	0.267
多項式近似	5 次, 片側 3 点ずつ	0.262	0.209	0.368	0.209
多項式近似	6 次, 片側 3 点ずつ	0.548	0.437	0.781	0.427
多項式近似	4 次, 片側 6 点ずつ	0.362	0.354	0.378	0.354
多項式近似	5 次, 片側 6 点ずつ	0.358	0.348	0.378	0.348
多項式近似	6 次, 片側 6 点ずつ	0.325	0.310	0.355	0.310
多項式近似	4 次, 片側 9 点ずつ	0.376	0.373	0.382	0.373
多項式近似	5 次, 片側 9 点ずつ	0.374	0.370	0.382	0.370
多項式近似	6 次, 片側 9 点ずつ	0.361	0.354	0.376	0.354
スプライン補間	片側 3 点ずつ	0.269	0.214	0.379	0.213
スプライン補間	片側 6 点ずつ	0.271	0.216	0.382	0.215
スプライン補間	片側 9 点ずつ	0.271	0.216	0.382	0.215

周期 4 出力 1, 周期 3 出力 1, 周期 2 出力 1 パターンを通じた結果を総括する。表 3.14 に、各疎化パターンにおける補間手法の平均 NMSE を示す。

表 3.14 周期 4 出力 1, 周期 3 出力 1, 周期 2 出力 1 パターンにおける平均 NMSE

手法	設定	錦糸町	八重洲 (LoS)	八重洲 (NLoS)
スプライン補間	-	0.00840	0.0365	0.0552
多項式近似	4 次, 片側 3 点ずつ	0.00970	0.0370	0.0558
多項式近似	5 次, 片側 3 点ずつ	0.00970	0.0370	0.0558

スプライン補間と 4 次多項式近似は、パイロット疎化率が 25% から 50% に変化しても安定した補間精度を維持した。錦糸町では両手法の平均 NMSE は 0.01 以下であり、八重洲 (LoS) では 0.04 以下、八重洲 (NLoS) においても 0.06 未満を維持した。本評価の結果から、チャネル予測モデルの重み更新に用いる補間手法として、スプライン補間または 4 次多項式近似が有効であることが示唆された。

3.6 おわりに

本章では、チャネル予測モデルの重み更新に用いる補間手法を選定するため、錦糸町駅前と八重洲の2種類の地形データから生成したCSI系列に対して補間精度の比較実験を実施した。比較対象として、スプライン補間および多項式近似を用いた。

実験の結果、スプライン補間と4次多項式近似が両データセットで最良の精度を達成し、錦糸町ではNMSEは0.01以下、八重洲では0.04から0.06程度であった。パイロット信号の送信頻度を低減し欠損率が25%から50%に増加した場合においても、両手法は安定した補間精度を維持した。

以上の結果から、次章以降の実験ではスプライン補間または4次多項式近似を用いて提案機構を実装する。

■ 第4章

時系列補間型学習データ を用いた無線チャネル予 測機構

4.1 はじめに

本章では、第2章で指摘した予測スロットにおいて推定値が得られずモデルの重みを更新できないという問題に対して補間を用いた新たなモデル重み更新機構を提案する。その際に用いる補間手法は第3章で比較検証した中で最も有効な手法を採用する。

4.2 時系列補間型学習データを用いたチャネル予測機構によるモデル重み更新

本研究では、参照信号削減のため予測スロットでは参照信号を送信せず、当該スロットのCSI推定値が得られない状況を前提とする。このとき、予測スロットでは教師信号、すなわち正解ラベルが欠損するため、既存の重み更新手法をそのまま適用できない。そこで、予測を継続しながらも時系列CSI予測モデルを更新できる枠組みを提案する。本枠組みの要点は、欠損した正解ラベルを直ちに用意して逐次更新するのではなく、後続スロットで観測されるCSI推定値に基づき予測スロットの補間値を事後的に算出し、推定値と補間値で構成されるCSI系列を一定量蓄積した後に、その系列から更新用の学習サンプル群を構成してモデルを更新する点にある。提案機構の概要を図4.1に示す。

以下、時刻 t をスロット時刻とし、参照信号から得るCSI推定値を \mathbf{H}_t 、予測モデルが出力するCSI予測値を $\widehat{\mathbf{H}}_t$ とする。補間ににより得られる予測スロットの補間値を $\widetilde{\mathbf{H}}_t$ とする。説明のため、直近3スロットを入力として1スロット先を予測する3入力1出力の予測モデルを例にとる。このとき、学習済み予測モデル f_θ により

$$\widehat{\mathbf{H}}_{t+3} = f_\theta(\mathbf{H}_t, \mathbf{H}_{t+1}, \mathbf{H}_{t+2}) \quad (4.1)$$

を得る。しかし、参照信号削減の運用では予測スロット $t+3$ において参照信号を送信しないため、 \mathbf{H}_{t+3} は観測できず、 $\widehat{\mathbf{H}}_{t+3}$ に対する教師信号が欠落する。

そこで本研究では、予測スロットより後に得られる推定値を用い、欠損した \mathbf{H}_{t+3} を事後的に推定する。具体的には、次スロット以降で参照信号が送信されて $\mathbf{H}_{t+4}, \mathbf{H}_{t+5}, \dots$ が得られたら、欠損時刻の前後に存在する推定値を用いて補間し、予測スロットに対応する補間値

$$\widetilde{\mathbf{H}}_{t+3} \quad (4.2)$$

を算出する。この $\widetilde{\mathbf{H}}_{t+3}$ は、予測スロットで本来得られるべき \mathbf{H}_{t+3} の近似として扱うことで、教師あり学習に必要な正解ラベルを補間ににより近似する役割を担う。

補間値は後続スロットの推定値が得られてはじめて定まるため、欠損が生じるたびに即時に学習サンプルを確定させて逐次更新する運用とはならない。本研究では、推定値と補間値で構成される CSI 系列を蓄積し、所定の長さの時系列が揃った時点で、その系列から更新用の学習サンプル群を構成してモデルを微調整する。例えば、3 入力 1 出力の設定では、入力を $\tilde{\mathbf{H}}_{t+3}, \mathbf{H}_{t+4}, \mathbf{H}_{t+5}$ 、出力を \mathbf{H}_{t+6} として学習サンプルを作成し、複数サンプルをまとめて更新に用いる。ここで、3 入力の並びは一例であり、入力の 3 時刻のうち予測スロットに対応する 1 点を $\tilde{\mathbf{H}}$ で置き換え、残りを後続スロットで得られる推定値で構成すればよい。すなわち、

$$\mathbf{H}_{t+6} \approx f_{\theta}(\tilde{\mathbf{H}}_{t+3}, \mathbf{H}_{t+4}, \mathbf{H}_{t+5}) \quad (4.3)$$

となるように損失を計算し、勾配法によりモデルを微調整する。

以上の手順を繰り返すことで、参照信号削減下でも予測スロットにおける欠損ラベルを補間により補った CSI 系列を蓄積し、蓄積した系列から学習サンプル群を構成して更新を反復できる。これにより、環境変化に伴う分布の変化に追従したモデル更新を実現する。

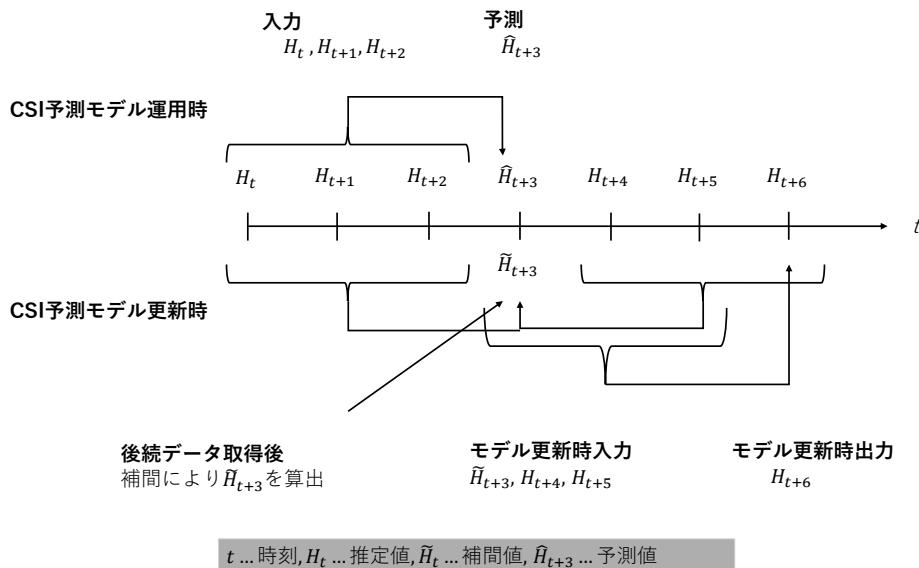


図 4.1 提案機構の概要

4.3 シミュレーション

4.3.1 シミュレーション条件

本節では、提案機構の有効性を検証するためのシミュレーション条件について述べる。本実験で用いる CSI 系列は、節 3.3.1 で述べたとおり、Sionna によるレイトレーシングで生成したものである。以下、本実験で用いる学習データの構成および実験手順を説明する。

(a) ベースラインモデルおよび補間モデルの学習

本実験では、事前学習用データセットとして事前学習データを用いる。事前学習データは、池袋、渋谷、新宿の 3 地域から取得した CSI 系列で構成される。この事前学習データから、時系列 CSI 予測を担うベースラインモデルと、欠損時刻の CSI を推定する補間モデルの両方を学習する。

ベースラインモデルの学習では、事前学習データを学習用、検証用、テスト用の 3 つに分割する。分割比率は Train:Val:Test = 7:2:1 とし、学習用データでモデルを訓練し、検証用データで過学習の監視および最良モデルの選択を行い、テスト用データで汎化性能を評価する。

補間モデルの学習も同一の事前学習データを用いる。ニューラルネットワーク補間を用いる場合は、補間モデル専用のデータ分割を行う。補間モデルの学習では Train:Val = 8:2 の比率で分割し、学習用データで補間モデルを訓練し、検証用データで性能を監視する。スプライン補間や多項式近似など事前学習を要しない補間手法では、このステップは不要である。

以上により、事前学習データからベースラインモデルと補間モデルの両方を得る。ベースラインモデルは以降のファインチューニングにおける初期値として用い、補間モデルはファインチューニング用データセット生成時の補間値算出に用いる。

(b) 検証用データの 5 分割

検証用データは、錦糸町で取得した CSI 系列で構成される。この検証用データを用いて、ベースラインモデルを新環境に適応させるファインチューニングを実施する。

評価の信頼性を高めるため、検証用データを 5 分割し、交差検証により評価する。具体的には、検証用データを 5 つの互いに重複しない部分集合に分割する。各分割において、

5つの部分集合のうち4つをファインチューニング用として用い、残りの1つを評価用として用いる。すなわち、ファインチューニング用と評価用の比率は4:1である。

この分割を5回繰り返し、各回で異なる部分集合を評価用に割り当てることで、すべてのデータが1度は評価用として用いられる。5分割交差検証により、特定のデータ分割に依存した偏りを排除し、データセットの難易度による評価結果の変動を均一化する。

(c) フайнチューニング用データセットの生成

各分割において、ファインチューニング用として割り当てられた4/5の検証用データから、学習サンプルを生成する。ファインチューニング用データセットの生成には、補間手法を用いる。

具体的には、連続するCSIフレームからスライディングウィンドウ方式でサンプルを抽出する。抽出したウィンドウの中心時刻に対応するフレームを欠損フレームとみなし、周囲のフレームを用いて補間値を算出する。補間値の算出には、3次スプライン補間、ニューラルネットワーク補間、多項式近似などの手法を適用する。算出した補間値を入力系列に含め、後続時刻の真値を出力とする学習サンプルを構成する。

この手順により、欠損時刻を補間値で補ったファインチューニング用学習サンプル群が得られる。補間手法ごとに異なるファインチューニング用データセットを生成し、手法間の性能比較に用いる。

(d) フайнチューニングの実施

生成したファインチューニング用データセットを用いて、ベースラインモデルを更新する。ベースラインモデルの重みを初期値として読み込み、ファインチューニング用データセットで追加学習を行う。学習後のモデルを適応後モデルとして保存する。

この操作を補間手法ごとに実施し、各補間手法に対応する適応後モデルを得る。ファインチューニングのハイパーパラメータは、学習率、エポック数、バッチサイズを含め、すべての手法で共通の値を用いる。

(e) 評価

各分割において、評価用として割り当てられた1/5の検証用データを用いて、適応後モデルの予測精度を評価する。評価指標には、予測NMSEを用いる。

評価対象は、ファインチューニングを行わないベースラインモデル、各補間手法を用いてファインチューニングした適応後モデル、および予測を行わない場合である。予測なしとは直前フレームをそのまま次時刻の予測値として出力する手法であり、予測モデルの有

効性を確認するためのベースラインとして用いる。

各分割で得られた予測 NMSE を補間手法ごとに記録し、5分割すべての評価が完了した後に平均値を算出する。ベースラインモデルから適応後モデルへの改善率を補間手法間で比較し、提案機構の有効性を検証する。

(f) 交差検証の意義

5分割交差検証を採用する理由は、評価結果の信頼性と汎化性を確保するためである。単一のデータ分割のみで評価した場合、評価用データに含まれる軌跡の特性によって結果が変動する可能性がある。例えば、評価用データに予測が容易な軌跡が偏って含まれれば、改善率は過大評価される。逆に、予測が困難な軌跡が偏って含まれれば、改善率は過小評価される。

5分割交差検証では、すべてのデータが評価用として1度は使用されるため、特定の軌跡に依存した評価の偏りを抑制できる。5回の評価結果を平均することで、データセット全体に対する平均的な性能を推定し、提案機構の有効性をより客観的に評価する。

4.3.2 機械学習モデル

はじめに本論文で用いる時系列 CSI 予測を実行するニューラルネットワークのアーキテクチャについて説明する。本論文では多重パーセプトロン (MLP) と長短期記憶 (LSTM) を用いた2種類のニューラルネットワークを用いる。

本論文の CSI 予測器は、全結合層からなる多層パーセプトロン (MLP) として実装する。時刻方向に過去 T_I フレーム分の CSI を用い、各フレームをベクトル化して結合した入力 $\mathbf{x} \in \mathbb{R}^{T_I \cdot F}$ から、次フレーム 1 枚分の CSI をベクトル化した出力 $\hat{\mathbf{y}} \in \mathbb{R}^F$ を回帰する。ここで、 F は 1 フレームの CSI (行列) をフラット化した次元である。

MLP の層構成は以下のとおりである。中間層では ReLU により非線形性を導入し、過学習を抑制するために Dropout ($p = 0.1$) を適用する。

- Linear(in_dim → 2048) → ReLU → Dropout($p = 0.1$)
- Linear(2048 → 1024) → ReLU → Dropout($p = 0.1$)
- Linear(1024 → 512) → ReLU → Dropout($p = 0.1$)
- Linear(512 → out_dim)

以上により、過去 T_I フレームに含まれる時系列情報を、固定長ベクトル \mathbf{x} として受け取り、次フレームの CSI ベクトル $\hat{\mathbf{y}}$ を予測する。

続いて LSTM のアーキテクチャについて説明する。LSTM では、過去 T_I フレーム分の CSI を時系列として入力し、隠れ状態により時間方向の依存関係を保持しながら次フレームの CSI を回帰する。入力は MLP と同様に、各フレームの CSI をベクトル化して結合した $\mathbf{x} \in \mathbb{R}^{T_I \cdot F}$ である。本論文の設定では $T_I = 3$, $F = 3072$ より $\mathbf{x} \in \mathbb{R}^{9216}$ となる。バッチサイズを B とすると入力形状は $[B, T_I \cdot F] = [B, 9216]$ である。この入力を時系列へ再整形し、

$$\mathbf{X} \in \mathbb{R}^{B \times T_I \times F} = \mathbb{R}^{B \times 3 \times 3072} \quad (4.4)$$

を得る。 \mathbf{X} は 3 フレームからなる系列であり、各タイムステップは 3072 次元の CSI ベクトルに対応する。

LSTM の層構成は以下のとおりである。本論文では 2 層のスタック LSTM を用いる。過学習を抑えるため、層間に Dropout $p = 0.1$ を適用する。

- 第 1 層 LSTM: 入力 $[B, 3, 3072]$ を受け取り、隠れ状態次元 512 の系列出力 $[B, 3, 512]$ を出力する。
- 第 2 層 LSTM: 第 1 層の出力 $[B, 3, 512]$ を入力とし、 $[B, 3, 512]$ を出力する。
- 特徴抽出: 第 2 層 LSTM の最終タイムステップの隠れ状態 $\mathbf{h}_{T_I} \in \mathbb{R}^{B \times 512}$ を特徴量として用いる。 \mathbf{h}_{T_I} は過去 3 フレームの情報を集約した固定長表現である。
- 全結合層: 抽出した特徴量 \mathbf{h}_{T_I} を全結合層へ与え、次フレームの CSI ベクトルを回帰する。全結合層は $\text{Linear}(512 \rightarrow F)$ とし、出力形状は $[B, F] = [B, 3072]$ である。

以上により、過去 T_I フレームに含まれる時系列情報を、隠れ状態により保持しながら次フレームの CSI ベクトル $\hat{\mathbf{y}}$ を予測する。

(a) 機械学習モデルのハイパーパラメーター

本論文で用いる予測モデルと補間モデル、および補間値を用いたファインチューニングの、学習率、エポック数、バッチサイズ設定値を以下に示す。

ベースラインモデルのトレーニング 学習率は 1×10^{-3} , エポック数は 40, バッチサイズは 128 である。

補間モデルである Interpolator NN のトレーニング 学習率は 1×10^{-4} , エポック数は 10, バッチサイズは 128 である。

ファインチューニング 学習率は 1×10^{-4} , エポック数は 20, バッチサイズは 128 である。

損失評価には、正規化平均二乗誤差 Normalized Mean Squared Error, NMSE を用いる。NMSE は、推定値と予測値の二乗誤差を推定値の電力で正規化した量であり、サンプルごとに算出した後に平均し以下の式で表される

■予測 NMSE 予測 NMSE は、予測モデルが output する予測値 $\widehat{\mathbf{H}}_t$ と真値 \mathbf{H}_t の誤差を評価する。

$$\text{NMSE}_{\text{pred}} = \frac{\|\widehat{\mathbf{H}}_t - \mathbf{H}_t\|_2^2}{\|\mathbf{H}_t\|_2^2} \quad (4.5)$$

4.4 時系列補間型学習データを用いた無線チャネル予測機構評価

本節では、節 4.3 で述べたシミュレーション条件に基づき、時系列補間型学習データを用いたチャネル予測機構の評価を行う。

4.4.1 新基地局設置時

本節の実験では他セルで運用していたチャネル予測モデルを新規基地局へ展開する状況を想定している。具体的には、池袋、渋谷、新宿の 3 地域で収集した CSI 系列により事前学習したモデルを、錦糸町駅前の環境に適応させる。新規基地局の設置直後は十分な学習データが蓄積されていないため、限られたサンプル数でモデルを適応させる手法が求められる。提案する時系列補間型学習データを用いたファインチューニングが、この課題に對してどの程度有効であるかを検証する。

事前学習データには、節 3.3.1 で述べた渋谷駅前、新宿駅前、池袋駅前の 3 地域における地形データに対してレイトレーシングを実施し生成した CSI 系列を用いる。1 サンプルは入力用の 3 時刻分の CSI と出力用の 1 時刻分の CSI で構成され、連続する 4 時刻の CSI 系列を非重複で切り出して生成する。

事前学習データのサンプル数を表 4.1 に示す。学習用データが 204,390 サンプル、検証用データが 49,193 サンプル、テスト用データが 18,859 サンプルであり、合計 272,442 サンプルで構成される。

表 4.1 事前学習データのサンプル数

データ種別	サンプル数
学習用 (Train)	204,390
検証用 (Val)	49,193
テスト用 (Test)	18,859
合計	272,442

検証用データには、錦糸町駅前の地形データに対してレイトレーシングを実施し生成した CSI 系列を用いる。検証用データのサンプル数は約 277,900 である。事前学習データと検証用データは互いに独立した地理的環境から取得しており、両者の間にデータの重複はない。

本評価では、既存セルで運用していたチャネル予測モデルを新規基地局へ展開する状況を想定する。具体的には、池袋、渋谷、新宿の 3 地域で収集した CSI 系列により事前学習したモデルを、錦糸町という未知の環境に適応させる。新規基地局の設置直後は十分な学習データが蓄積されていないため、限られたサンプル数で効率的にモデルを適応させる手法が求められる。提案する時系列補間型学習データを用いたファインチューニングが、この課題に対してどの程度有効であるかを検証する。

(a) ベースラインモデルの学習結果

まず、事前学習データを用いたベースラインモデルの学習結果を示す。図 4.2 にベースラインモデルの学習曲線を示す。横軸はエポック数、縦軸は NMSE である。エポックを重ねるごとに学習用データおよび検証用データの双方で NMSE が減少しており、モデルが適切に学習されていることが確認できる。

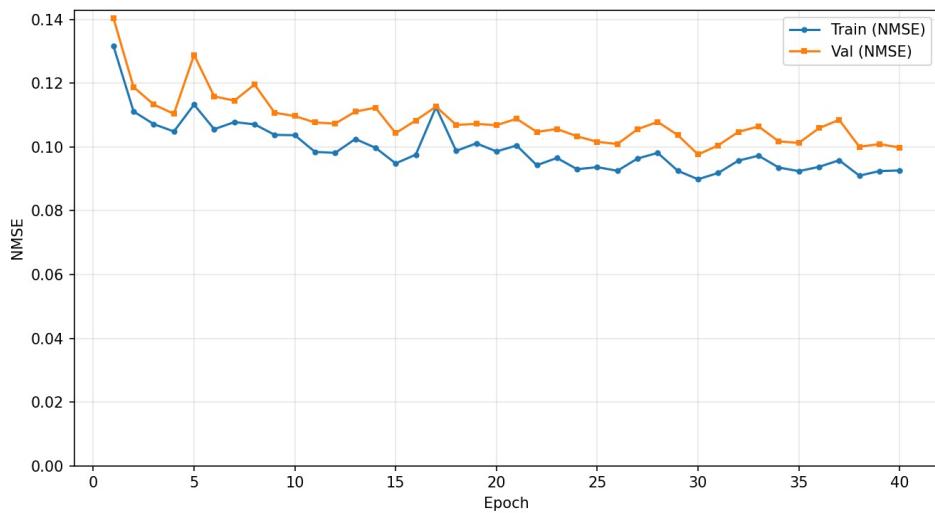


図4.2 ベースラインモデルの学習曲線

次に、ベースラインモデルの予測性能を評価するため、予測を行わない場合との比較を行う。予測なしの手法として、入力3フレームの最終時刻 $t = 2$ における CSI 推定値をそのまま出力時刻 $t = 3$ の推定値として使用する方法を定義する。予測なしは直前の推定値をビームフォーミングに使用する場合に相当し、予測によりどの程度の改善が得られるかを評価する基準となる。

表4.2に、錦糸町の検証用データにおけるベースラインモデルと予測なしの NMSE 比較結果を示す。5分割交差検証の各 fold において、ベースラインモデルの NMSE は予測な

しと比較して大幅に小さい値を示している。平均 NMSE はベースラインモデルが 0.136, 予測なしが 0.321 であり、ベースラインモデルは予測なしの場合と比較して NMSE を約 58% 削減している。この結果から、事前学習により獲得したチャネル予測能力が、未知の環境である錦糸町においても一定の汎化性能を発揮していることがわかる。

表 4.2 ベースラインモデルと予測なしの NMSE 比較

Fold	ベースラインモデル	予測なし
0	0.144	0.493
1	0.141	0.326
2	0.127	0.205
3	0.143	0.348
4	0.128	0.232
平均	0.136	0.321

続いて、節 3.2で述べた補間手法を用いて予測スロットの CSI を補間する。補間手法の選定にあたっては、表 3.2に示した錦糸町データセットにおける補間精度評価の結果を参考にする。同評価では、錦糸町駅前の地形データに対してレイトレーシングにより生成した CSI 系列を用いて各補間手法の精度を比較した。その結果、スプライン補間および 4 次または 5 次の多項式近似が NMSE 0.006 程度と最良の精度を達成することが判明している。

本実験では、上記の評価結果に基づき、スプライン補間および多項式近似を採用して予測スロットの CSI を補間する。これらの補間手法は事前学習を必要としないため、新規基地局において即座に適用可能である点も利点となる。補間により生成した CSI を用いてファインチューニング用の学習サンプルを構成し、ベースラインモデルの適応を試みる。

(b) 学習サンプルの構成

3 入力 1 出力のチャネル予測モデルを運用する場合、 $\mathbf{H}_t, \mathbf{H}_{t+1}, \mathbf{H}_{t+2}$ から $\widehat{\mathbf{H}}_{t+3}$ を得る。参照信号を削減する予測スロットでは、時刻 $t + 3$ の推定値 \mathbf{H}_{t+3} を獲得できない。基地局が利用できる CSI 系列は $\mathbf{H}_t, \mathbf{H}_{t+1}, \mathbf{H}_{t+2}, -, \mathbf{H}_{t+4}, \mathbf{H}_{t+5}, \mathbf{H}_{t+6}, -, \dots$ のように推定値と欠損が周期的に現れる系列となる。欠損時刻に対して補間を適用すると、補間値 $\widetilde{\mathbf{H}}_{t+3}$ が得られ、系列は $\mathbf{H}_t, \mathbf{H}_{t+1}, \mathbf{H}_{t+2}, \widetilde{\mathbf{H}}_{t+3}, \dots$ となる。

この補間後の系列から学習サンプルを構成する方法として、補間値 $\widetilde{\mathbf{H}}$ の配置位置に応じて 4 種類のパターンが考えられる。表 4.3に各パターンの構成を示す。Label は補間値

を出力として用いる構成であり、First, Middle, Last はそれぞれ補間値を入力の 1 番目, 2 番目, 3 番目に配置する構成である。

表 4.3 補間値の配置位置による学習サンプルの構成

パターン	入力 1	入力 2	入力 3	出力
Label	H_0	H_1	H_2	\widetilde{H}_3
First	\widetilde{H}_3	H_4	H_5	H_6
Middle	H_2	\widetilde{H}_3	H_4	H_5
Last	H_1	H_2	\widetilde{H}_3	H_4

(c) フайнチューニング結果

各サンプル構成を用いてベースラインモデルをファインチューニングし、予測精度の改善率を評価した。補間手法としてはスpline補間を採用した。表 4.4にスpline補間を用いた場合の結果を示す。表中のファインチューニング後 NMSE は 5 分割交差検証における平均値であり、ベースラインモデル比改善率はベースラインモデルの NMSE からの削減率を表す。

表 4.4 スpline補間ににおける配置位置ごとのファインチューニング結果

配置位置	ファインチューニング後 NMSE	ベースラインモデル比改善率
Label	0.0319	78.5%
First	0.0303	79.6%
Middle	0.0335	77.4%
Last	0.0310	79.1%

First が最良の結果を示し、NMSE は 0.030265、ベースラインモデル比改善率は 79.56% となった。補間値を入力の 1 番目に配置する構成が最も効果的であることがわかる。全ての配置位置において 77% 以上の改善率が得られており、補間値を用いたファインチューニングが新規基地局への適応に有効であることが確認できる。

(d) 補間手法ごとの予測精度改善率

続いて、スpline補間および多項式近似を用いて時系列補間型学習データを作成し、ファインチューニングによる予測精度改善率を評価した。補間値の配置位置としては、前

節の結果に基づき First パターンを採用した。

本実験では 5 分割交差検証を用いて評価を行った。各分割において、ファインチューニング用データに対して各補間手法を適用し、First パターンの学習サンプルを構成してベースラインモデルを更新した。更新後のモデルを評価用データで検証し、予測精度改善率を算出した。

表 4.5 に補間手法ごとの予測精度改善率を示す。表中の補間 NMSE は各補間手法が出力する補間値 $\tilde{\mathbf{H}}$ と真値 \mathbf{H} との誤差を表す。ファインチューニング前 NMSE はベースラインモデルの NMSE、ファインチューニング後 NMSE は更新後モデルの NMSE である。改善率はファインチューニング前 NMSE からの削減率を表し、5 分割交差検証における平均値を示す。

$$\text{improve} = \frac{\text{NMSE}_{\text{base}} - \text{NMSE}_{\text{adapted}}}{\text{NMSE}_{\text{base}}} \times 100 \quad (4.6)$$

表 4.5 補間手法ごとの予測精度改善率

補間手法	補間 NMSE	予測なし	ベースラインモデル	FT 後 NMSE	ベースラインモデルからの改善率
スプライン補間	0.00610	0.321	0.136	0.028	79.4%
片側 3 点ずつの 4 次多項式近似	0.00590	0.321	0.136	0.028	79.4%
片側 3 点ずつの 5 次多項式近似	0.00590	0.321	0.136	0.028	79.4%
片側 6 点ずつの 4 次多項式近似	0.229	0.321	0.136	0.050	63.2%

スプライン補間、片側 3 点ずつの 4 次多項式近似、片側 3 点ずつの 5 次多項式近似の 3 手法は、補間 NMSE が 0.006 程度と高精度であり、ファインチューニング後の改善率も 79% 以上を達成した。一方、片側 6 点ずつの 4 次多項式近似は補間 NMSE が 0.229 と低精度であり、改善率は 63.24% にとどまった。

この結果から、補間手法自体の精度がファインチューニング後の予測精度改善率に影響を与えることがわかる。表 3.2 に示したとおり、錦糸町データセットにおいてスプライン補間および片側 3 点ずつの 4 次または 5 次多項式近似が高精度であることが判明していた。本実験においても、補間精度の高い手法ほど予測精度改善率が高くなる傾向が確認された。補間 NMSE が 0.006 程度の手法では 79% 以上の改善率を達成した一方、補間 NMSE が 0.229 の手法では改善率が 63% 程度に低下した。

以上の結果から、時系列補間型学習データを用いたファインチューニングにおいて、補間手法の選定が予測精度に影響を与えることが示された。高精度な補間手法を用いることで、新規基地局への適応においてより高い予測精度改善率を達成できる。

(e) 学習サンプル数の影響評価

学習サンプル数を段階的に増加させた場合の予測性能改善を評価する。ファインチューニングに用いるサンプル数が予測精度に与える影響を明らかにすることで、実運用における必要データ量の指針を得る。

評価対象のベースラインとして、ファインチューニング前のベースラインモデルと予測なしを設定した。ベースラインモデルの NMSE は 0.1326、予測なしの NMSE は 0.3621 である。表 4.6 に各サンプル数における予測 NMSE を示す。補間手法として、3 次スプライン補間、片側 3 点ずつの 4 次多項式近似、片側 3 点ずつの 5 次多項式近似の 3 手法を用いた。

表 4.6 学習サンプル数と予測 NMSE の関係

サンプル数	FT 前 NMSE	3 次スpline	片側 3 点ずつの 4 次多項式	片側 3 点ずつの 5 次多項式
0	0.133	0.133	0.133	0.133
19,575	0.133	0.188	0.188	0.188
39,150	0.133	0.133	0.133	0.133
58,725	0.133	0.105	0.105	0.105
78,300	0.133	0.0894	0.0888	0.0892
97,874	0.133	0.0774	0.0770	0.0769

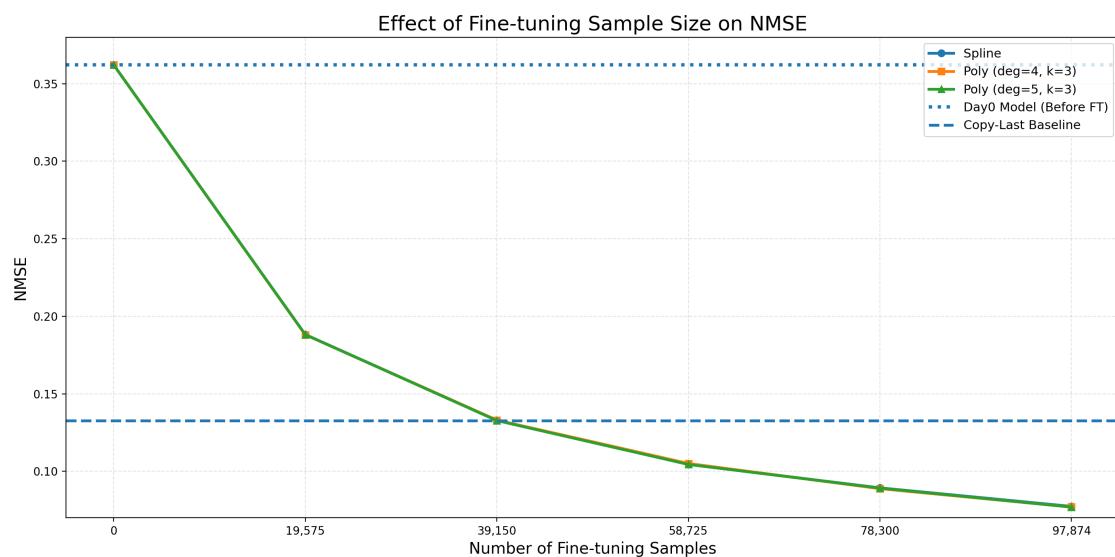


図 4.3 学習サンプル数と予測 NMSE の関係

表 4.6 および図 4.3 から、学習サンプル数の増加に伴い NMSE が減少する傾向が確認で

きる。サンプル数0のときはファインチューニングが未実施であり、NMSEは0.1326である。サンプル数19,575ではNMSEは0.188程度となり、ファインチューニング前と比較して一時的に悪化するが、サンプル数の増加に伴い改善する。サンプル数39,150ではNMSE0.133程度に達し、ベースラインモデルのNMSE0.1326とほぼ同等の性能を示す。これ以上のサンプル数ではベースラインモデルを上回る性能を達成する。

サンプル数97,874では最良の結果が得られ、5次多項式近似でNMSE0.0769を達成した。ファインチューニング前と比較して約79%の改善である。3つの補間手法間のNMSE差は全てのサンプル数において0.002以内であり、手法間の性能差は小さい。

図中の水平破線はベースラインを示しており、上側の破線が予測なし、下側の破線がファインチューニング前のベースラインモデルである。サンプル数の増加に伴い、ファインチューニング後のNMSEがベースラインモデルを下回り、十分なサンプル数があれば補間値を用いた学習が有効に機能することが確認できる。

(f) 雑音に対する堅牢性評価

提案手法の雑音環境下における性能を評価するため、評価用CSIに対して加法性白色ガウス雑音(AWGN)を付与し、各SNRにおける予測NMSEを測定した。

雑音の付与方法を以下に示す。CSIテンソルを $\mathbf{H} \in \mathbb{C}^{T \times R_B \times T_x \times R_x}$ とする。SNR[dB]からノイズパワー比 σ を

$$\sigma = 10^{-\frac{\text{SNR}_{\text{dB}}}{10}} \quad (4.7)$$

として算出する。標準複素ガウス雑音 $z \sim \mathcal{CN}(0, 1)$ を生成し、CSIの平均電力を $P_s = \mathbb{E}[|\mathbf{H}|^2]$ とする。雑音を $n = \sqrt{\sigma P_s / 2} z$ としてスケーリングし、雑音付加後のCSIを

$$\mathbf{H}_{\text{noisy}} = \mathbf{H} + n \quad (4.8)$$

とする。このとき、信号対雑音電力比は $\text{SNR} = P_s / \mathbb{E}[|n|^2] = 1/\sigma$ を満たす。

評価対象のベースラインとして、ファインチューニング前の事前学習モデルであるベースラインモデルと、直前フレームをそのまま予測値とする予測なしの場合を設定した。ベースラインモデルの予測NMSEは0.1439、予測なしのNMSEは0.1755である。表4.2に示した結果と値が異なるのは、データ分割のランダム性の違いによる。本評価ではNMSEが比較的小さく算出される区間が評価用データに割り当てられたと考えられる。

評価対象のSNRは-2, 0, 2, 4, 6, 8, 10, 15, 20 dBとした。表4.7に各SNRにおける予測NMSEを示す。比較対象の補間手法として、3次スプライン補間、片側3点ずつの4次多項式近似、片側3点ずつの5次多項式近似の3手法を用いた。

表 4.7 各 SNR における予測 NMSE

SNR [dB]	3次スプライン	片側3点ずつの4次多項式	片側3点ずつの5次多項式
クリーン	0.0310	0.0310	0.0309
-2	0.0817	0.0813	0.0818
0	0.0614	0.0617	0.0615
2	0.0481	0.0486	0.0487
4	0.0411	0.0415	0.0414
6	0.0369	0.0371	0.0371
8	0.0348	0.0348	0.0343
10	0.0333	0.0332	0.0332
15	0.0316	0.0315	0.0316
20	0.0313	0.0311	0.0312

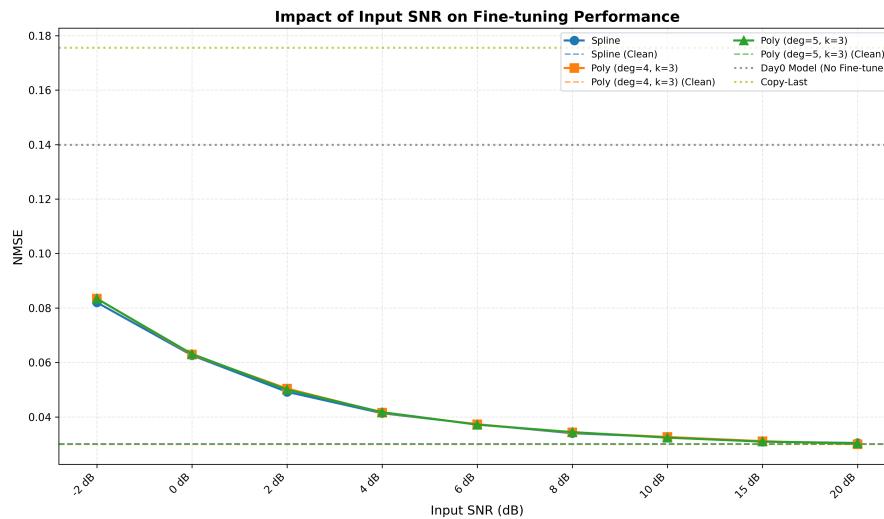


図 4.4 各 SNR における予測 NMSE

表 4.7および図 4.4から、SNR が低いほど予測 NMSE が大きくなり、SNR が高くなるほど予測 NMSE が小さくなることが確認できる。SNR が -2 dB のとき、3次スプライン補間では 0.0817、片側3点ずつの4次多項式近似では 0.0813、片側3点ずつの5次多項式近似では 0.0818 の NMSE を示す。一方、SNR が 20 dB のとき、各手法の NMSE は 0.0313, 0.0311, 0.0312 となり、クリーンな場合の 0.0310 前後に近づく。この結果から、ノイズが大きい環境では予測精度が低下するが、SNR が高くなるにつれて予測精度が向上し、ノイズの影響が小さくなる環境ではクリーンな場合と同等の性能を維持できることが示される。

3つの補間手法を比較すると、各SNRにおけるNMSEの差は0.0001から0.0006程度であり、手法間の性能差は小さい。特にSNRが8dB以上の高SNR領域では、3手法のNMSEはほぼ一致しており、補間手法の選択による性能への影響は限定的である。このことから、ノイズ環境における予測性能は、補間手法の違いよりもSNRの影響が支配的であると考えられる。

(g) セル内チャネル統計変動時 (NLoS から LoS への適応)

本節では、同一セル内においてチャネル統計特性が変動した場合の予測性能を評価する。前節では異なる地域間でのモデル適応を検証したが、実環境では同一セル内においても建物の建設や解体により電波伝搬環境が変化する場合がある。本節の実験では、このような環境変化に対する予測モデルの適応性を検証する。

評価用データセットとして、東京駅八重洲口周辺の地形データを用いる。当該エリアは現在大規模な再開発が進行しており、新たな高層ビルの建設によりセル内の電波伝搬環境が変化する状況を想定できる。図3.5に示すように、本評価では同一エリアにおいてビル建設前後の2種類の地形データを用意した。図3.5bはビル建設後の状態を示しており、高層ビルにより見通しが遮られたNLoS環境を形成している。一方、図3.5aはビル建設前の状態であり、見通しが確保されたLoS環境となっている。

本実験では、NLoS環境で運用していたチャネル予測モデルを環境変化後のLoS環境に適応させる状況を想定する。ビル建設後のNLoS環境で収集したCSI系列により事前学習を行い、その後ビル解体や都市再開発によりLoS環境へ変化した際に、限られたサンプル数でモデルを再適応させることを目指す。セル内の環境変化は段階的に生じることが多く、変化直後は新環境に対応した学習データが不足するため、効率的なファインチューニング手法が求められる。

実験手順は前節と同様とする。事前学習に用いるモデルアーキテクチャおよびハイパラメータ、補間手法、ファインチューニングの設定は節4.4.1と同一である。本節では事前学習データとして八重洲のビル建設後(NLoS環境、図3.5b)の地形データを用い、評価用データセットにはビル建設前(LoS環境、図3.5a)の地形データを用いる。

(h) ベースラインモデルの学習結果

事前学習データを用いたベースラインモデルの学習結果を示す。図4.5にベースラインモデルの学習曲線を示す。横軸はエポック数、縦軸はNMSEである。

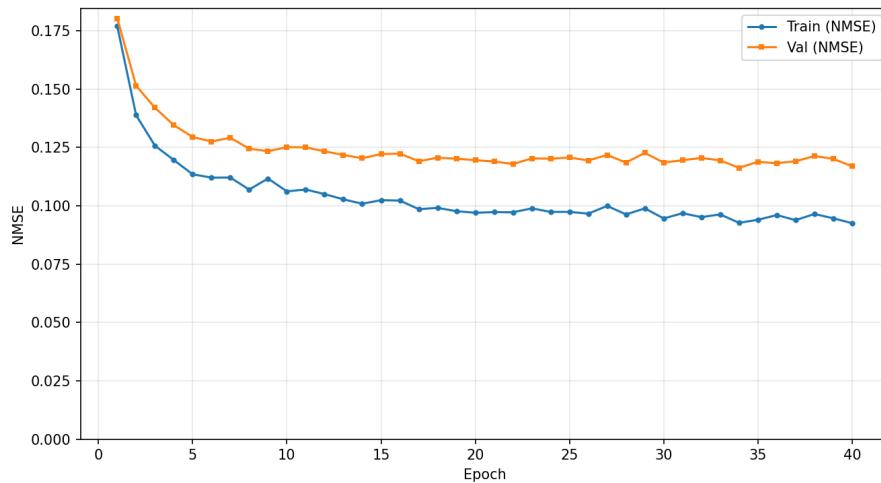


図4.5 ベースラインモデルの学習曲線 (NLoS から LoS への適応)

学習用データの NMSE はエポック数の増加に伴い単調に減少し、40 エポック終了時点で約 0.093 に収束している。検証用データの NMSE は初期エポックで急速に減少した後、約 0.12 前後で推移しており、15 エポック以降はほぼ横ばいとなっている。学習用データと検証用データの NMSE に約 0.03 の差が生じているが、検証用データの NMSE が発散していないことから、過学習の兆候は軽微であると判断できる。学習曲線の挙動は前節の図 4.2 と類似しており、モデルが安定して収束していることが確認できる。

次に、ファインチューニングを行わない状態でのベースラインモデルの予測性能を評価する。表 4.8 に、八重洲の LoS 環境における評価結果を示す。予測なしとは前節と同様に、入力 3 フレームの最終時刻における CSI 推定値をそのまま出力時刻の推定値として使用する手法である。

表4.8 ベースラインモデルと予測なしの NMSE 比較 (NLoS から LoS への適応)

Fold	ベースラインモデル (FT 前)	予測なし
0	0.328	0.201
1	0.438	0.179
2	0.303	0.092
3	0.310	0.095
4	0.410	0.140
平均	0.358	0.141

ベースラインモデル（ファインチューニング前）の NMSE は平均 0.358 であり、予測なしの平均 0.141 と比較して大きい値を示している。この結果は、NLoS 環境で学習したモデルが LoS 環境に対して適切に汎化できていないことを示す。前節の新基地局設置時の評価ではベースラインモデルが予測なしを上回る性能を示したが、本実験ではチャネル統計特性の変化により予測精度が大幅に低下している。NLoS 環境と LoS 環境では電波伝搬特性が根本的に異なるため、事前学習で獲得したチャネル予測能力が新環境に適用できていない。この結果から、セル内の環境変化に対応するためにはファインチューニングによるモデル適応が必要であることが示唆される。

(i) ファインチューニング結果

ベースラインモデルに対してファインチューニングを実施し、予測精度の改善を評価する。補間手法の選定にあたっては、表 3.3 に示した八重洲データセットにおける補間精度評価の結果を参考にする。同評価では、スプライン補間および 4 次または 5 次の多項式近似が NMSE 0.05 程度と最良の精度を達成することが確認されている。本実験ではこれらの手法を採用し、補間値を用いたファインチューニングを実施する。

学習サンプルの構成については、前節の表 4.4において補間値を入力の 1 番目に配置する First パターンが最良の改善率を示したことから、本実験でも First パターンを採用する。

表 4.9 に各補間手法を用いたファインチューニング結果を示す。表中の FT 後 NMSE および改善率は 5 分割交差検証における平均 \pm 標準偏差であり、改善率は各 fold におけるベースラインモデル（FT 前）の NMSE からの削減率を集計したものである。

表 4.9 補間手法ごとのファインチューニング結果（NLoS から LoS への適応）

補間手法	補間 NMSE	予測なし	ベースラインモデル	FT 後 NMSE	ベースラインモデルからの改善率
スプライン補間	0.0456	0.141	0.358	0.098 ± 0.023	$72.8 \pm 3.57\%$
片側 3 点ずつの 4 次多項式近似	0.0463	0.141	0.358	0.096 ± 0.024	$73.4 \pm 3.44\%$
片側 3 点ずつの 5 次多項式近似	0.0463	0.141	0.358	0.098 ± 0.023	$72.9 \pm 3.55\%$

4 次多項式近似が最良の結果を示し、NMSE は 0.0960 となった。5 次多項式近似およびスプライン補間も同程度の精度を達成しており、3 手法間の NMSE 差は 0.002 以内に収まっている。ファインチューニング前のベースラインモデル（FT 前）と比較すると、4 次多項式近似では改善率が Fold 平均で $73.35 \pm 3.44\%$ となった。予測なしと比較しても、ファインチューニング後のモデルは全 fold で NMSE が低く、環境変化に対して有効に適応できていることが確認できる。この結果から、時系列補間型学習データを用いたファインチューニングにより、セル内の環境変化に対してもモデルを効果的に適応できることが

確認された。

次に、ファインチューニングに用いる学習サンプル数と予測精度の関係を評価する。実運用においては新環境でのデータ収集量が限られる場合があるため、少量のサンプルでどの程度の性能改善が得られるかを把握することは重要である。図4.6に、学習サンプル数を変化させた場合のファインチューニング後 NMSE を示す。

比較対象の補間手法として、スプライン補間、片側3点ずつの4次多項式近似、片側3点ずつの5次多項式近似に加え、ニューラルネットワーク補間（コンテキスト長3）を追加した。ニューラルネットワーク補間は第3.2節で述べた手法であり、補間精度が低い場合にファインチューニング性能がどのように変化するかを検証するために比較対象として含めた。第3.3.2節の補間精度評価において、ニューラルネットワーク補間は多項式近似やスプライン補間と比較して補間 NMSE が高い傾向にあることが確認されている。したがって、ニューラルネットワーク補間を用いたファインチューニングでは、補間精度の劣化がどの程度予測性能に影響を与えるかを観察できる。

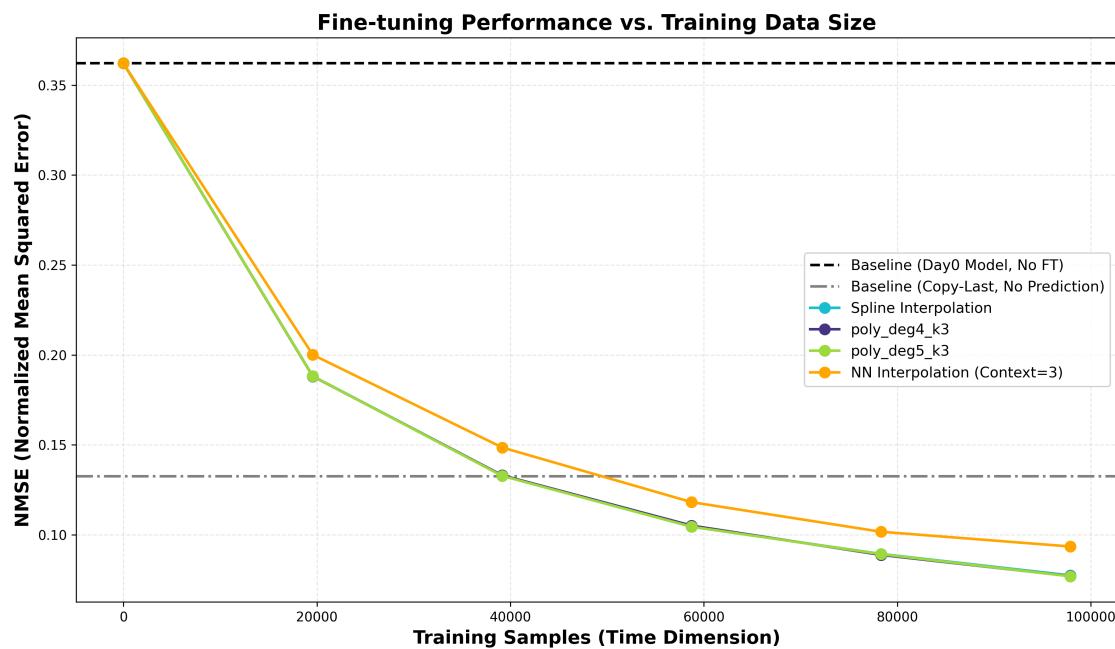


図4.6 学習サンプル数とファインチューニング後 NMSE の関係 (NLoS から LoS への適応)

図4.6から、全ての補間手法において学習サンプル数の増加に伴い NMSE が単調に減少する傾向が確認できる。図中の上側の水平破線はファインチューニング前のベースラインモデル (NMSE 約 0.36)，下側の水平破線は予測なし (NMSE 約 0.13) を示す。

スプライン補間, 4次多項式近似, 5次多項式近似の3手法は, 全てのサンプル数において同程度の NMSE を示しており, 曲線がほぼ重なっている. これらの手法では, 学習サンプル数が 20,000 の時点で NMSE が約 0.19 となり, ベースラインモデルに対して約 47% の改善を達成している. 学習サンプル数が 40,000 に達すると NMSE は約 0.13 となり, 予測なしと同等の性能に到達する. さらに学習サンプル数を増加させると, 60,000 サンプルで NMSE は約 0.10, 100,000 サンプルで NMSE は約 0.08 となり, 予測なしを大幅に上回る性能を達成している.

一方, ニューラルネットワーク補間 (コンテキスト長 3) は, 他の 3 手法と比較して NMSE が一貫して高い値を示している. 学習サンプル数が 20,000 のとき NMSE は約 0.20 であり, スプライン補間等の約 0.19 と比較して若干高い. この差異は学習サンプル数の増加に伴い拡大し, 100,000 サンプルにおいてニューラルネットワーク補間の NMSE は約 0.09 であるのに対し, スプライン補間等は約 0.08 となっている.

この結果から, 補間精度がファインチューニング後の予測精度に影響を与えることが確認された. ニューラルネットワーク補間は補間 NMSE が他手法より高いため, 生成される学習サンプルの品質が相対的に低く, これがファインチューニング後の予測性能の低下につながっている. ただし, ニューラルネットワーク補間を用いた場合でもベースラインモデルや予測なしを上回る性能を達成しており, 補間精度が多少低い場合でも提案手法が有効に機能することが示された.

以上の結果から, 補間手法の選択においては補間精度が高い手法を優先すべきであること, また学習サンプル数が限られる状況でも提案手法により一定の性能改善が得られることが確認された.

(j) 雑音に対する堅牢性評価

提案手法の雑音環境下における性能を評価するため, 評価用 CSI に対して加法性白色ガウス雑音を付与し, 各 SNR における予測 NMSE を測定した. 雑音の付与方法は節 4.4.1 と同様である.

評価対象の SNR は -2, 0, 2, 4, 6, 8, 10, 15, 20 dB とした. 比較対象の補間手法として, 3 次スプライン補間, 片側 3 点ずつの 4 次多項式近似, 片側 3 点ずつの 5 次多項式近似の 3 手法を用いた. 表 4.10 に各 SNR における予測 NMSE を示す.

表 4.10 各 SNR における予測 NMSE (NLoS から LoS への適応)

SNR [dB]	3 次スプライン	片側 3 点ずつの 4 次多項式	片側 3 点ずつの 5 次多項式
クリーン	0.0766	0.0768	0.0769
20	0.0766	0.0767	0.0768
15	0.0767	0.0770	0.0771
10	0.0782	0.0784	0.0785
8	0.0806	0.0807	0.0807
6	0.0850	0.0849	0.0849
4	0.0921	0.0916	0.0917
2	0.102	0.101	0.102
0	0.112	0.110	0.110
-2	0.132	0.131	0.131

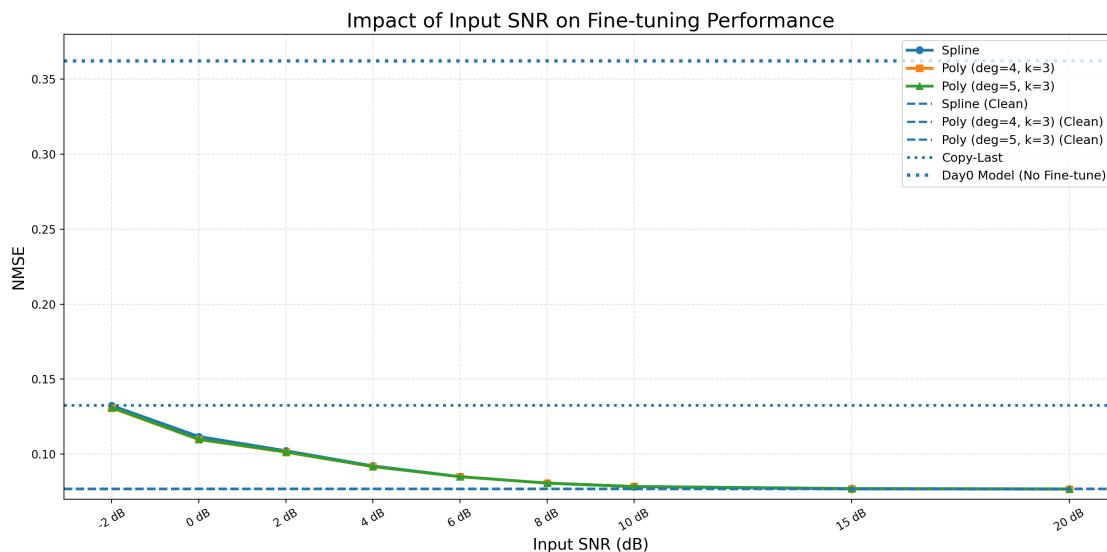


図 4.7 各 SNR における予測 NMSE (NLoS から LoS への適応)

表 4.10 および図 4.7 から、SNR の低下に伴い予測 NMSE が増加する傾向が確認できる。SNR が -2 dB のとき、3 次スプライン補間では 0.1324、片側 3 点ずつの 4 次多項式近似では 0.1307、片側 3 点ずつの 5 次多項式近似では 0.1311 の NMSE を示す。一方、SNR が 20 dB 以上の高 SNR 領域では、各手法の NMSE は 0.077 程度となり、クリーンな場合とほぼ同等の性能を維持している。

図中の水平破線はベースラインを示しており、上側の破線がファインチューニング前のベースラインモデル、下側の破線が予測なしである。ファインチューニング後のモデル

は、SNR が -2 dB の低 SNR 環境においても予測なしと同程度の NMSE を達成しており、SNR が 0 dB 以上では予測なしを下回る性能を示している。ファインチューニング前のベースラインモデルと比較すると、全ての SNR 条件においてファインチューニング後のモデルが大幅に低い NMSE を達成している。

3つの補間手法を比較すると、各 SNR における NMSE の差は 0.002 以内であり、手法間の性能差は小さい。特に SNR が 8 dB 以上の高 SNR 領域では、3 手法の NMSE はほぼ一致している。前節の新基地局設置時の評価と同様に、ノイズ環境における予測性能は補間手法の違いよりも SNR の影響が支配的である。

4.4.2 セル内チャネル統計変動時

(a) セル内チャネル統計変動時 (LoS から NLoS への適応)

前節では NLoS 環境から LoS 環境への適応を検証したが、本節では逆方向の適応、すなわち LoS 環境から NLoS 環境への適応について評価する。都市部においては新規ビルの建設により、従来見通しが確保されていたセルにおいて遮蔽物が出現し NLoS 環境へ移行する状況が頻繁に生じる。このような環境変化に対しても、提案する時系列補間型ファインチューニング手法が有効であるかを検証する。

本実験では、ビル建設以前の LoS 環境で収集した CSI 系列により事前学習を行い、その後ビル建設により NLoS 環境へ変化した際に、限られたサンプル数でモデルを再適応させることを想定する。前節の評価では NLoS 環境で運用していたモデルを LoS 環境に適応させたが、本節では逆に LoS 環境で運用していたチャネル予測モデルを NLoS 環境に適応させる。LoS 環境から NLoS 環境への移行では、直接波が遮蔽されることでチャネルの変動特性が大きく変化するため、モデルの適応がより困難になることが予想される。

評価用データセットには、前節と同様に東京駅八重洲口周辺の地形データを用いる。図 3.5 に示した 2 種類の地形データのうち、本節ではビル建設前の LoS 環境（図 3.5a）を事前学習に用い、ビル建設後の NLoS 環境（図 3.5b）を評価対象とする。すなわち、前節とは事前学習環境と評価環境の役割を入れ替えた設定である。

実験手順は前節と同様とする。事前学習に用いるモデルアーキテクチャおよびハイパラメータは節 4.4.1 と同一である。補間手法には、第 3.3.2 節において有効性が確認されたスプライン補間、片側 3 点ずつの 4 次多項式近似、片側 3 点ずつの 5 次多項式近似の 3 手法を用いる。ファインチューニングの設定は前節と同様に、補間値を入力の 1 番目に配置する First パターンを採用する。

(b) ベースラインモデルの学習結果

LoS 環境の事前学習データを用いたベースラインモデルの学習結果を示す。図 4.8 にベースラインモデルの学習曲線を示す。横軸はエポック数、縦軸は NMSE である。

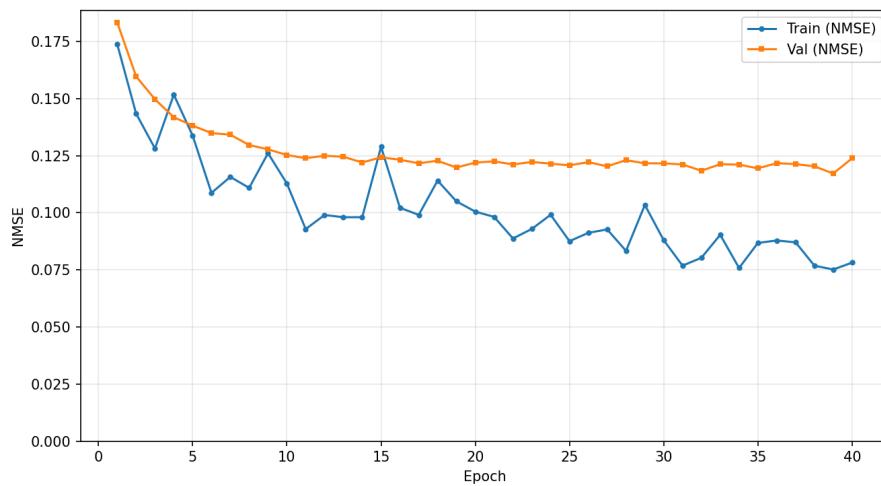


図 4.8 ベースラインモデルの学習曲線 (LoS から NLoS への適応)

学習用データの NMSE はエポック数の増加に伴い減少し、40 エポック終了時点で約 0.08 に収束している。検証用データの NMSE は初期エポックで急速に減少した後、約 0.12 前後で推移している。学習用データと検証用データの NMSE に約 0.04 の差が生じているが、検証用データの NMSE が発散していないことから、過学習の兆候は軽微であると判断できる。前節の NLoS 環境での事前学習（図 4.5）と比較すると、LoS 環境での学習は検証用 NMSE が若干高い傾向にあるが、学習の収束挙動は同様である。

次に、ファインチューニングを行わない状態でのベースラインモデルの予測性能を評価する。表 4.11 に、八重洲の NLoS 環境における評価結果を示す。予測なしとは前節と同様に、入力 3 フレームの最終時刻における CSI 推定値をそのまま出力時刻の推定値として使用する手法である。

表 4.11 ベースラインモデルと予測なしの NMSE 比較 (LoS から NLoS への適応)

Fold	ベースラインモデル (FT 前)	予測なし
0	0.506	0.205
1	0.487	0.209
2	0.496	0.221
3	0.484	0.193
4	0.462	0.201
平均	0.487	0.206

ベースラインモデル（ファインチューニング前）の NMSE は平均 0.487 であり、予測なしの平均 0.206 と比較して約 2.4 倍大きい値を示している。この結果は、LoS 環境で学習したモデルが NLoS 環境に対して適切に汎化できていないことを示す。前節の NLoS → LoS 適応（ベースライン NMSE 0.4096）と比較して、本節の LoS → NLoS 適応ではベースライン NMSE がより高い値を示している。LoS 環境では直接波が支配的であり比較的単純なチャネル特性を学習するが、NLoS 環境では多重反射による複雑な伝搬経路が存在するため、環境変化に伴う特性変動が大きく、モデルの汎化がより困難になっていると考えられる。この結果から、LoS → NLoS 適応においてもファインチューニングによるモデル適応が必要であることが示唆される。

(c) ファインチューニング結果

ベースラインモデルに対してファインチューニングを実施し、予測精度の改善を評価する。補間手法の選定にあたっては、第 3.3.2 節において有効性が確認されたスプライン補間、片側 3 点ずつの 4 次多項式近似、片側 3 点ずつの 5 次多項式近似を採用する。学習サンプルの構成については、前節と同様に補間値を入力の 1 番目に配置する First パターンを用いる。

表 4.12 に各補間手法を用いたファインチューニング結果を示す。表中の FT 後 NMSE および改善率は 5 分割交差検証における平均 ± 標準偏差である。

表 4.12 補間手法ごとのファインチューニング結果 (LoS から NLoS への適応)

補間手法	補間 NMSE	予測なし	ベースラインモデル	FT 後 NMSE	ベースラインモデルからの改善率
スプライン補間	0.0574	0.206	0.487	0.128±0.017	73.8±3.22%
片側 3 点ずつの 4 次多項式近似	0.0580	0.206	0.487	0.128±0.017	73.8±3.24%
片側 3 点ずつの 5 次多項式近似	0.0580	0.206	0.487	0.127±0.017	73.8±3.25%

5次多項式近似が最良の結果を示し、NMSEは 0.127 ± 0.017 となった。スプライン補間および4次多項式近似も同程度の精度を達成しており、3手法間のNMSE差は0.001以内に収まっている。ファインチューニング前のベースラインモデルのNMSE 0.487と比較すると、5次多項式近似では改善率 $73.83 \pm 3.25\%$ を達成した。予測なしのNMSE 0.206と比較しても、ファインチューニング後のモデルは約38%低いNMSEを達成している。

前節のNLoS → LoS適応(FT後NMSE 0.096、改善率約73%)と比較すると、本節のLoS → NLoS適応ではFT後NMSEがやや高く(0.127)、改善率は同程度(約74%)である。これは、NLoS環境における複雑なチャネル特性が予測をより困難にしているためと考えられる。しかしながら、提案手法により大幅な性能改善が得られており、セル内の環境変化に対してもモデルを効果的に適応できることが確認された。

次に、ファインチューニングに用いる学習サンプル数と予測精度の関係を評価する。前節のNLoS → LoS適応と同様に、少量のサンプルでどの程度の性能改善が得られるかを把握することは実運用において重要である。図4.9に、学習サンプル数を変化させた場合のファインチューニング後NMSEを示す。

比較対象の補間手法として、スプライン補間、片側3点ずつの4次多項式近似、片側3点ずつの5次多項式近似の3手法を用いた。

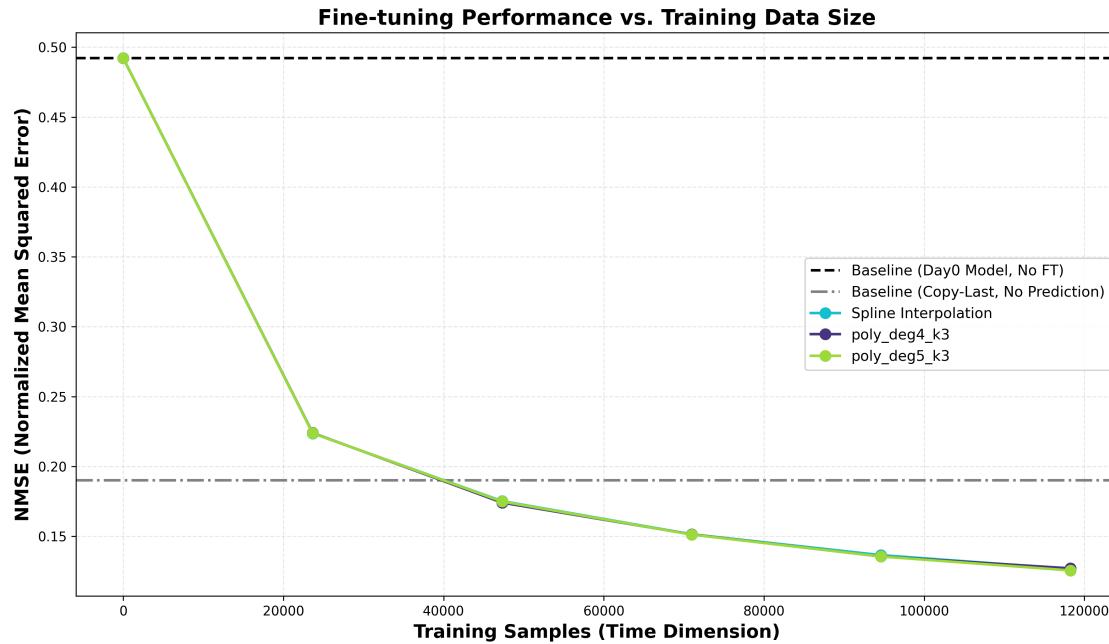


図4.9 学習サンプル数とファインチューニング後 NMSE の関係 (LoS から NLoS への適応)

図4.9から、全ての補間手法において学習サンプル数の増加に伴い NMSE が単調に減少する傾向が確認できる。図中の上側の水平破線はファインチューニング前のベースラインモデル (NMSE 約 0.49)，下側の水平破線は予測なし (NMSE 約 0.19) を示す。

スプライン補間，4次多項式近似，5次多項式近似の3手法は、全てのサンプル数において同程度の NMSE を示しており、曲線がほぼ重なっている。これらの手法では、学習サンプル数が 25,000 の時点で NMSE が約 0.22 となり、ベースラインモデルに対して約 55% の改善を達成している。学習サンプル数が 50,000 に達すると NMSE は約 0.175 となり、予測なしを下回る性能に到達する。さらに学習サンプル数を増加させると、70,000 サンプルで NMSE は約 0.15, 90,000 サンプルで NMSE は約 0.135 となり、120,000 サンプルでは NMSE は約 0.125 となって予測なしを大幅に上回る性能を達成している。

前節の NLoS → LoS 適応 (図4.6) と比較すると、本節の LoS → NLoS 適応では予測なしを下回るために必要なサンプル数がより多い傾向にある。NLoS → LoS 適応では約 40,000 サンプルで予測なしと同等になるのに対し、LoS → NLoS 適応では約 50,000 サンプルが必要である。また、最終的な NMSE についても、NLoS → LoS 適応では 100,000 サンプルで約 0.08 に達するのに対し、LoS → NLoS 適応では 120,000 サンプルでも約 0.125 にとどまっている。これらの差異は、NLoS 環境におけるチャネル変動の複雑さが

予測をより困難にしていることを反映している。

ただし、LoS → NLoS 適応においても学習サンプル数の増加に伴う一貫した性能改善が確認されており、十分なサンプル数を確保することで高い予測精度を達成できることが示された。

(d) 雑音に対する堅牢性評価

提案手法の雑音環境下における性能を評価するため、評価用 CSI に対して加法性白色ガウス雑音を付与し、各 SNR における予測 NMSE を測定した。雑音の付与方法は節 4.4.1 と同様である。

評価対象の SNR は −2, 0, 2, 4, 6, 8, 10, 15, 20 dB とした。比較対象の補間手法として、3 次スプライン補間、片側 3 点ずつの 4 次多項式近似、片側 3 点ずつの 5 次多項式近似の 3 手法を用いた。表 4.13 に各 SNR における予測 NMSE を示す。

表 4.13 各 SNR における予測 NMSE (LoS から NLoS への適応)

SNR [dB]	3 次スプライン	片側 3 点ずつの 4 次多項式	片側 3 点ずつの 5 次多項式
クリーン	0.127	0.127	0.126
20	0.127	0.127	0.126
15	0.127	0.127	0.127
10	0.130	0.128	0.128
8	0.130	0.131	0.130
6	0.134	0.134	0.133
4	0.139	0.140	0.139
2	0.147	0.148	0.147
0	0.160	0.160	0.160
−2	0.181	0.181	0.181

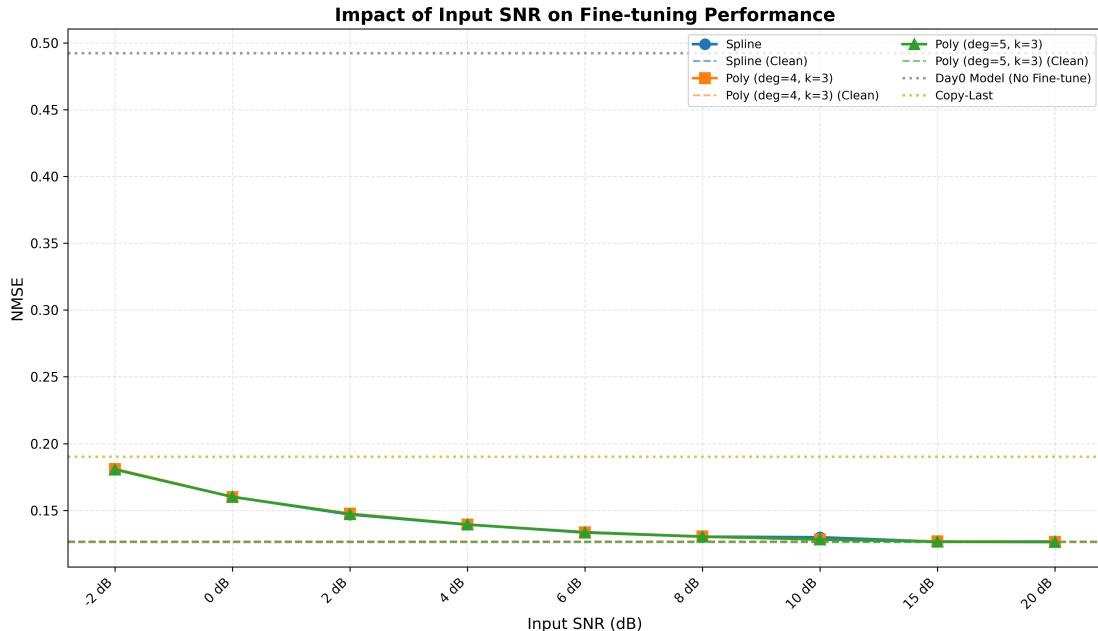


図 4.10 各 SNR における予測 NMSE (LoS から NLoS への適応)

表 4.13および図 4.10から、SNR の低下に伴い予測 NMSE が増加する傾向が確認できる。SNR が -2 dB のとき、3 次スプライン補間では 0.1806、片側 3 点ずつの 4 次多項式近似では 0.1811、片側 3 点ずつの 5 次多項式近似では 0.1805 の NMSE を示す。一方、SNR が 20 dB 以上の高 SNR 領域では、各手法の NMSE は 0.127 程度となり、クリーンな場合とほぼ同等の性能を維持している。

図中の水平破線はベースラインを示しており、上側の破線がファインチューニング前のベースラインモデル (NMSE 0.4921)、下側の破線が予測なし (NMSE 0.1901) である。ファインチューニング後のモデルは、SNR が -2 dB の低 SNR 環境においても予測なしを下回る NMSE (約 0.18) を達成している。SNR が 0 dB 以上では、ファインチューニング後のモデルは予測なしと比較して大幅に低い NMSE を示している。ファインチューニング前のベースラインモデルと比較すると、全ての SNR 条件においてファインチューニング後のモデルが大幅に低い NMSE を達成している。

3 つの補間手法を比較すると、各 SNR における NMSE の差は 0.001 以内であり、手法間の性能差は極めて小さい。特に SNR が 10 dB 以上の高 SNR 領域では、3 手法の NMSE はほぼ一致している。前節の NLoS \rightarrow LoS 適応と同様に、ノイズ環境における予測性能は補間手法の違いよりも SNR の影響が支配的である。

前節の NLoS \rightarrow LoS 適応 (表 4.10) と比較すると、本節の LoS \rightarrow NLoS 適応では SNR

が -2 dB のときの NMSE が 0.18 程度であり、前節の 0.13 程度よりも高い値を示している。これは、NLoS 環境における複雑なチャネル特性が雑音環境下においても予測を困難にしていることを示唆する。しかしながら、いずれの SNR 条件においてもファインチューニング後のモデルは予測なしおよびベースラインモデルを上回る性能を示しており、提案手法の有効性が確認された。

(e) セル内チャネル統計変動における双方向適応の比較考察

本節では、セル内チャネル統計変動時における 2 つの適応方向、すなわち NLoS \rightarrow LoS 適応（節 (g)）と LoS \rightarrow NLoS 適応（節 (a)）の実験結果を比較し、適応方向の違いが予測性能に与える影響について考察する。

(f) 実験結果の比較

表 4.14 に両方向の適応実験における主要な評価指標を整理する。

表 4.14 NLoS \rightarrow LoS 適応と LoS \rightarrow NLoS 適応の比較

評価指標	NLoS \rightarrow LoS	LoS \rightarrow NLoS
予測なし NMSE	0.140	0.206
ベースライン NMSE (FT 前)	0.410	0.487
FT 後 NMSE (最良)	0.0960	0.128
改善率	約 76%	約 74%
最良補間手法	4 次多項式近似	5 次多項式近似
SNR -2 dB 時 NMSE	0.13 程度	0.18 程度

表 4.14 から、全ての評価指標において NLoS \rightarrow LoS 適応が LoS \rightarrow NLoS 適応よりも優れた結果を示していることが確認できる。以下では、この差異が生じる要因について物理的な観点から考察する。

(g) LoS 環境と NLoS 環境のチャネル特性の違い

LoS 環境と NLoS 環境では、電波伝搬の物理的メカニズムが根本的に異なる。LoS 環境では送受信間に直接波が存在し、この直接波がチャネル応答の主成分となる。直接波は伝搬距離に応じた位相回転と自由空間伝搬損失により特徴づけられ、ユーザの移動に伴うドップラー周波数シフトも比較的予測しやすい挙動を示す。したがって、LoS 環境のチャネル時系列は滑らかな変動パターンを持ち、時間的相関が強い傾向にある。

一方, NLoS 環境では直接波が遮蔽物により遮断され, 散乱波や反射波のみがチャネル応答を構成する. 複数の反射経路が干渉し合うことでマルチパスフェージングが生じ, チャネル応答は振幅と位相の両方において急激な変動を示す. 特に, 各反射経路の遅延時間と到来角が異なるため, ユーザの微小な移動でも経路間の位相関係が大きく変化し, チャネル時系列は複雑で予測困難なパターンとなる.

(h) 予測なし性能の差異に関する考察

予測なし手法は直前の CSI 推定値をそのまま将来時刻の推定値として使用するため, その性能はチャネルの時間的相間に強く依存する. 表 4.14において, LoS 環境での予測なし NMSE (0.1397) が NLoS 環境 (0.2056) より約 32% 低い値を示している. この差異は, LoS 環境のチャネルがより強い時間的相関を持ち, 時間変動が緩やかであることを反映している.

NLoS 環境では, マルチパスフェージングによる急激なチャネル変動が生じるため, 直前の観測値と現在の真値との乖離が大きくなる. この結果として, 予測なし手法の予測誤差が増大し, NLoS 環境での予測なし NMSE が高い値を示している.

(i) ベースラインモデルの汎化性能に関する考察

ファインチューニング前のベースラインモデルの NMSE は, NLoS \rightarrow LoS 適応で 0.4096, LoS \rightarrow NLoS 適応で 0.4869 であり, LoS \rightarrow NLoS 適応の方が約 19% 高い値を示している. この差異は, 事前学習環境と評価環境の特性差がモデルの汎化性能に与える影響を示唆している.

NLoS \rightarrow LoS 適応では, 複雑な NLoS 環境で事前学習したモデルを比較的単純な LoS 環境に適用する. NLoS 環境での学習により, モデルは多様なチャネル変動パターンを学習しており, LoS 環境における規則的な変動パターンに対しても一定程度の予測能力を発揮できると考えられる. すなわち, 複雑な環境での学習が単純な環境への汎化を部分的に可能にしている.

一方, LoS \rightarrow NLoS 適応では, 比較的単純な LoS 環境で事前学習したモデルを複雑な NLoS 環境に適用する. LoS 環境では直接波が支配的であり, チャネル変動は主にドップラー効果による滑らかな位相回転として現れる. このような限定的なパターンのみを学習したモデルは, NLoS 環境における急激な振幅変動やマルチパスフェージングに対応できず, 汎化性能が低下する. この結果として, LoS \rightarrow NLoS 適応ではベースライン NMSE がより高い値を示している.

(j) フайнチューニング効果の差異に関する考察

ファインチューニング後の NMSE は, NLoS → LoS 適応で 0.0960, LoS → NLoS 適応で 0.1275 であり, 約 33% の差が生じている. 改善率についても, NLoS → LoS 適応が約 76%, LoS → NLoS 適応が約 74% と, 若干の差異が見られる.

この差異は, 目標環境である LoS 環境と NLoS 環境の本質的な予測困難度の違いに起因すると考えられる. 前述のように, LoS 環境のチャネルは時間的相関が強く滑らかに変動するため, 時系列予測モデルにとって学習・予測が容易である. 一方, NLoS 環境のチャネルは急激な変動を示すため, 同程度の学習データとモデル容量では, LoS 環境と同等の予測精度を達成することが困難である.

ただし, 両方向とも 70% 以上の改善率を達成しており, 提案する時系列補間型ファインチューニング手法は適応方向に関わらず有効に機能することが確認された. LoS → NLoS 適応においても予測なしと比較して約 38% の NMSE 改善を達成しており, 実用上十分な性能向上が得られている.

(k) 雑音環境下における性能差に関する考察

SNR が -2 dB の低 SNR 環境において, NLoS → LoS 適応では NMSE が 0.13 程度, LoS → NLoS 適応では 0.18 程度を示しており, 約 38% の差が生じている. この差異は, クリーン環境での性能差 (約 33%) よりも拡大している.

雑音環境では, CSI 推定値に加法性雑音が重畠されるため, 時系列データから真のチャネル変動パターンを抽出することがより困難になる. NLoS 環境では元来チャネル変動が複雑であるため, 雑音の影響を受けた際に真のチャネル変動と雑音成分を分離することがより困難になる. この結果として, LoS → NLoS 適応では雑音環境における性能劣化がより顕著に現れている.

しかしながら, LoS → NLoS 適応においても SNR が -2 dB の条件で予測なし (NMSE 0.1901) を下回る性能を維持しており, 提案手法は雑音環境においても有効に機能することが確認された.

4.5 パイロット疎化拡大に伴う無線チャネル予測機構評価

前節までの評価では, 3 入力 1 出力の機械学習モデルを用いた. パイロット信号の送信周期を 5 ms とすると, この設定は 20 ms あたり 1 回のパイロット送信を予測により削減できることを意味する. すなわち, 4 スロット中 3 スロットで推定値を取得し, 残り 1 ス

ロットの参照信号送信を省略する運用に相当する。

本節では、パイロット信号の削減割合をさらに大きくした場合についても、提案したチャネル予測機構によりモデルの精度を改善しつつ運用が可能であるかを評価する。

入出力の時間間隔を変化させることで、同一の3入力1出力モデルを用いながらパイロット送信の削減割合を増加させることができ。疎化パターンは、推定値 \mathbf{H} が得られるスロットと予測値 $\widehat{\mathbf{H}}$ で代替するスロットの周期的な配置として定義する。本研究では、周期4出力1パターン、周期3出力1パターン、周期2出力1パターンの3種類を検討する。

各パターンの時系列配置と予測モデルへの入出力対応を表4.15に示す。

表4.15 疎化パターンと入出力の対応

パターン	時系列配置	入力	出力
周期4出力1	$\mathbf{H}, \mathbf{H}, \mathbf{H}, \widehat{\mathbf{H}}, \dots$	$\mathbf{H}_{t-3}, \mathbf{H}_{t-2}, \mathbf{H}_{t-1}$	$\widehat{\mathbf{H}}_t$
周期3出力1	$\mathbf{H}, \mathbf{H}, \widehat{\mathbf{H}}, \dots$	$\mathbf{H}_{t-4}, \mathbf{H}_{t-2}, \mathbf{H}_{t-1}$	$\widehat{\mathbf{H}}_t$
周期2出力1	$\mathbf{H}, \widehat{\mathbf{H}}, \dots$	$\mathbf{H}_{t-5}, \mathbf{H}_{t-3}, \mathbf{H}_{t-1}$	$\widehat{\mathbf{H}}_t$

周期4出力1パターンでは4スロット中1スロットを予測で代替し、削減率は25%である。周期3出力1パターンでは3スロット中1スロットを予測で代替し、削減率は約33%となる。周期2出力1パターンでは2スロット中1スロットを予測で代替し、削減率は50%に達する。

いずれのパターンでも、予測対象となる $\widehat{\mathbf{H}}$ スロットの直前に存在する3つの \mathbf{H} スロットを入力として選択する。周期4出力1パターンでは直前3スロットが連続して \mathbf{H} であるため、時刻 $t-3, t-2, t-1$ の CSI を入力とする。周期3出力1パターンでは $t-3$ が $\widehat{\mathbf{H}}$ スロットとなるため、これを避けて $t-4, t-2, t-1$ を選択する。周期2出力1パターンでは1スロットおきに $\widehat{\mathbf{H}}$ が配置されるため、 $t-5, t-3, t-1$ の3点を選択する。

このように入力の時間間隔を調整することで、モデルの入出力形式を3入力1出力に統一したまま、異なる削減率に対応した学習データを生成できる。

提案機構では、補間値を用いてファインチューニング用の学習サンプルを構成する。各疎化パターンにおいて、サンプルの構成方法は複数存在する。入力の3スロットと出力の1スロットに対して、推定値 \mathbf{H} と補間値 $\widetilde{\mathbf{H}}$ をどのように配置するかによって異なる学習サンプルが得られる。本研究では、パターンごとに2種類のサンプル構成を比較し、どの構成が予測精度の改善に有効であるかを検証した。

各疎化パターンにおけるファインチューニング用サンプルの構成を表4.16に示す。

表 4.16 フайнチューニング用サンプルの構成

パターン	構成名	入力	出力
周期 3 出力 1	$\widetilde{H}HH\widetilde{H} \rightarrow H$	$\widetilde{H}, H, \widetilde{H}$	H
周期 3 出力 1	$H\widetilde{H}H \rightarrow H$	H, \widetilde{H}, H	H
周期 2 出力 1	$\widetilde{H}\widetilde{H}\widetilde{H} \rightarrow H$	$\widetilde{H}, \widetilde{H}, \widetilde{H}$	H
周期 2 出力 1	$HHH \rightarrow \widetilde{H}$	H, H, H	\widetilde{H}

周期 3 出力 1 パターンでは、時系列 $H, H, \widetilde{H}, H, H, \widetilde{H}, \dots$ において、入力の 3 スロットに補間値 \widetilde{H} が 1 つまたは 2 つ含まれる構成となる。 $\widetilde{H}HH\widetilde{H} \rightarrow H$ は入力に補間値を 2 つ含み推定値を出力とする構成である。 $H\widetilde{H}H \rightarrow H$ は入力に補間値を 1 つ含み推定値を出力とする構成である。

周期 2 出力 1 パターンでは、時系列 $H, \widetilde{H}, H, \widetilde{H}, \dots$ において、入力と出力の構成が大きく異なる 2 種類となる。 $\widetilde{H}\widetilde{H}\widetilde{H} \rightarrow H$ は入力がすべて補間値であり推定値を出力とする構成である。 $HHH \rightarrow \widetilde{H}$ は入力がすべて推定値であり補間値を出力とする構成である。

4.5.1 LSTM モデルにおける疎化拡大

本節では、LSTM モデルを用いて疎化拡大の評価を行う。用いる LSTM アーキテクチャは、節 4.3 で述べた 2 層スタック LSTM と同一である。

本節では、周期 3 出力 1 パターンおよび周期 2 出力 1 パターンを用いて評価する。周期 3 出力 1 パターンは 3 スロット中 1 スロットを予測で代替し削減率 33% に相当する。周期 2 出力 1 パターンは 2 スロット中 1 スロットを予測で代替し削減率 50% に相当する。

(a) ベースラインモデルの学習

周期 3 出力 1 パターンおよび周期 2 出力 1 パターンのベースラインモデルについて、学習曲線を図 4.11 および図 4.12 に示す。

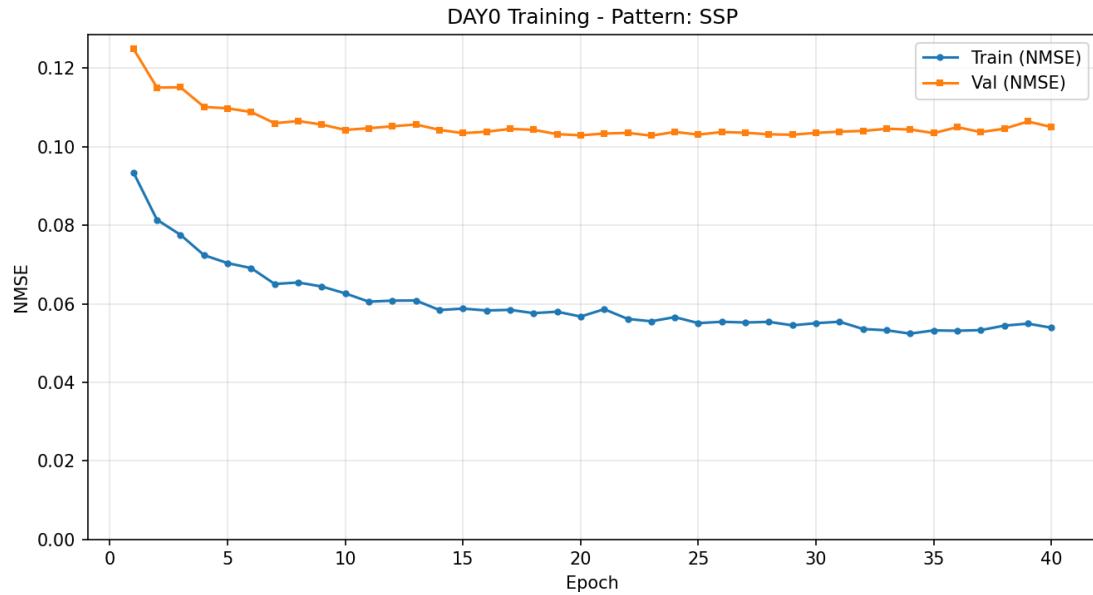


図 4.11 周期 3 出力 1 パターンにおける LSTM ベースラインモデルの学習曲線

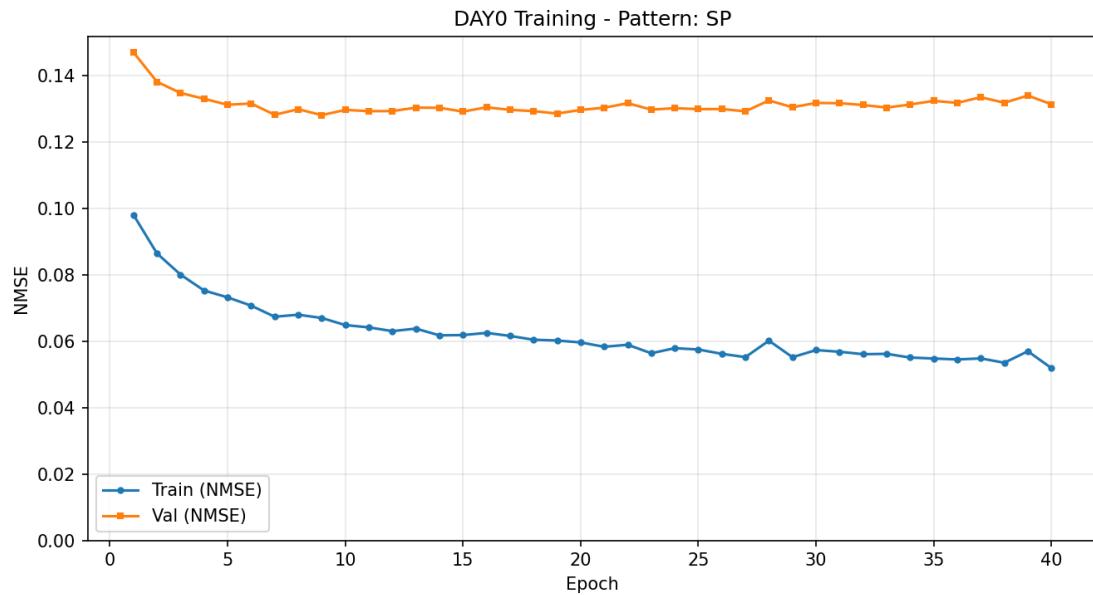


図 4.12 周期 2 出力 1 パターンにおける LSTM ベースラインモデルの学習曲線

両パターンとともに、検証 NMSE は序盤の 5 から 10 エポック程度で急激に低下し、その後はほぼ横ばいとなる。訓練 NMSE は 40 エポックまで緩やかに改善を続けるが、検証 NMSE の改善は限定的である。この傾向から、ベースラインモデルは早期に収束する特

性を持つことがわかる。

訓練 NMSE と検証 NMSE の間には一定の差が存在するものの、検証 NMSE が後半で悪化し続ける挙動は見られない。軽度の過学習が生じているが安定した状態を維持している。この差は、事前学習データと検証データの間の分布差、すなわち学習に用いた都市と評価に用いた都市の環境差に起因すると考えられる。

周期 3 出力 1 パターンと周期 2 出力 1 パターンを比較すると、周期 3 出力 1 パターンのほうが検証 NMSE が低い傾向にある。同一の LSTM アーキテクチャであっても、入力の観測密度が高いパターンのほうが予測精度が高くなることを示している。周期 3 出力 1 パターンでは入力間隔が狭く時間的に近接した観測値を利用できるため、予測対象との相関が強く保たれる。一方、周期 2 出力 1 パターンでは入力間隔が広がり、時間的に離れた観測値を用いるため予測が困難になる。

(b) ベースラインモデルの評価

予測なしとベースラインモデルについて、評価データに対する各分割の NMSE を表 4.17 および表 4.18 に示す。

表 4.17 周期 3 出力 1 パターンにおけるベースライン比較

Fold	予測なし NMSE	ベースライン NMSE
0	0.240	0.140
1	0.187	0.126
2	0.169	0.116
3	0.200	0.134
4	0.204	0.114
平均	0.200	0.126

表 4.18 周期 2 出力 1 パターンにおけるベースライン比較

Fold	予測なし NMSE	ベースライン NMSE
0	0.240	0.168
1	0.187	0.148
2	0.169	0.137
3	0.200	0.158
4	0.204	0.139
平均	0.200	0.150

周期 3 出力 1 パターンでは、ベースラインモデルが予測なしに対して平均 37.03% の改善を達成している。周期 2 出力 1 パターンでは平均 25.07% の改善にとどまる。疎化率が高くなるほど予測が困難になり、ベースラインモデルの性能優位性が縮小する傾向が確認できる。

(c) フайнチューニング後の性能

提案機構によるファインチューニング後の性能を周期 3 出力 1 パターンについて表 4.19、周期 2 出力 1 パターンについて表 4.20 に示す。表 4.16 で示した 2 種類のサンプル構成それぞれについてファインチューニングを実施した。補間手法として、3 次スプライン補間、片側 3 点ずつの 4 次多項式近似、片側 3 点ずつの 5 次多項式近似の 3 手法を比較した。

表 4.19 フайнチューニング後の予測性能（周期 3 出力 1 パターン）

サンプル構成	補間手法	予測なし	ベースラインモデル	FT 後 NMSE	ベースラインモデルからの改善率 [%]
$\overline{H} \overline{H} \overline{H} \rightarrow H$	3 次スプライン補間	0.200	0.126	0.0357 ± 0.0049	71.7 ± 2.71
$\widetilde{H} \widetilde{H} \widetilde{H} \rightarrow H$	片側 3 点ずつの 4 次多項式近似	0.200	0.126	0.0369 ± 0.0052	70.8 ± 2.53
$\widetilde{H} \widetilde{H} \widetilde{H} \rightarrow H$	片側 3 点ずつの 5 次多項式近似	0.200	0.126	0.0369 ± 0.0052	70.8 ± 2.53
$H \widetilde{H} H \rightarrow H$	3 次スプライン補間	0.200	0.126	0.0350 ± 0.0052	72.2 ± 3.25
$H \widetilde{H} H \rightarrow H$	片側 3 点ずつの 4 次多項式近似	0.200	0.126	0.0351 ± 0.0051	72.1 ± 3.24
$H \widetilde{H} H \rightarrow H$	片側 3 点ずつの 5 次多項式近似	0.200	0.126	0.0351 ± 0.0051	72.1 ± 3.24

表 4.20 フайнチューニング後の予測性能（周期 2 出力 1 パターン）

サンプル構成	補間手法	予測なし	ベースラインモデル	FT 後 NMSE	ベースラインモデルからの改善率 [%]
$\overline{H} \overline{H} \overline{H} \rightarrow H$	3 次スプライン補間	0.200	0.150	0.0580 ± 0.0092	61.4 ± 4.03
$\widetilde{H} \widetilde{H} \widetilde{H} \rightarrow H$	片側 3 点ずつの 4 次多項式近似	0.200	0.150	0.0679 ± 0.0124	54.8 ± 6.07
$\widetilde{H} \widetilde{H} \widetilde{H} \rightarrow H$	片側 3 点ずつの 5 次多項式近似	0.200	0.150	0.0679 ± 0.0124	54.8 ± 6.07
$H H H \rightarrow \widetilde{H}$	3 次スプライン補間	0.200	0.150	0.0477 ± 0.0060	68.2 ± 2.90
$H H H \rightarrow \widetilde{H}$	片側 3 点ずつの 4 次多項式近似	0.200	0.150	0.0507 ± 0.0060	66.2 ± 2.68
$H H H \rightarrow \widetilde{H}$	片側 3 点ずつの 5 次多項式近似	0.200	0.150	0.0507 ± 0.0060	66.2 ± 2.68

周期3出力1パターンでは、 $\mathbf{H}\widetilde{\mathbf{H}}\mathbf{H} \rightarrow \mathbf{H}$ と3次スプライン補間の組み合わせが最良の性能を示している。ベースラインから72.19%の改善を達成し、NMSEは0.0350まで低下した。周期2出力1パターンでは、 $\mathbf{H}\mathbf{H}\mathbf{H} \rightarrow \widetilde{\mathbf{H}}$ と3次スプライン補間の組み合わせが最良であり、68.20%の改善を達成してNMSEは0.0477となった。

サンプル構成間の比較では、入力に補間値を多く含む構成よりも、入力に推定値を多く含む構成のほうが高い改善率を示している。周期3出力1パターンでは、 $\widetilde{\mathbf{H}}\mathbf{H}\widetilde{\mathbf{H}} \rightarrow \mathbf{H}$ が71.65%であるのに対し、 $\mathbf{H}\widetilde{\mathbf{H}}\mathbf{H} \rightarrow \mathbf{H}$ は72.19%と若干の差がある。周期2出力1パターンでは差がより顕著であり、 $\widetilde{\mathbf{H}}\widetilde{\mathbf{H}}\widetilde{\mathbf{H}} \rightarrow \mathbf{H}$ が61.37%であるのに対し、 $\mathbf{H}\mathbf{H}\mathbf{H} \rightarrow \widetilde{\mathbf{H}}$ は68.20%と約7ポイントの差がある。入力に補間値が多く含まれると補間誤差がモデルに伝播しやすく、性能が低下すると考えられる。

補間手法間の比較では、3次スプライン補間が片側多項式近似よりも優れた性能を示す傾向にある。片側3点ずつの4次多項式近似と片側3点ずつの5次多項式近似は同一の性能を示しており、次数の違いによる差は見られない。

(d) パイロット削減と予測精度の両立

以上の結果から、パイロット信号を削減した場合においても、提案機構によるファインチューニング後のNMSEが予測なしよりも低く抑えられていることが確認できる。

予測なしのNMSEは約0.200であるのに対し、周期3出力1パターンでは最良構成で0.035、周期2出力1パターンでは0.048を達成している。周期2出力1パターンはパイロット送信を50%削減する設定であるが、それでも予測なしの約4分の1のNMSEを実現している。

この結果は、提案したチャネル予測機構がパイロット信号の削減と予測精度の維持を両立できることを示している。パイロット削減率を高めると予測が困難になりベースラインモデルの性能は低下するが、補間値を用いたファインチューニングにより新環境への適応が可能となり、実用的な予測精度を確保できる。

4.5.2 多出力LSTMモデルによる疎化拡大

前節までの評価では、予測モデルの出力を1フレームとしていた。本節では、出力フレーム数を拡張し、複数フレームを同時に予測する多出力構成について評価する。予測ホライズンを拡張することで、より多くの予測スロットを一度に生成でき、パイロット信号の削減効果をさらに高められる。

本実験では、周期3・2出力パターンと周期4・3出力パターンの2種類を検討する。周

期3・2出力パターンは周期3で2フレームを同時に予測する構成であり、周期4・3出力パターンは周期4で3フレームを同時に予測する構成である。入力フレーム数は両パターンとも6フレームとする。

(a) 多出力LSTMのアーキテクチャ

多出力LSTMでは、過去 $T_I = 6$ フレーム分のCSIを入力とし、将来 T_O フレーム分のCSIを同時に回帰する。周期3・2出力パターンでは $T_O = 2$ 、周期4・3出力パターンでは $T_O = 3$ である。

■入力層 入力は各フレームのCSIをベクトル化して結合した $\mathbf{x} \in \mathbb{R}^{T_I \cdot F}$ である。本実験の設定では $T_I = 6$ 、 $F = 3072$ より $\mathbf{x} \in \mathbb{R}^{18432}$ となる。バッチサイズを B とすると入力形状は $[B, T_I \cdot F] = [B, 18432]$ である。この入力を時系列へ再整形し、

$$\mathbf{X} \in \mathbb{R}^{B \times T_I \times F} = \mathbb{R}^{B \times 6 \times 3072} \quad (4.9)$$

を得る。 \mathbf{X} は6フレームからなる系列であり、各タイムステップは3072次元のCSIベクトルに対応する。

■LSTM層 節4.5.1と同様に2層のスタックLSTMを用いる。第1層は入力 $[B, 6, 3072]$ を受け取り、隠れ状態次元512の系列出力 $[B, 6, 512]$ を出力する。第2層は第1層の出力を入力とし、 $[B, 6, 512]$ を出力する。層間にDropout $p = 0.1$ を適用する。

■特徴抽出 第2層LSTMの最終タイムステップの隠れ状態 $\mathbf{h}_{T_I} \in \mathbb{R}^{B \times 512}$ を特徴量として用いる。 \mathbf{h}_{T_I} は過去6フレームの情報を集約した固定長表現である。

■全結合層 抽出した特徴量 \mathbf{h}_{T_I} を全結合層へ与え、複数フレームのCSIベクトルを同時に回帰する。全結合層は以下の構成とする。

- Linear(512 → 512) → ReLU → Dropout($p = 0.1$)
- Linear(512 → 256) → ReLU → Dropout($p = 0.1$)
- Linear(256 → $T_O \cdot F$)

出力形状は $[B, T_O \cdot F]$ であり、周期3・2出力パターンでは $[B, 6144]$ 、周期4・3出力パターンでは $[B, 9216]$ となる。

(b) 入出力の時系列配置

各パターンにおける入出力の時系列配置を説明する。時刻 t を最初の出力時刻とし、入力と出力を離散オフセットで定義する。

周期 3・2 出力パターンでは周期 3 で \mathbf{H} と $\widehat{\mathbf{H}}$ が配置される。入力オフセットは $[-16, -13, -10, -7, -4, -1]$ であり、出力オフセットは $[0, 1]$ である。入力の各時刻は S スロットに対応し、出力の 2 時刻は P スロットに対応する。入力の最後の時刻 $t - 1$ が S スロットとなるため、 t は S の直後の P スロットである。

周期 4・3 出力パターンでは周期 4 で \mathbf{H} と $\widehat{\mathbf{H}}$ が配置される。入力オフセットは $[-21, -17, -13, -9, -5, -1]$ であり、出力オフセットは $[0, 1, 2]$ である。入力の各時刻は \mathbf{H} スロットに対応し、出力の 3 時刻は $\widehat{\mathbf{H}}$ スロットに対応する。周期 3・2 出力パターンと同様に、入力の最後の時刻 $t - 1$ が \mathbf{H} スロットとなる。

各サンプルの入出力は以下のように構成される。

$$\mathbf{X} = [\mathbf{H}_{t+o_0}, \mathbf{H}_{t+o_1}, \dots, \mathbf{H}_{t+o_5}] \in \mathbb{R}^{T_I \cdot F} \quad (4.10)$$

$$\mathbf{Y} = [\mathbf{H}_{t+u_0}, \mathbf{H}_{t+u_1}, \dots] \in \mathbb{R}^{T_O \cdot F} \quad (4.11)$$

ここで、 o_i は入力オフセット、 u_i は出力オフセットである。

(c) 予測なしベースライン

予測を用いないベースラインとして、予測なしの場合を定義する。予測なしとは入力系列の最終フレームを出力フレーム数だけ繰り返して出力する手法である。

評価データ $\mathbf{X} \in \mathbb{R}^{N \times (T_I \cdot F)}$ 、 $\mathbf{Y} \in \mathbb{R}^{N \times (T_O \cdot F)}$ に対して、予測なしの予測値は以下のように計算される。

$$\mathbf{x}_{\text{last}} = \mathbf{X}[:, (T_I - 1)F : T_I \cdot F] \in \mathbb{R}^{N \times F} \quad (4.12)$$

$$\widehat{\mathbf{Y}}_{\text{copy}} = \text{repeat}(\mathbf{x}_{\text{last}}, T_O) \in \mathbb{R}^{N \times (T_O \cdot F)} \quad (4.13)$$

周期 3・2 出力パターンでは同一フレームを 2 回、周期 4・3 出力パターンでは 3 回並べる。この手法は予測ホライズン中のチャネルが変化しないと仮定するベースラインであり、予測モデルの有効性を検証する基準となる。

(d) 学習条件

ベースラインモデルの学習条件を以下に示す。事前学習では 40 エポック、ファインチューニングでは 20 エポックの学習を実施する。ファインチューニング時の学習率は

1×10^{-4} とする。その他のハイパーパラメータは節 4.5.1 と同一である。

(e) 補間手法

本実験では、補間手法として 5 次多項式近似を採用する。多項式近似の設定は片側 3 点ずつの近傍 S スロットを用いる構成とする。表 3.2 に示したとおり、錦糸町データセットにおける補間精度評価において、5 次多項式近似は片側 3 点ずつの設定で NMSE 0.0059 を達成しており、スプライン補間と同等の高い補間精度を示した。この結果に基づき、本実験では 5 次多項式近似を用いて予測スロットの CSI を補間する。

(f) フайнチューニング用サンプルの構成

補間後の CSI 系列からファインチューニング用の学習サンプルを構成する方法を説明する。本実験では、入力に真値のみを用い、出力に補間値を用いる構成を採用する。

周期 3・2 出力パターンおよび周期 4・3 出力パターンにおける入出力の値の種別を表 4.21 に示す。入力の各オフセット位置は周期の倍数だけ離れた位置を指すため、全て \mathbf{H} スロットに対応する。出力の各オフセット位置は $\widehat{\mathbf{H}}$ スロットに対応し、補間値を用いる。

表 4.21 周期 3・2 出力および周期 4・3 出力パターンにおける入出力の値の種別

パターン	位置	オフセット	値の種別
周期 3・2 出力	入力	-16, -13, -10, -7, -4, -1	全て真値
周期 3・2 出力	出力	0, 1	全て補間値
周期 4・3 出力	入力	-21, -17, -13, -9, -5, -1	全て真値
周期 4・3 出力	出力	0, 1, 2	全て補間値

ファインチューニング用サンプルの生成では、出力時刻 t が必ず $\widehat{\mathbf{H}}$ スロットとなるよう設計している。時刻 t が $\widehat{\mathbf{H}}$ スロットであるかどうかは、 $t \bmod \text{period} \neq 0$ により判定する。周期 3・2 出力パターンでは周期 3、周期 4・3 出力パターンでは周期 4 である。入力オフセットは周期の倍数だけ離れた位置を指すため、入力時刻は全て \mathbf{H} スロットとなり真値を用いる。出力時刻は $\widehat{\mathbf{H}}$ スロットであるため補間値を用いる。

この構成により、入力には補間誤差を含まない真値のみを与え、出力として補間値を予測するようモデルを学習させる。前節までの評価では入力に補間値を含む構成も検討したが、入力に真値を多く含む構成のほうが高い改善率を示す傾向にあった。本実験でも同様の傾向を踏まえ、入力を全て真値とする構成を採用した。

(g) 予測なしベースラインの比較

周期3・2出力パターンおよび周期4・3出力パターンにおいて、予測を行わなかった場合の結果（予測なしおよび事前学習のみのベースラインモデル）を表4.22および表4.23に示す。

表4.22 周期3・2出力パターンにおけるベースライン比較

Fold	予測なし	ベースライン
0	0.463	0.427
1	0.381	0.340
2	0.338	0.351
3	0.403	0.376
4	0.385	0.346
平均	0.394	0.368

表4.23 周期4・3出力パターンにおけるベースライン比較

Fold	予測なし	ベースライン
0	0.618	0.528
1	0.548	0.476
2	0.478	0.476
3	0.576	0.509
4	0.524	0.433
平均	0.549	0.484

(h) 評価結果

周期3・2出力パターンおよび周期4・3出力パターンにおける評価結果を示す。5分割交差検証により各分割のNMSEを測定した。

表4.24に周期3・2出力パターン、表4.25に周期4・3出力パターンのファインチューニング結果を示す。表中のFT後NMSEおよび改善率は5分割交差検証における平均±標準偏差であり、改善率は各foldにおけるベースラインモデル(FT前)のNMSEからの削減率を集計したものである。

表 4.24 周期 3・2 出力パターンにおけるファインチューニング結果

補間手法	補間 NMSE	予測なし	ベースラインモデル	FT 後 NMSE	ベースラインモデルからの改善率
片側 3 点ずつの 5 次多項式近似	0.153	0.394	0.368	0.183 ± 0.024	50.4 ± 3.47%

表 4.25 周期 4・3 出力パターンにおけるファインチューニング結果

補間手法	補間 NMSE	予測なし	ベースラインモデル	FT 後 NMSE	ベースラインモデルからの改善率
片側 3 点ずつの 5 次多項式近似	0.262	0.549	0.484	0.317 ± 0.042	34.5 ± 7.40%

周期 3・2 出力パターンでは、ファインチューニング後の平均 NMSE は 0.183 ± 0.024 であり、ベースラインモデルと比較して $50.40 \pm 3.47\%$ の改善を達成した。予測なしの平均 NMSE 0.3941 と比較すると約 53.6% の改善である。

周期 4・3 出力パターンでは、ファインチューニング後の平均 NMSE は 0.317 ± 0.042 であり、ベースラインモデルと比較して $34.54 \pm 7.40\%$ の改善を達成した。予測なしの平均 NMSE 0.5487 と比較すると約 42.2% の改善である。

両パターンともにファインチューニングにより予測精度が改善されている。周期 3・2 出力パターンではベースラインからの改善率が約 50%，周期 4・3 出力パターンでは約 35% であり、出力フレーム数が増加するほど改善率は低下する傾向にある。予測ホライズンが長くなるほど予測が困難になるため、この傾向は妥当である。

4.6 おわりに

本章では、参照信号削減下における時系列 CSI 予測モデルの更新手法として、時系列補間型学習データを用いたチャネル予測機構を提案した。予測スロットでは参照信号を送信しないため正解ラベルが欠損するという問題に対し、後続スロットで得られる推定値から補間により欠損時刻の CSI を事後的に算出し、推定値と補間値で構成される学習サンプルを蓄積してモデルを更新する枠組みを示した。

提案機構の有効性を検証するため、レイトレーシングにより生成した CSI 系列を用いて 3 種類の適応シナリオを評価した。新基地局設置時の評価では、池袋、渋谷、新宿の 3 地域で事前学習したモデルを錦糸町環境に適応させた結果、スプライン補間および多項式近似を用いたファインチューニングにより約 79% の予測精度改善を達成した。セル内チャネル統計変動時の評価では、NLoS から LoS への適応で約 73%，LoS から NLoS への適応で約 74% の改善率を達成した。双方向の適応結果を比較すると、LoS 環境はチャネルの時間的相関が強く予測が容易であるため、NLoS から LoS への適応がより高い最終精度を達成する傾向にあることが確認された。

パイロット疎化拡大の評価では、削減率 33% の周期 3 出力 1 パターンで約 72%，削減率 50% の周期 2 出力 1 パターンで約 68% の改善率を達成した。多出力 LSTM を用いた予測ホライズン拡張では、2 フレーム同時予測の周期 3・2 出力パターンで約 50%，3 フレーム同時予測の周期 4・3 出力パターンで約 35% の改善率を達成した。予測ホライズンが長くなるほど改善率は低下するが、いずれの条件においてもファインチューニング後のモデルは予測なしを上回る予測精度を示した。

雑音環境下における評価では、SNR の低下に伴い予測 NMSE が増加する傾向が確認されたが、SNR が -2 dB の条件においてもファインチューニング後のモデルはベースラインを上回る性能を維持した。補間手法間の性能差は SNR の影響と比較して小さく、スプライン補間と多項式近似はほぼ同等の結果を示した。

以上の結果から、提案した時系列補間型学習データを用いたチャネル予測機構は、参照信号削減を維持しながら環境変化に追従したモデル更新を実現できることが確認された。

第5章

結論

5.1 本研究の主たる成果

本論文は、参照信号削減下における時系列 CSI 予測モデルの重み更新を目的として、時系列補間型学習データを用いたチャネル予測機構を提案しその評価を行った。本研究の成果は以下の 2 点である。

1 点目は、チャネル予測モデルの重み更新に有効な補間手法を特定した点である。線形補間、スプライン補間、多項式近似、ニューラルネットワーク補間の 4 種類を比較した結果、スプライン補間と 4 次多項式近似が NMSE 0.01 以下の高精度を達成した。パイロット信号の送信頻度を低減し欠損率が 25% から 50% に増加した場合においても、両手法は安定した補間精度を維持した。この結果から、時系列補間型学習データの生成に適した補間手法として、スプライン補間および 4 次多項式近似が有効であることを示した。

2 点目は、参照信号削減下でもモデル更新が可能な枠組みを提案し、その有効性を確認した点である。予測スロットでは参照信号を送信しないため正解ラベルが欠損するという問題に対し、後続スロットで得られる推定値から補間に由来する欠損時刻の CSI を事後に算出し、推定値と補間値で構成される学習サンプルを蓄積してモデルを更新する手法を提案した。レイトレーシングにより生成した CSI 系列を用いた評価では、新基地局設置時に約 79%，セル内チャネル統計変動時に約 73% から 74% の予測精度改善を達成した。パイロット削減率を 50% に拡大した場合においても、ファインチューニング後のモデルは予測を用いない場合を上回る性能を維持した。

以上の成果により、参照信号削減を維持しながら環境変化に追従したモデル更新が実現可能であることを示した。提案機構は、新規基地局への展開およびセル内の電波伝搬環境変化の両方に対応でき、時系列 CSI 予測の実運用における適応性向上に寄与する。

5.2 今後の課題

本研究における今後の課題と展望を述べる。

第一に、評価データの多様性に関する課題がある。本研究では錦糸町および八重洲の地形データから生成した CSI 系列を用いて評価したが、より多くの地域や環境条件を対象とした検証が求められる。都市部以外の郊外や屋内環境など、異なる電波伝搬特性を持つ環境での有効性を確認する必要がある。

第二に、補間手法の拡張に関する課題がある。本研究ではスプライン補間や多項式近似といった解析的手法と単純なニューラルネットワークを比較したが、GAN や拡散モデル

などより高度な生成モデルを用いた補間手法についても検討の余地がある。パイロット削減割合の拡大に伴い予測改善率が低下する傾向が確認されたため、高削減率においても精度を維持できる補間手法の探索が必要である。

第三に、ベースラインモデルの強化に関する課題がある。本研究では MLP および LSTM を用いたが、ファインチューニングを必要としない汎化性能の高いモデルとの比較により、提案機構の位置づけをより明確にできる。

第四に、シミュレーション条件の現実性に関する課題がある。本研究では単一端末の歩行軌跡を対象としたが、端末間干渉の考慮、新幹線やバスなど高速移動体への対応、場所ごとのデータ分布の偏りを考慮したサンプリング手法の検討が求められる。

第五に、評価指標の拡張に関する課題がある。本研究では NMSE を用いて CSI 予測精度を評価したが、予測した CSI を用いたビームフォーミングの結果として得られるスループットや誤り率など、通信品質に直結する指標での評価が実用性の観点から重要である。

謝辞

本研究は東京大学工学系研究科電気系工学専攻森川・成末研究室の森川博之教授、成末義哲准教授のご指導の下で行いました。本研究を進めるにあたり多くの方に支えて頂きました。ここに深く感謝の気持ちを表します。

森川博之教授には、本研究を行う機会を与えていただくと共に、オフィスアワーなどを通して多くの助言を賜りました。とりわけ研究に取り組む姿勢や未来に必要な技術を考え続けることの意義をご指導いただきました。深く感謝申し上げます。

成末義哲准教授には、本研究の基礎知識を学ばせていただくとともに、研究を進める上での考え方を数多く教えていただきました。研究テーマを考える段階から個別のミーティングを何度も組んでいただき、本当にありがとうございました。豊富な知識と経験に基づいた意見を下さり、多くの着眼点に気付かされ、また、日々の進捗に関して適切な助言をいただきました。心から感謝申し上げます。

修士課程の佐藤龍吾氏には、同じ通信グループの仲間としてテーマに関するアドバイスを近い視点からいただきました。深く感謝申し上げます。修士課程の嶋田大地氏には、研究に関する基礎事項を学ばせていただき、その細部まで探究する姿勢には驚かされました。深く感謝申し上げます。

博士課程の林政東氏、朱天昊氏には、大学院に入学し右も左も分からぬ私の質問に都度丁寧に答えてくださいました。多くのサポートをいただきました。深く感謝いたします。博士課程の山口温大氏には、弛まず堅実に研究を進めていく姿勢から多くの刺激をいただきました。深く感謝いたします。

修士課程2年生の森永智大氏には、研究の合間の雑談を通じてリラックスする機会をいただきました。深く感謝いたします。修士課程2年生の杉村洋介氏には、常にポジティブな態度で研究に腰を据えて取り組む姿からモチベーションを高めていただきました。深く感謝いたします。修士課程2年生の加賀谷湧氏には、規則正しくストイックな研究姿勢を見せる一方でメリハリのついた生活を送る姿から、自分自身も頑張ろうという気持ちをいただきました。深く感謝いたします。修士課程2年生の范維翰氏には、研究生活で苦しい

謝辞

ときにお互いに支え合うことができ、精神的な安定をいただきました。深く感謝いたします。

修士課程1年生の大久保諒一氏と蔡海濤氏には、入学当初から公私両面でお世話になり、楽しく知的な研究生活を送ることができました。深く感謝いたします。秘書の川北敦子さんには、快適に研究活動が行えるよう事務面でサポートしていただきました。深く感謝申し上げます。

学科同期の曹晨亭氏、全濟旭氏には、研究に関する情報交換や土日を使った研究活動に付き合っていただき、プライベートでも親しくしていただきました。深く感謝いたします。矢口真那斗氏には、AI関連の知識を多くご教示いただきました。深く感謝いたします。

最後に、私の研究活動を理解し、温かく寛容に支えてくれた家族に感謝の意を表し、謝辞の結びとします。

2025年1月22日

参考文献

- [1] M. Eladawi, “5G NR slot format deep dive,” <https://www.mohamedeladawi.com/5g-nr-slot-format-deep-dive-2/>. ref. Dec. 14, 2025.
- [2] PolicyTracker, “FDD (frequency division duplex) glossary page,” <https://www.policytracker.com/glossary/fdd/>. ref. Dec. 14, 2025.
- [3] S. Dongre and H. Rahbari, “Implicit channel coordination to tackle starvation attacks in 5G and Wi-Fi coexistence systems,” Proc. IEEE Global Communications Conference (GLOBECOM), pp.4136–4141, Rio de Janeiro, Brazil, Dec. 2022.
- [4] H. Jiang, M. Cui, D.W.K. Ng, and L. Dai, “Accurate channel prediction based on transformer: Making mobility negligible,” IEEE J. Sel. Areas Commun., vol.40, no.9, pp.2717–2732, Sept. 2022.
- [5] Y. Zhu, X. Dong, and T. Lu, “An adaptive and parameter-free recurrent neural structure for wireless channel prediction,” IEEE Trans. Commun., vol.67, no.11, pp.8086–8096, Nov. 2019.
- [6] 服部 武, 藤岡雅宣, 5G 教科書: LTE/IoT から 5G まで, インプレス標準教科書シリーズ, インプレス, 東京, 2018.
- [7] 3GPP, “TS 38.211: NR; physical channels and modulation,” https://www.3gpp.org/ftp/Specs/archive/38_series/38.211/. ref. Dec. 14, 2025.
- [8] R. Adeogun, “Toward intelligent fading channel prediction: A comprehensive survey,” IEEE Access, vol.13, pp.111260–111281, 2025.
- [9] C. Jiang, J. Guo, X. Li, S. Jin, and J. Zhang, “AI for CSI prediction in 5G-advanced and beyond,” China Commun., vol.22, no.11, pp.1–16, 2025.
- [10] J. Li, Q. Zhang, X. Xin, Y. Tao, Q. Tian, F. Tian, D. Chen, Y. Shen, G. Cao, Z. Gao, and J. Qian, “Deep learning-based massive MIMO CSI feedback,” Proc. 2019 18th International Conference on Optical Communications and Networks

- (ICOCN), pp.1–3, Huangshan, China, Aug. 2019.
- [11] 3GPP, “TR 38.821: Solutions for NR to support non-terrestrial networks (NTN),” https://www.3gpp.org/ftp/Specs/archive/38_series/38.821/. ref. Dec. 17, 2025.
 - [12] N. Wiener, Extrapolation, Interpolation, and Smoothing of Stationary Time Series: With Engineering Applications, MIT Press and John Wiley & Sons, Cambridge, MA, 1949.
 - [13] V. Arya and K. Appaiah, “Kalman filter based tracking for channel aging in massive MIMO systems,” Proc. 2018 International Conference on Signal Processing and Communications (SPCOM), pp.362–366, Bangalore, India, July 2018.
 - [14] Y. Zhang, J. Wang, J. Sun, B. Adebisi, H. Gacanin, G. Gui, and F. Adachi, “CV-3DCNN: Complex-valued deep learning for CSI prediction in FDD massive MIMO systems,” IEEE Wireless Commun. Lett., vol.10, no.2, pp.266–270, Feb. 2021.
 - [15] T. Ding and A. Hirose, “Fading channel prediction based on complex-valued neural networks in frequency domain,” Proc. 2013 International Symposium on Electromagnetic Theory (EMTS), pp.640–643, Hiroshima, Japan, May 2013.
 - [16] W. Jiang and H.D. Schotten, “Recurrent neural network-based frequency-domain channel prediction for wideband communications,” Proc. 2019 IEEE 89th Vehicular Technology Conference (VTC2019-Spring), pp.1–6, Kuala Lumpur, Malaysia, Apr. 2019.
 - [17] J. Yuan, H.Q. Ngo, and M. Matthaiou, “Machine learning-based channel prediction in massive MIMO with channel aging,” IEEE Trans. Wireless Commun., vol.19, no.5, pp.2960–2973, May 2020.
 - [18] W. Zheng, Z. Liu, Y. Yuan, J. Li, B. He, and F. Lin, “Fading channel prediction based on attention mechanism,” Proc. 2023 5th International Conference on Electronic Engineering and Informatics (EEI), pp.400–404, Wuhan, China, Jun. 2023.
 - [19] F. Yang, Y. Wu, F. Wang, and S. Gong, “Deep transfer learning-based downlink channel prediction for FDD massive MIMO systems,” IEEE Trans. Veh. Technol., vol.69, no.11, pp.13294–13299, 2020.
 - [20] L. Hoang, P. Frenger, and S. Eriksson, “Map-based foundation model for 5G massive MIMO channel prediction,” Proc. IEEE International Conference on

- Communications (ICC), Montreal, Canada, June 2025. To appear.
- [21] H.T. Hoang, T.N. Do, and G. Kaddoum, “Domain adaptation-enabled realistic map-based channel estimation for MIMO-OFDM,” Proc. 36th International Symposium on Personal, Indoor and Mobile Radio Communications (PIMRC), pp.1–6, Istanbul, Turkey, 2025.
 - [22] H. Kim, J. Choi, and D.J. Love, “Massive MIMO channel prediction via meta-learning and deep denoising: Is a small dataset enough?,” IEEE Trans. Wireless Commun., vol.22, no.6, pp.4014–4028, June 2023.
 - [23] B. Liu, X. Liu, S. Gao, X. Cheng, and L. Yang, “LLM4CP: Adapting large language models for channel prediction,” J. Commun. Inf. Netw., vol.9, no.2, pp.113–125, June 2024.
 - [24] J. Xu, S. Jere, Y. Song, Y.-H. Kao, L. Zheng, and L. Liu, “Learning at the speed of wireless: Online real-time learning for AI-enabled MIMO in NextG,” <https://arxiv.org/abs/2403.02651>, 2024. arXiv:2403.02651.
 - [25] M.A. Mohsin, M. Umer, A. Bilal, M.A. Jamshed, and J.M. Cioffi, “Continual learning for wireless channel prediction,” <http://arxiv.org/abs/2506.22471>, 2025. arXiv:2506.22471, ref. Dec. 28, 2025.
 - [26] M. Mohsin, W. Wang, S. Abeywickrama, J. Zhang, and C. Yuen, “Continual learning for channel estimation in time-varying environments,” IEEE Trans. Wireless Commun., 2025. Early Access.
 - [27] Z. Chen, Z. Zhang, Z. Yang, C. Huang, and M. Debbah, “Channel deduction: A new learning framework to acquire channel from outdated samples and coarse estimate,” IEEE J. Sel. Areas Commun., vol.43, no.3, pp.944–958, 2025.
 - [28] D. Li, H. Li, H. Zhang, and X. Gu, “A channel prediction scheme under the condition of incomplete history,” Proc. 2024 4th International Conference on Neural Networks, Information and Communication Engineering (NNICE), pp.1264–1268, 2024.
 - [29] E. Tekgul, J. Chen, J. Tan, F. Vook, S. Özen, and A. Jajoo, “Deep learning-based channel state information prediction with incomplete history,” Proc. 2022 IEEE Wireless Communications and Networking Conference (WCNC), pp.447–452, 2022.
 - [30] 3GPP, “Study on artificial intelligence AI and machine learning ML for NR air interface,” 3GPP TR 38.843, 2023. Release 18.

-
- [31] Nokia, “Scaling up AI/ML for cellular radio access,” <https://www.nokia.com/blog/scaling-up-aiml-for-cellular-radio-access/>, 2025. ref. Dec. 29, 2025.
 - [32] Others, “On the combination of AI and wireless technologies: 3GPP standardization progress,” <https://arxiv.org/abs/2407.10984>, 2024. arXiv:2407.10984, ref. Dec. 29, 2025.
 - [33] Wireless Infrastructure Association, “The challenges of artificial intelligence in the RAN,” <https://wia.org/the-challenges-of-artificial-intelligence-in-the-ran/>, 2025. ref. Dec. 29, 2025.
 - [34] T.M. Cover, “Universal portfolios,” Mathematical Finance, vol.1, no.1, pp.1–29, 1991.
 - [35] E. Kalnay, Atmospheric Modeling, Data Assimilation and Predictability, Cambridge University Press, Cambridge, UK, 2003.
 - [36] G. Evensen, “The ensemble Kalman filter: Theoretical formulation and practical implementation,” Ocean Dynamics, vol.53, pp.343–367, 2003.
 - [37] M.E.M. Makhlof, M. Guillaud, and Y. Vindas, “Multi-cell outdoor channel state information dataset (MOCSID),” Presented at the 2025 EuCNC & 6G Summit, 2025.
 - [38] A. Kurs, A. Karalis, R. Moffatt, J.D. Joannopoulos, P. Fisher, and M. Soljačić, “Wireless power transfer via strongly coupled magnetic resonances,” Science, vol.317, no.5834, pp.83–86, July 2007.
 - [39] T. Campi, S. Cruciani, and M. Feliziani, “Magnetic shielding of wireless power transfer systems,” Proc. 2014 International Symposium on Electromagnetic Compatibility, pp.422–425, Tokyo, Japan, Dec. 2014.
 - [40] J. Gama, I. Žliobaitė, A. Bifet, M. Pechenizkiy, and A. Bouchachia, “A survey on concept drift adaptation,” ACM Comput. Surv., vol.46, no.4, pp.44:1–44:37, 2014.

■ 発表文献

論文誌 (査読あり)

[1] IEEE Global Communications Conference (GLOBECOM 2026), 投稿予定.

総合大会

[2] 松橋悠, 佐藤 龍吾, 善村 聰至, 李 允成, 成末義哲, 森川博之, “時系列補間型学習データに基づく疎パイロット下の無線チャネル予測機構 電子情報通信学会総合大会, March 2026. (発表予定)